iPAS 中級 AI 應用規劃師

3.2

電腦視覺技術與應用

Computer Vision

從像素、卷積到場景理解；用任務與指標判斷模型。

圖解精讀教材 / 第 1 版

本章的記憶主線

輸出決定任務	特徵如何學習	結果如何驗證
分類／框／遮罩	CNN／ViT	IoU／mAP／風險

章節基本資訊

科目：L21 人工智慧技術應用與規劃

主要評鑑：L21102；銜接 L21203、L21301、L21302

預估閱讀：75～100 分鐘（估算，含解析、不含作答）

優先掌握：任務與標註、卷積／池化、Flatten、偵測架構、IoU／mAP、分類評估與遷移學習；依本冊列示試題與先備必要性排序。

完成後，你應該能夠

- 由輸出需求區分分類、偵測、語意／實例／全景分割。
- 讀懂卷積與池化數值、張量尺寸及 IoU 計算。
- 選擇評估指標，辨識資料、模型與部署的限制。

閱讀路線：任務／資料 p.2～6 → 模型／指標 p.7～18 → 應用／風險 p.19～24
考點與比對 p.25～26 → 練習 p.27～28 → 複習／來源 p.29～30
三題完整解析放最後 p.31～33，可先作答再翻閱。

看懂影像：先分清數字、特徵與任務

01 重點速覽 / Computer Vision（CV）由影像或影片擷取可用資訊。

- 影像可表示為高度 H、寬度 W、通道 C 的數值陣列。
- 分類給類別；偵測再給位置；分割提供像素區域。
- 卷積學局部模式；ReLU 加非線性；池化改變空間解析度。
- IoU 看重疊；AP／mAP 看偵測排序與匹配；指標不能混用。
- 真實效能還受標註、場域、延遲、隱私與公平性影響。

影像數字 → 特徵表示 → 任務輸出 → 業務判斷

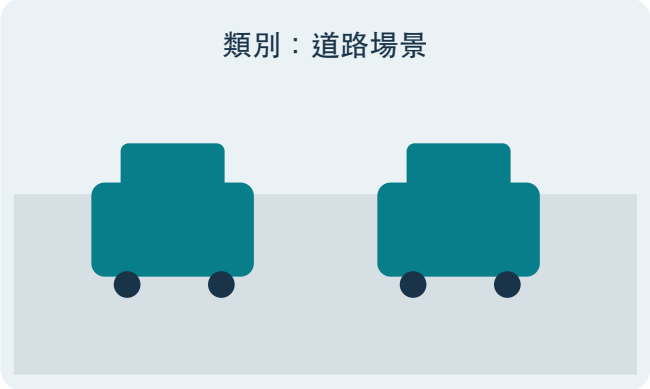
層次	白話與例子
像素／通道	RGB 常有三通道；128×128×3 表示空間尺寸及色彩通道，並非三張不同場景。
影像處理	調尺寸、降噪、改善亮度，處理的是輸入的數值與品質。
視覺理解	推論「有無瑕疵」「瑕疵在哪裡」，需要模型／規則與任務定義。
數值不等於語意	像素顏色相近不代表同物體；模型也可能學到背景捷徑。

記憶方式：鏡頭先把光變成數字，模型再從數字學模式。深度學習減少手工特徵負擔，但沒有讓資料與拍攝條件變得不重要。

同一張圖，四種不同的答案

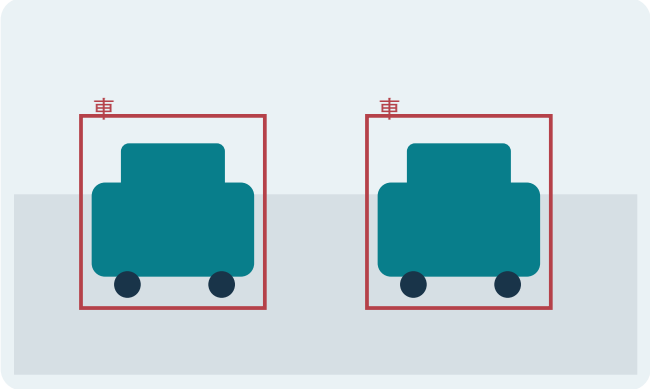
02 核心知識 A / 分類、物件偵測、語意分割與實例分割。

影像分類 Image Classification



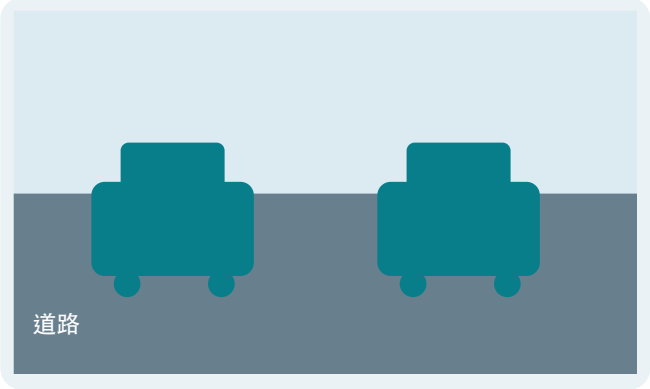
整張影像的類別，不提供每個物件的位置。

物件偵測 Object Detection



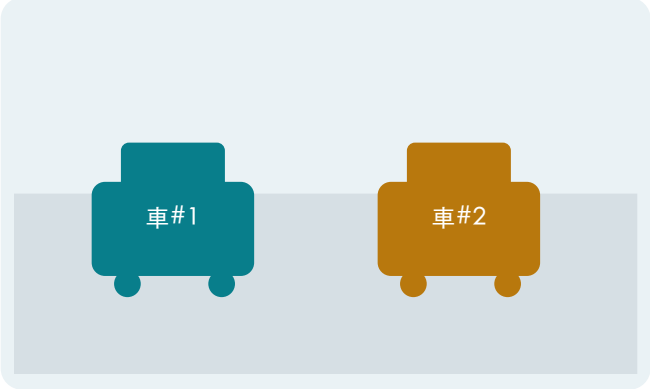
物件的類別 + 邊界框（Bounding Box）。

語意分割 Semantic Segmentation



每個像素的類別；兩台車使用同一類別色。

實例分割 Instance Segmentation



物件遮罩 + 個體；車#1、車#2 分開。

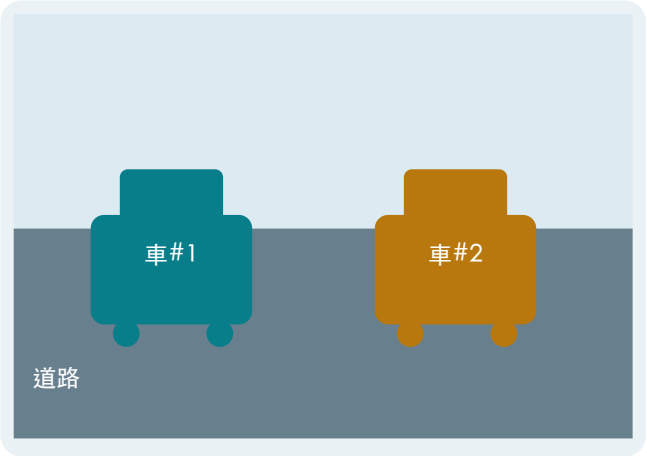
圖例：藍綠 = 車類別或車#1；琥珀 = 車#2；灰 = 道路。實例分割圖的其餘背景僅為參考底圖，不表示輸出已完整標記每個背景類別。

考試角度：【歷屆已考】115 年第一次 Q6 比較是否區分同類個體；Q7 要求每件商品的精確遮罩。看到框要想到定位；看到像素與個體才進一步分辨分割任務。

來源 [1] 3-41～42、3-49～51；[2] p.45～49；[6] Q6、Q7。示意圖為自編。

全景分割與標註：道路和每一台車都要交代

02 核心知識 B / Panoptic Segmentation 結合完整場景類別與物件個體。



Things：可數個體，如每台車。

Stuff：道路、天空等區域。

全景輸出為每個像素給類別，並區分 things 的實例；圖為簡化示意。

任務	標註／輸出要素
分類／偵測	影像標籤／物件類別與框座標。
語意／實例／全景	像素類別／物件個體遮罩／完整像素類別加個體資訊。
關鍵點／OCR	關節等點座標／文字區域及字串；Optical Character Recognition 是光學字元辨識。
標註品質	統一定義遮擋、難例與忽略區域；自動標註仍需覆核。

歷屆已考｜114 Q34 與 115 Q6 的題目邊界不同

114 年第二次 Q34 明列全景分割，要求每像素場景類別並區分同類個體，公告 D；115 年第一次 Q6 在語意／實例比較中，公告 C。不能只看到「分個體」便忽略完整題意與選項。

影像前處理：改了圖片，也要改對標註

02 核心知識 C / Resize、Padding、Cropping 與像素轉換。

處理	為什麼需要？	容易出錯的地方
尺寸調整／補邊／裁切	符合輸入尺寸、保留比例或選區域。	拉伸會變形；裁切可能剪掉病灶／瑕疵。
像素縮放／標準化	如 x/255；或 (x – mean)/std。	均值與標準差依預訓練規格或訓練集，不能亂套。
降噪／對比／Gamma	處理噪聲、亮度與對比差異。	太強可能抹掉細小瑕疵或改變判斷線索。
RGB／灰階／HSV	依任務保留色彩或亮度資訊。	灰階不是一般地只取藍色通道；丟掉顏色可能傷害任務。
資料增強／影格取樣	增加訓練變化；影片依時間取樣。	不是所有翻轉都合理；不要打亂必要時間資訊。

影像平移／縮放 → 框、遮罩、關鍵點同步轉換

例：框在 100×100 圖的座標為 (10,20,30,40)，等比例放大為 200×200 時，框也變成 (20,40,60,80)。分割類別遮罩縮放須保留離散標籤，常用最近鄰方式，避免產生不存在的類別值。

必記：增強應保留任務意義；例如文字左右翻轉、病灶方向改變，可能不適合直接沿用標籤。附件 p.52 的「只取藍色通道」是示範選通道，不能當標準灰階轉換定義。

來源 [1] 3-46～47；[2] p.50～54；[3] p.15～16。表與例子為自編。

資料與泛化：同一段影片不等於獨立樣本

02 核心知識 D / Data Leakage、Domain Shift、Transfer Learning。

泛化是在未見樣本上維持表現；**資料洩漏**讓測試資訊跑入開發流程，分數便可能過度樂觀。同病患、同產品或相鄰影格高度相似，要先依群組或時間切分，再只對訓練資料增強。

資料來源與標註

涵蓋白天／夜晚、設備與瑕疵種類；訂一致標準。

↓

切分與前處理

按病患、產品批次、鏡頭或時間切分；避免近重複跨集合。

↓

訓練與驗證

調參、門檻與增強以訓練／驗證資料決定。

↓

獨立場域測試

量測不同群體與條件；保留真實測試資料。

少量標註：先評估預訓練模型與遷移微調，不保證從零訓練越大越好。半監督學習結合未標註資料；主動學習挑選值得人工標註的樣本；自動標籤錯誤也可能被放大。

考點與限制：115 Q36 考少資料遷移學習；Q33 合成資料補充而非完全取代真實資料；Q37 的 SMOTE 是數值特徵空間插值觀念，不能直接宣稱原始像素插值必產生合理瑕疵影像。

CNN：由局部模式組合成任務線索

02 核心知識 E / Convolutional Neural Network，卷積神經網路。

白話：像拿可學習的小視窗掃描影像，逐層組合邊緣、紋理及更複雜模式。卷積的局部連結與權重共享，減少每個位置各自學一套參數的需求；並非每個濾鏡都能固定命名成「眼睛」或「斜線」。

輸入與卷積 Convolution

小卷積核在各位置計算，得到特徵圖 Feature Map。

↓

ReLU 非線性

整流線性單元（Rectified Linear Unit）：ReLU(x)=max(0,x)，不做機率正規化。

↓

池化／下採樣 Pooling

常用局部聚合降低空間尺寸；有些模型改用步幅卷積。

↓

任務輸出頭

分類、框、遮罩等輸出；不一定都使用 Flatten 接全連接。

必記｜層的角色不同，不是所有層都在「分類」

卷積學特徵；激活提供非線性；池化改變空間資訊；輸出頭對應任務。池化可減少計算與部分位置敏感度，卻不保證避免過擬合，也不保證完全平移不變。

算一次卷積：乘起來、加總，再過 ReLU

03 公式與計算 A / 單一通道、步幅 1、無補邊、bias=0。

輸入 X（3×3）

1	2	0
0	1	3
2	1	0

卷積核 K（2×2）

1	0
0	-1

左上角：

$1\times1+2\times0+0\times0+1\times(-1)=0$

每個視窗用相同 K 計算；不是只挑最大數。

卷積輸出（2×2）

0	-1
-1	1

ReLU 後（2×2）

0	0
0	1

其餘位置：右上 $2-3=-1$；左下 $0-1=-1$；右下 $1-0=1$。ReLU 逐元素處理，因此只把負數改成 0；卷積核的係數與影像像素都可影響結果。

延伸補充｜非原教材內容：以上精確計算用來理解卷積，不是官方歷屆數字題。實務卷積有多通道、多個核與偏差；數學卷積翻核和框架常見交叉相關的慣例須分清。

尺寸與池化：先看視窗，再看步幅

03 公式與計算 B / Stride（步幅）、Padding（補邊）、Kernel（卷積核）。

延伸補充｜非原教材內容：尺寸與參數

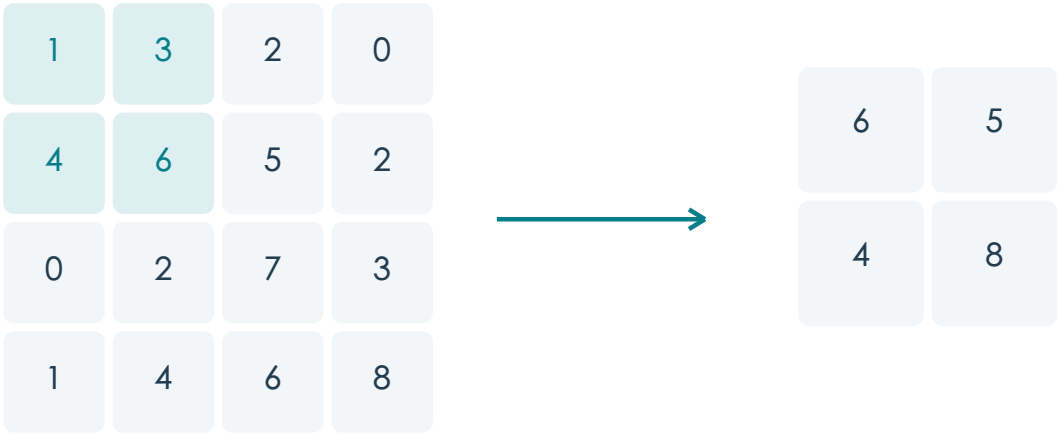
單一空間方向、dilation=1：

輸出長度 = floor((輸入長度 + 2P − K)/S) + 1

K：核大小；P：每側補邊量；S：步幅；floor：向下取整。

例：32×32、3 通道 → 8 個 3×3 核，P=1、S=2，輸出為 8×16×16（通道×高×寬）。groups=1 且每個輸出通道有 bias：參數 8×(3×3×3 + 1)=224。

Max Pool：2×2 視窗，步幅 2



左上視窗 [1,3;4,6]：Max Pool=6；Average Pool=(1 + 3 + 4 + 6)/4=3.5。一般池化不學卷積核權重；當通道不變，只縮小空間尺寸。

歷屆比較｜Softmax 與 Max Pool 的工作不同

114 年第二次 Q8 公告 C 的「保留所有資訊」太強：Softmax 給同維正規化分布，但不可逆；Max Pool 取每個局部區域的最大值。不要把兩者都當成取最大值。

Flatten、GAP、Softmax：三件不同的事

02 核心知識 F / 展平、全域平均池化與分類輸出。

操作	輸入 → 輸出（省略 batch）	會做什麼？
Flatten 展平	8×7×7 → 392	重排維度；不學權重，也不選特徵。
GAP 全域平均池化	8×7×7 → 8	每通道平均，縮減空間資訊；不是展平的同一計算。
Linear 全連接	392 → 類別數，或 8 → 類別數	學習加權映射，依前一層輸出形狀設定。
Softmax／Sigmoid	logits → 分類分數	互斥多類別常用 Softmax；多標籤常逐類用 Sigmoid。

```
# 示意形狀；N 表示 batch size
features: [N, 8, 7, 7]
flatten(start_dim=1): [N, 392]
Linear(392, 10): [N, 10]
```

Softmax 分數總和為 1，但高分不保證已校準，也不保證預測真實。不可把分類機率直接當作物件位置或分割遮罩。



歷屆已考｜115 年第一次 Q32 公告 B：Flatten

題目採傳統展平接全連接的指定路徑；選項 A 的 GAP 接全連接在合適架構也可行。因此記「本路徑需符合維度」，不要記成 CNN 一律必須 Flatten，或 GAP 是錯誤架構。

模型家族：抓設計重點，不背單一排名

02 核心知識 G / 傳統特徵、CNN 家族與預訓練模型。

家族／方法	應記住的設計觀念	判斷限制
Canny／SIFT／SURF／ORB	邊緣或特徵點；可搭配 SVM、KNN 等分類器。	手工特徵仍可能適合特定資源與場景。
LeNet／AlexNet	早期數字辨識／2012 ImageNet 的 CNN 里程碑。	不要將所有變體固定成同一層數。
VGG／GoogLeNet	小卷積核堆疊／Inception 多分支處理。	名字不是所有硬體上的最佳方案保證。
ResNet／DenseNet	殘差相加／跨層特徵串接。	相加與串接不同；尺寸與通道須相容。
MobileNet 等輕量模型	以資源效率為重要設計目標。	端上延遲、記憶體與準確度仍要實測。

殘差示意：y = F(x) + x

ResNet 讓模型可學習相對輸入的殘差，改善深層網路最佳化與資訊傳遞；形狀不同時可另用投影。不是保證所有梯度問題消失，也不是網路越深一定越準。

考試角度：115 Q36 在每類約 50 張的限制下，評估預訓練 CNN 遷移微調。判斷模型時一起看資料量、任務、資源、驗證結果，不把「新架構」當萬用答案。

來源 [1] 3-42～44、3-49、3-58；[3] p.21～23；[6] Q36；[10]。

偵測：一次預測，或先提議候選區域

02 核心知識 H / YOLO、SSD 與 Faster R-CNN。

物件偵測同時輸出物件類別與位置；通常另有分數。單階段和兩階段是流程差異，速度與精度仍受版本、輸入解析度、硬體與後處理影響。

單階段 | YOLO、SSD

影像 → 特徵 → 類別與位置預測

兩階段 | Faster R-CNN

特徵 → RPN 候選區域 → 區域分類與框修正

RPN：Region Proposal Network，區域提議網路。SSD：Single Shot MultiBox Detector，運用多尺度特徵進行單階段偵測。初代 YOLO 的具體設計不能套用所有後續版本。

延伸補充 | 非原教材內容：NMS（Non-Maximum Suppression，非極大值抑制）可依分數及重疊程度抑制重複框；不是每個新架構都必須用同一後處理。信心門檻、NMS 重疊門檻與評估 IoU 門檻，目的不同。

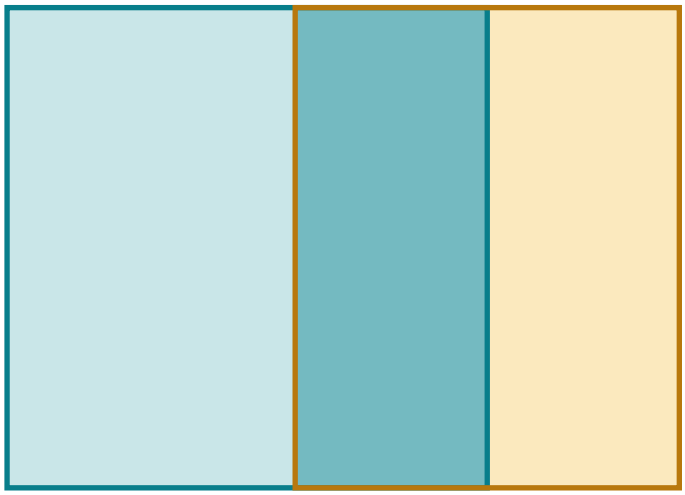
必記／考試角度：115 年第一次 Q10 公告 A，核心為單階段 vs 候選區域後分類。找到人臉不等於驗證身分；找到車牌框也不等於已讀出車牌文字。

來源 [1] 3-49～50；[6] Q10；[11][12]。流程為簡化示意。

IoU：重疊要除以聯集，不能把交集算兩次

03 公式與計算 C / Intersection over Union，交並比。

定義：IoU = 交集面積 / 聯集面積。可比較框或二元遮罩；兩者都非空時，範圍 0～1。評估門檻依資料集／任務決定，不是永遠固定 0.5。



真實框：10×10=100

預測框：8×10=80

交集：4×10=40

藍綠框 = 真實；琥珀框 = 預測；深藍綠 = 交集

$$IoU = 40 / (100 + 80 - 40) = 2/7 \approx 0.286$$

為什麼要減交集？100 + 80 把重疊區域算了兩遍，聯集只算一次。分母不是相加得到的 180，也不是直接挑真實框或預測框面積。

歷屆已考 | 114 年第二次 Q7：提高 IoU 門檻

代表定位匹配的重疊要求更嚴格，不代表同一模型的 mAP 必然上升。框要算真陽性，還須類別與匹配規則成立；不是只要 IoU 達標就能無限重複計分。

來源 [1] 3-51～52；[5] Q7。沿用來源面積數字，幾何圖為重新繪製。

AP／mAP：不能只看一個框有多準

03 指標與流程 / Average Precision；mean Average Precision。

先固定 IoU 門檻、類別與評估規則。按偵測分數排序，依規則把預測與真實物件一對一匹配；漏掉的目標影響 Recall，錯類、定位失敗或重複框可造成 FP。此處忽略 crowd／ignore 等進階規則。

排序／分數	匹配結果	累積 Precision	累積 Recall
1／0.9	TP	1/1 = 1	1/2 = 0.5
2／0.8	FP	1/2 = 0.5	1/2 = 0.5
3／0.7	TP	2/3 ≈ 0.667	2/2 = 1

例中真實目標共 2 個。AP概括 Precision – Recall 關係；若採「未插值、在每次 Recall 增加處平均 Precision」的簡化規則，本例 AP=(1 + 2/3)/2≈0.833。COCO 並非直接使用這個簡化算法。

報告寫法	該問清楚的條件
mAP@0.5	各類別在 IoU=0.5 下的 AP 再平均。
COCO AP@[.50:.95]	多個 IoU 門檻取平均，還固定 Recall 取樣、最大偵測數等條件。
比較模型	框 AP 與遮罩 AP、資料集、類別、尺寸與門檻須一致。

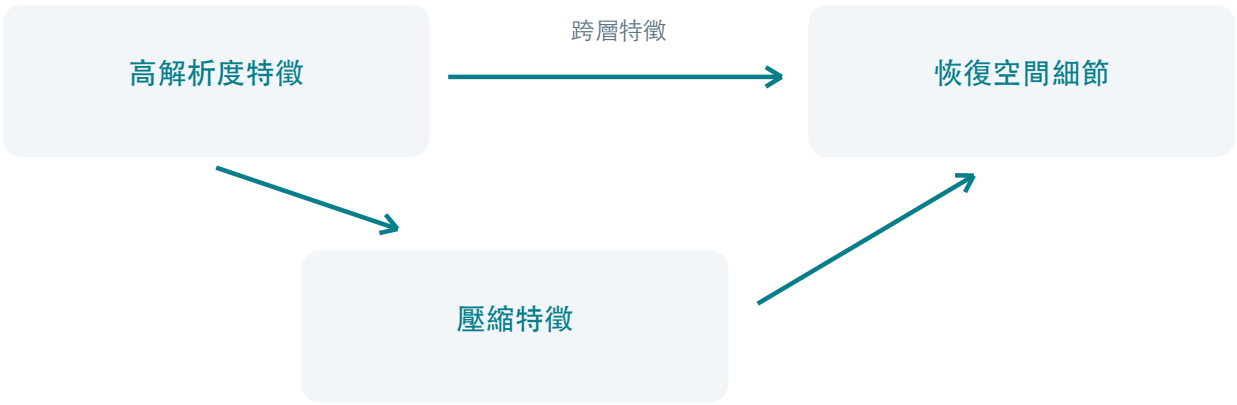
延伸補充｜非原教材內容：若兩類 AP 為 0.8、0.6，該固定設定下 mAP=(0.8 + 0.6)/2=0.7。它不是所有框 IoU 的平均，也不是單一分類準確率。

來源 [5] Q7；補充 [19] COCO 官方評估實作。本頁為簡化教學。

分割模型：保留語意，也要找回位置細節

02 核心知識 I / FCN、U-Net、Mask R-CNN 與 SAM。

模型	核心觀念	限制與辨識
FCN	Fully Convolutional Network：密集預測與上採樣。	上採樣恢復輸出尺寸，不等於找回所有遺失資訊。
U-Net	編碼器／解碼器，跨尺度 skip connection。	常用於醫學等分割；不只限醫療，也不自動解決不平衡。
Mask R-CNN	Faster R-CNN 加物件 mask 分支。	輸出個體遮罩，對應實例分割。
SAM	Segment Anything Model：可由點／框等提示產生遮罩。	不代表自動辨識所有類別，也不保證所有領域皆準。



白話：下採樣有助整合語意，較高解析度的特徵能提供定位細節；U-Net 的跳接把對應尺度的資訊帶給解碼端。不是把圖片縮小再放大就自動得到正確遮罩。

考試角度：【歷屆已考】115 Q6、Q7 要分清類別與個體；【推測題型】依每像素或每物件遮罩需求選模型，並辨識「自動保證準確」等過度敘述。

來源 [1] 3-44、3-50～51；[13][14][17]。U 形圖為概念示意。

分割評估：背景很準，不代表小瑕疵沒漏

03 公式與計算 D / 像素 Accuracy、IoU、mIoU 與 Dice。

以一個類別的二元遮罩為例：真實正區域 A、預測正區域 B。TP 是交集像素；FP、FN 分別是多畫與漏畫的像素。對分割問題先確認計數單位是像素、影像還是物件。

指標	定義	要小心什麼？
像素 Accuracy	判對像素 / 全部像素	背景 99% 時，全猜背景也可很高。
IoU	交集 / 聯集 = TP/(TP + FP + FN)	看正區域重疊；空集合處理要訂規則。
mIoU	指定類別的 IoU 平均	須明列背景、忽略類別與平均規則。
Dice coefficient	2×交集 / (|A| + |B|)	同一二元集合計數下，形式等同該類別 F1。

延伸補充｜非原教材內容：同一遮罩的兩種比例

$$|A| = 10，|B| = 8，交集 = 6$$

IoU=6/(10 + 8 – 6)=0.5；Dice=12/18≈0.667。
同一二元遮罩且聯集非空：Dice=2IoU/(1 + IoU)。先分別平均的 mIoU 通常不能直接換成平均 Dice；soft Dice 與空集合規則另訂。

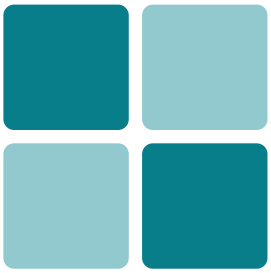
必記：mIoU 不是 mAP；遮罩 AP 還涉及物件匹配與分數排序。只有像素 Accuracy 高，可能掩蓋前景或少數類別的失敗。

來源 [1] 3-51～52、3-57～58；公式比較為延伸補充，不代表官方固定題型。

ViT 與圖文模型：影像也能變成 token

02 核心知識 J / Vision Transformer；CLIP；BLIP。

ViT將影像分成 patch，轉成向量並加入位置資訊，再交給 Transformer。不是把整張圖當一個詞，也不表示每個像素一定各自成為一個 token；混合 CNN／Transformer 架構也存在。



Patch 向量 + 位置資訊
→ Transformer → 任務輸出

模型概念	做什麼？	不要混淆
CLIP	Contrastive Language-Image Pre-training：圖文對比學習，共同嵌入空間比相似。	可做零樣本分類／搜尋；不等於直接生成圖片或詳細描述。
BLIP	Bootstrapping Language-Image Pre-training：圖文理解／生成模型的代表。	依訓練任務與模型設計，可做描述等；不能等同只有相似度。
ViT vs CNN	以 patch 間注意力／局部卷積作為主要表示機制。	不能不看資料與預訓練，就斷言一者永遠較準。

考試角度：114 年第二次 Q35 公告 A，考 CLIP 的圖文共同空間與零樣本分類。零樣本指此下游任務未用其標註樣本訓練，不表示模型從未預訓練；提示與類別文字仍會影響結果。

生成與合成資料：好看不等於真實可用

02 核心知識 K / GAN、Diffusion 與跨模態生成；細部原理銜接 3.3。

GAN 生成對抗網路

生成器與鑑別器互相學習

Diffusion 擴散模型

學習去噪，逐步生成樣本

Generative Adversarial Network（GAN）與 Diffusion Model 都能用於影像生成；它們不等於分類器或分割遮罩輸出。文字條件、圖像條件與編輯等能力依具體模型而異。

用途	為什麼有幫助？	仍須驗證
設計／影像編輯	產生草圖、創意或替代視覺版本。	物理細節、品牌、字元與權利來源。
合成訓練資料	補充罕見天候、角度或瑕疵情境。	是否涵蓋真實分布；標註與生成物件一致。
與辨識模型串接	先生成／修復，再分類或偵測。	修復可能創造不存在的線索，不能當真實觀測。



歷屆已考 | 115 年第一次 Q33：補充，不是完全取代

合成資料可增加情境，但仍需真實資料驗證。偽影、domain gap 與不合理標籤可能傷害模型；不要只比較影像美觀或把生成模型的自信當作品質保證。

範圍保留：原指引提及 GAN、Diffusion、文字生圖與跨模態，本冊先建立用途與限制；損失函數、去噪細節與生成風險將於 3.3／3.4 展開。

來源 [1] 3-40、3-42～44；[6] Q33。比較為概念導讀，不推測產品最新內部架構。

人臉、車牌與追蹤：定位之後還有任務

04 產業應用 A / Detection、Verification、Identification 與 OCR。

人臉偵測

找出哪裡有人臉；這一步沒有證明是誰。

↓

特徵與比對

取臉部表示；驗證 1:1 是不是聲稱的人，辨識 1:N 是資料庫哪個人。

↓

身分與授權

依使用情境設門檻、活體／防偽與人工處理，不把高相似當零風險。

場景	完整流程	關鍵限制
車牌 ANPR	先偵測車牌 → 校正／裁切 → OCR 讀字串。	框準不等於字串對；反光、角度與遮擋影響讀取。
人流追蹤	逐影格偵測，再跨影格關聯 ID。	單張偵測數相加不是不重複人數；遮擋會換 ID。
場域監控	事件規則、影像分析與人工查核整合。	誤報、漏報、隱私與權限需一起驗證。

必記：人臉偵測與身分比對的指標不同；車牌可再量測整串辨識正確率。工具框架名稱不保證特定辨識能力，實際流程要依輸出與驗證結果判斷。

來源 [1] 3-50、3-53；[2] p.57；[1b] 勘誤 p.3。例子與流程為自編。

製造與醫療：先定義錯一次會造成什麼

04 產業應用 B / 檢測瑕疵、量測區域與輔助判讀。

需求	可能任務	驗收要問
整片產品良／不良	影像分類	少數瑕疵 Recall、誤剔率與不同批次表現。
哪裡有刮痕	偵測或分割	位置／像素範圍、極細瑕疵及尺度。
量測病灶範圍	分割 + 專業判讀	邊界、設備與病患差異；不能只看總像素準確率。
篩檢異常影像	分類／偵測 + 覆核	敏感度與誤報、專家標註及真實場域驗證。

正類 = 瑕疵：FN 是漏放不良品，FP 是誤剔良品。

若 100 件中只有 1 件不良，全部猜良品也有 99% Accuracy，卻一件瑕疵都沒抓到。指標需對準業務成本，不能只挑最高百分比。

歷屆已考 | 115 年第一次 Q27：人機協作

題設需由人類承擔最終臨床決策，公告 A：Human-in-the-Loop（HITL）覆核架構。這是題目與系統設計觀念，不把附件「達資深醫師水準」延伸為所有設備、病種皆適用的準確度宣稱。

自駕、零售與 AR／VR：畫面以外的依賴

04 產業應用 C / 視覺結果常是更大系統的一個輸入。

應用	視覺扮演的角色	不可省略的條件
自動駕駛	車道、行人、障礙物偵測與場景分割。	感測器融合、追蹤、決策與控制；偵測正確不等於行車必安全。
智慧零售	商品／人流、路徑與停留熱區分析。	追蹤誤差、遮擋、授權與用途邊界。
AR 擴增實境	追蹤實體環境，疊加虛擬資訊。	定位穩定與低延遲；不只是生成一張圖。
VR 虛擬實境	追蹤動作並在虛擬環境回饋。	姿態估計、感測器與互動同步。

Augmented Reality（AR）與 Virtual Reality（VR）是應用介面；視覺感知可結合雷達、LiDAR 等感測器。多模態融合的細節保留到 3.4，不與單一影像分類混為一談。

端到端延遲 = 擷取 + 傳輸 + 前處理 + 推論 + 後處理

延伸補充｜非原教材內容：若希望以單一路徑每秒處理 30 張，平均每張預算約 1000/30≈33.3 ms；但佇列、平行管線與突發負載會改變實際延遲。FPS 吞吐量與單次回應時間不可直接當同一指標。

考試角度：【推測題型】依輸出與場域限制選方法，辨識「辨識準確就代表整個自動化系統安全」的過度推論。

來源 [1] 3-54～55；[2] p.59～60。延遲例與比對為自編。

分類指標：一個混淆矩陣算不出完整 AUC

03 公式與比較 E / Top-k、ROC 與 AUC；分類 F1 接續前冊。

指標	核心定義	常見混淆
Accuracy／F1	正確比例／Precision 與 Recall 的調和平均。	不平衡時只看 Accuracy 容易誤導。
Top-5 Accuracy	真實類別出現在前 5 名的樣本比例。	Top-5 Error = 1 – Top-5 Accuracy，兩者方向相反。
ROC 曲線	橫軸 FPR，縱軸 TPR；遍歷分數門檻。	不是橫軸 Precision，也不是 IoU。
ROC AUC	ROC 曲線下面積，概括分數排序辨識力。	單一門檻的混淆矩陣不足以直接得到完整 AUC。

$$TPR = TP/(TP + FN)；FPR = FP/(FP + TN)$$

假設病患為正類：TPR 表示病患中被抓到的比例；FPR 表示健康者中被誤報的比例。門檻改變時兩者可能一起變；AUC 高也不保證任何臨床／業務門檻都合適。

Top-5 例：100 張中有 90 張的真實類別在前五名，Top-5 Accuracy=90%，Top-5 Error=10%。原指引 3-49 以「前五名視為正確」描述的是判定規則；報告時要分清正確率與錯誤率。

歷屆已考：115 Q8 公告 B，ROC 的軸；Q9 公告 D，單一混淆矩陣不能直接算完整 AUC。若沒有連續分數或多門檻結果，不應自行補造 ROC 曲線。

風險：熱力圖、遮臉與平衡資料都不是保證

05 常見陷阱 A / 隱私、公平性與可解釋性各有不同檢查。

風險	例子	檢查與限制
隱私／授權	人臉、車牌、病患影像與可識別背景。	目的、權限、保留期限與必要去識別；模糊不保證無法再識別。
偏見／可靠性	對少數膚色、角度、鏡頭或夜間表現較差。	分群誤報／漏報，查標註與代表性；平均值高不保證各群公平。
偽影／捷徑	模型依設備浮水印或影像角落判病種。	跨設備測試、錯誤分析與遮蔽實驗；不能只挑漂亮個案。

延伸補充｜非原教材內容：Grad-CAM

Gradient-weighted Class Activation Mapping（Grad-CAM）利用目標分數對卷積特徵的梯度，生成粗略的類別關聯區域。可輔助檢查模型是否看向不合理位置，但不是病灶真實邊界，也不是完整因果證明。

歷屆已考｜115 年第一次 Q29 公告 C

題設 CNN、近即時、不能大量重複採樣，選 Grad-CAM。200 ms 是該題的需求，不是任何硬體皆能達到的保證；熱力圖也不能取代獨立標註、效能驗證或人工覆核。

來源中的法規名稱僅作風險意識；本冊不把「告知」「同意」或「刪除／加密」任何單一措施視為所有情境皆已合規。

部署與維運：相機換了，模型也要重新驗證

06 流程與限制 / 邊緣、雲端、效能與資料漂移。

場域測試

固定鏡頭、夜間、遮擋、不同批次；對應真實 FP／FN 與區域大小。

↓

部署效能

測端到端延遲、峰值記憶體、吞吐量、網路與異常負載。

↓

監控與回饋

畫質、光照／解析度分布與標註抽查；資料漂移不等於已證明性能下降。

↓

版本與回退

模型 + 前處理 + 門檻 + 類別順序共同管理；異常可切回或轉人工。

改善方式	不要誤記
輕量模型／量化／剪枝	各有精度、相容性及加速限制；不能只看參數量。
蒸餾／遷移學習	學生學教師／沿用預訓練能力；與 LoRA 或量化不同。
批次與邊緣推論	批次可增吞吐但增加等待；放邊緣仍須測裝置資源。

歷屆已考：115 Q40 題設不換硬體且邊緣延遲仍不符要求，公告 D 為 FP32→INT8 量化與推論優化。須在部署硬體重新測效能和精度；不是任何量化都必然達標。

來源 [1] 3-55～58；[3] p.61～71；[6] Q40。流程與指標例為自編。

考點索引：優先順序有證據，也有限制

07 考試重點整理 / 紅色優先、橙色理解；不是官方題目權重。

知識點	優先	方式與依據
分割任務／個體	優先掌握	【歷屆已考】114 Q34；115 Q6、Q7；全景與實例的題意不同。
CNN／池化／Flatten	優先掌握	【歷屆已考】114 Q8；115 Q32；指定路徑與替代架構分清。
偵測架構與 IoU	優先掌握	【歷屆已考】114 Q7；115 Q10；定位／流程差異。
ROC／AUC	優先掌握	【歷屆已考】115 Q8、Q9；指標軸與單一門檻限制。
遷移／合成／部署	優先掌握	【歷屆已考】115 Q33、Q36、Q40；資料與資源條件。
CLIP／解釋／HITL	優先掌握	【歷屆已考】114 Q35；115 Q27、Q29。
標註／前處理／風險	重要理解	【官方評鑑】L21102；【教材重點】3-45～47、3-56～58。

考前必記｜五個判斷

① 整張、框、像素、個體。② 卷積、激活、池化、輸出各司其職。③ IoU、mAP、mIoU 不混用。④ 判 TP 還要看類別與匹配。⑤ 效能與場域風險一起驗證。

證據界線：同一題可對應多概念，不能因此重複計成多道題；本冊的卷積、張量、AP 與 Dice 計算為自編補充，不宣稱已在這兩份試卷以相同形式出現。

來源 [4][5][6]。兩份科目一各 50 題，只列本節確認相關題；未統計頻率。

教材比對：保留觀念，修正過度簡化

08 常見陷阱與完整性 / 原教材重要內容已由獨立子 Agent 比對。

原教材／考題容易誤記處	本冊判斷方式
附件 p.52 灰階示範只取藍通道	視為選通道的示範；一般灰階轉換不等於只取 B。
池化可避免過擬合；CNN 必須 Flatten	只能說可能有幫助；GAP、步幅卷積等設計可替代部分流程。
ResNet 解決所有梯度消失；U-Net 天生處理不平衡	改善訓練／跨尺度定位，不是所有資料與梯度問題都消失。
Top-5 Error 寫成前五名內視為正確	辨識判定規則與誤差比例；Error=1 – Accuracy。
IoU 達 0.5 就算每個框都正確	看評估設定、類別、重複框與一對一匹配。
YOLO 可直接完成人臉／車牌辨識	定位不是身分比對，也不是字串 OCR。

已涵蓋：官方定義／演進、標註與前處理、分類／偵測／分割、IoU、四類產業應用及三面風險；附件圖例、CNN 流程與應用已重新組織。特徵點方法與工具僅保留用途辨識，不背工具清單當作任務定義。

待續界線：GAN／Diffusion 詳細訓練與多模態融合放到 3.3／3.4；進階部署與最佳化放後章。本冊不是兩份附件全書的完整處理保證，也不提供未查證的產品排名或現行法律結論。

練習 1／2：由需求辨識任務與資料策略

09 自編中級單選 / 不是官方原題 / 三題詳解置於最後 p.31～33。

01 觀念比較

街景系統必須輸出每個像素的類別，包含道路與天空，也必須區分每一台車的個體。在下列選項都可用時，哪項最直接對應完整需求？

A 影像分類，只為整張圖輸出道路場景。

B 物件偵測，只輸出每台車的邊界框。

C 語意分割，只標記車類別、不區分車輛個體。

D 全景分割，給出完整像素類別與車輛個體資訊。

我的選擇：_____

02 情境與應用

工廠每種瑕疵只有約 50 張標註影像，且多張來自同一產品連續拍攝。希望公平評估未見產品的分類表現，哪個起始策略較合理？

A 先按產品群組切分，再評估預訓練模型微調，僅增強訓練集。

B 先複製所有影像數十次，再隨機逐張切分訓練與測試。

C 把測試集加入微調以避免資料不足，仍稱獨立測試。

D 從零訓練最大 ViT，不需比較基準或不同場域。

我的選擇：_____

對應：全景分割、遷移學習與群組切分。

練習 3：IoU 計算與門檻判斷

09 自編中級單選 / 只考一個候選框，不含 crowd 或忽略區域。

真實框面積 100，預測框面積 80，交集面積 60。類別相同，但評估規定 IoU 至少 0.6 才通過定位匹配；此真實物件尚未被其他框匹配。哪項正確？

真實／預測面積

100／80

交集／門檻

60／0.6

A IoU=0.75，因此此預測可通過定位匹配。

B IoU=0.50，因此此預測不能通過定位匹配。

C IoU≈0.333，因此此預測不能通過定位匹配。

D IoU=0.60，因此此預測可通過定位匹配。

我的選擇：_____

請寫出聯集、IoU 與門檻比較：

考前 3 分鐘：從輸出一路檢查到部署

10 章節總整理 / 八項核心，回想圖解而不是只背模型名稱。

01 任務

整張類別／物件框／像素類別／個體遮罩；完整場景 + 個體看全景分割。

02 資料

影像變換須同步標註；先按產品／病患／時間切分，再增強訓練。

03 CNN

卷積算局部加權、ReLU 加非線性、池化聚合；Flatten 不學權重。

04 架構

YOLO／SSD 單階段；Faster R-CNN 候選區域；U-Net 跨尺度跳接。

05 IoU／AP

IoU=交集/聯集；AP 看排序與匹配，mAP 要報類別與 IoU 設定。

06 分割指標

mIoU 不等於 mAP；Dice=2交集/(兩區域面積和)。

07 分類／圖文

ROC：FPR→TPR；單一混淆矩陣不足算 AUC；CLIP 比圖文相似。

08 真實系統

定位不等於身分；高分不等於安全；看隱私、分群誤差與端上延遲。

記憶口訣：先看輸出，再看資料；算清尺寸與比例，最後驗證真實場域。

來源索引與補充範圍

11 來源可追溯 / 藍綠色條目可點開；數字是本冊引用索引。

[1] 官方科目一學習指引：3-40～3-58（PDF p.47～65）。

[1b] 官方學習指引勘誤表：3-46、3-53、3-55 用語修正。

[2] 附件001_人工智慧技術應用.pdf：p.43～60；含圖例與 CNN 流程。

[3] 附件002_AI導入評估.pdf：p.13～17、21～23、61～71、77～80 相關摘錄。

[4] 官方評鑑內容範圍參考 115.06：L21102 與本冊銜接項目。

[5] 114 第二次科目一：Q7、8、34、35。

[6] 115 第一次科目一：Q6～10、12、27、29、32、33、36、37、40。

[7] PyTorch 2.14 | Conv2d：運算、輸出尺寸與權重。

[8] PyTorch 2.14 | MaxPool2d：視窗、步幅與局部最大值。

[9] Li 等 | BLIP：圖文理解與生成。

[10] He 等 | Deep Residual Learning for Image Recognition。

[11] Redmon 等 | You Only Look Once。

[12] Ren 等 | Faster R-CNN。

[13] Ronneberger 等 | U-Net。

[14] He 等 | Mask R-CNN。

[15] Dosovitskiy 等 | An Image is Worth 16x16 Words（ViT）。

[16] Radford 等 | Learning Transferable Visual Models（CLIP）。

[17] Kirillov 等 | Segment Anything（SAM）。

[18] Kirillov 等 | Panoptic Segmentation。

[19] COCO 官方 cocoapi | cocoeval.py：AP 設定及匹配實作。

[20] scikit-learn 官方文件 | Metrics and scoring：分類、ROC、AUC。

[21] Selvaraju 等 | Grad-CAM。

證據屬性：【官方評鑑】範圍；【歷屆已考】可查證題號；【教材重點】原教材強調；【推測題型】教師推論。三題皆自編，並非官方原題。

延伸補充｜非原教材內容：精確卷積數值／尺寸／參數、GAP 形狀比較、簡化 AP、Dice、全景分割及 Grad-CAM 限制等，直接支援理解或歷屆題辨識；不代表每個細節都是官方逐項要求，進階實作不優先背誦。

覆蓋邊界：本冊針對官方 3.2 與附件 CV 章節；完整生成模型、多模態融合及進階部署留後章。所有圖解以自編示意為主，來源頁碼依原 PDF。

附錄解析 1：完整場景加個體，要看全景

12 答案與逐項解析 / 第 1 題 / 題目見 p.27。

正確答案 D

題目同時要求道路、天空等完整像素類別，以及每台車的獨立個體資訊，最直接對應全景分割。不能只抓「有車」或只畫框；完整場景類別是本題的重要條件。

選項	判斷與理由
A 錯誤	影像分類給整張類別，無法提供每個像素與每台車的資訊。
B 錯誤	框指出物件位置，但沒有覆蓋道路／天空等完整像素類別。
C 錯誤	語意分割可給每像素類別，但不區分同類車輛的不同個體。
D 正確	全景分割整合場景語意與可數物件的實例，符合完整需求。

解題關鍵｜題目有完整場景與全景選項，才做此判斷

114 Q34 與本題需求相近，但本題文字與圖為自編；115 Q6 在語意與實例的二者比較中選實例。不要只背「區分個體 = 某個固定選項」，應讀完整條件。回到 p.3～4。

附錄解析 2：資料少，更要保留獨立測試

12 答案與逐項解析 / 第 2 題 / 題目見 p.27。

正確答案 A

題目要評估未見產品。同一產品連拍通常高度相似，先依產品群組切分可降低近重複資料造成的洩漏；再用預訓練能力建立可比較基準，並只對訓練集增強。仍需驗證，不保證一次成功。

選項	判斷與理由
A 正確	同時處理獨立測試、少資料利用與增強範圍，符合題目目的。
B 錯誤	複製後隨機切分易把同圖或同產品分到兩邊，分數可能過度樂觀。
C 錯誤	把測試資料加入訓練後，就不能再當成未參與開發的獨立測試。
D 錯誤	最大模型不保證少資料下泛化最好；需比較基準與真實場域。

歷屆與補充要分清楚

115 年第一次 Q36 提供少量影像並考預訓練 CNN 遷移微調；本題另加入產品群組切分，是自編的資料洩漏判斷。兩個觀念可一起用，不代表原考題有這些細節。回到 p.6、p.11。

附錄解析 3：先算聯集，再比較門檻

12 答案與逐項解析 / 第 3 題 / 題目見 p.28。

正確答案 B

步驟	計算與判斷
聯集	100 + 80 – 60 = 120；交集只能計一次。
IoU	60 / 120 = 0.50。
門檻	0.50 < 0.60；即使類別正確，也不能通過本題定位匹配。

交集 / 聯集，不是交集 / 預測面積。

選項	判斷與理由
A 錯誤	0.75 是 60/80，把預測面積誤當聯集。
B 正確	聯集 120，IoU 0.50，小於題設 0.60。
C 錯誤	約 0.333 是 60/180，忘記由兩面積總和減掉交集。
D 錯誤	0.60 是 60/100，把真實面積誤當聯集。

題目特別給定同類別與尚未匹配，讓焦點放在定位。一般 AP 評估還要依分數排序、一對一匹配與其他設定計算；若 IoU 達標，也不能一概略過這些規則。回到 p.13～14。