數據準備與模型選擇

5.1 圖解精讀 / 把可用資料變成可靠特徵，再按任務與限制選模型。

共同科目 L21 | L21301

先把資料做好，再讓模型公平比較。

本章不只背演算法名稱。你會練習判斷資料是否可用、前處理是否洩漏答案、特徵是否適合任務，以及在品質、延遲與成本限制下，哪一類模型值得先驗證。

來源與品質
收集／檢核／修正

→

特徵工程
轉換／選擇／降維

→

模型選擇
任務／資料／限制

→

驗證比較
切分／指標／成本

閱讀方式	本冊安排
學習目標	能選擇清理與編碼方式，分清學習任務，解讀簡單公式與前處理程式。
優先程度	優先掌握：官方核心＋兩卷實際試題證據；學習優先序不代表官方配分。
時間估算	精讀約90～130分鐘；可分成「資料與特徵」及「模型與驗證」兩次。
練習與解析	題目在p.36～37；三題完整答案與所有選項解析集中最後p.40～42。

來源與技術查核日：2026.10.30。圖解、算例與練習自行編製；原教材易誤記處另註明適用條件。

本章速覽：六個必須會判斷的問題

01 學習地圖 / 官方範圍：資料收集、清洗預處理、特徵工程與模型優缺點。

01 資料代表什麼？

先定一列的粒度、鍵值、可用時間與標籤；不是抓到檔案就能直接訓練。

02 缺漏或極端值怎麼辦？

找原因與業務意義，再選填補、修正或排除，避免刪掉真正的異常案例。

03 轉換何時學習？

切分後，只在訓練資料擬合填補、縮放、選擇及重採樣等步驟。

04 少幾個特徵等於PCA嗎？

特徵選擇保留原欄位；PCA建立新座標。保留變異不等於保證預測能力。

05 類別、數值，還是行動？

分類、迴歸、分群與強化學習的目標不同；深度與生成另有觀察軸。

06 哪個模型「最好」？

在一致資料與指標上驗證，還要符合延遲、資源、解釋與維護條件。



學習順序 | 資料證據 → 特徵 → 任務 → 比較與選擇

3.1～3.4學過的文字、影像與生成技術，在本章重新放到資料準備與選型流程中；部署架構與線上維運留待5.2深入。

資料收集：內部與外部，都要追溯來源

02 核心知識 A / Data Collection；用途與預測當下的可得性一起確認。

來源	常見內容	適用情境
ERP	Enterprise Resource Planning；銷售、庫存、採購與財務。	需求預測、補貨與營運分析。
CRM	Customer Relationship Management；顧客互動、服務與回饋。	流失分類、服務分析與分群。
機台／使用紀錄	設備狀態、IoT、POS、Web／App事件與內部報表。	預測維護、異常偵測、流程改善。
外部來源	政府開放資料、API、網頁擷取與授權商業資料。	天氣、競品、外部市場與情境特徵。

來源
誰產生／哪個版本 →

意義
欄位／單位／時間 →

權限
用途與授權範圍 →

更新
頻率／歷史快照

常見陷阱｜公開可讀，不等於任意使用；欄位可取得，不等於當時可取得

外部API、社群與商業平台的條件不同，依實際授權與規範確認。預測流失時若使用事後解約結果作輸入，會把未來答案洩漏給模型。

來源 [1] 5-2～5-3；[2] p.12～14。

資料品質：先對齊粒度，再看五個面向

02 核心原理 B / Data Quality；不是只算缺失比例。

粒度Grain是「一列代表什麼」。顧客表一人一列，交易表一筆交易一列；直接連接後人數變多，不一定是多了顧客，可能只是同一顧客有多筆交易。

面向	要確認的事情	例子
完整性 Completeness	必要欄位與紀錄是否缺少。	故障時間、標籤或重要感測值缺漏。
一致性 Consistency	跨欄位／來源格式與規則是否一致。	同顧客出生日期矛盾、單位混用。
準確性 Accuracy	是否反映真實值與正確標籤。	溫度抄錯、履歷資格標註錯。
時效性 Timeliness	更新延遲是否符合用途。	把數月前的庫存當即時庫存。
唯一性 Uniqueness	在約定鍵值與粒度下是否重複。	同一交易ID被重複載入。



判斷法｜先定義資料，再選清理規則

對齊主鍵、時間與單位，檢查連接前後的筆數及涵蓋率。相同金額不等於重複交易；值看似合理，也未必代表與事實相符。標註品質與代表性須另行檢查。

來源 [1] 5-4；[2] p.13～16；粒度與連接例為延伸補充。

缺失值：原因比補哪個數字更重要

02 核心知識 C / Missing Values；缺失可來自未量測、失敗或不適用。

方法	什麼時候考慮	限制與陷阱
平均／中位數填補	用訓練資料估計數值代表值；偏態或極端值下可評估中位數。	改變變異與關聯；不能說補完就恢復真實資料。
前向填補 ffill	按同一實體時間排序，以過去最後可得值填補。	須限制間隔與情境；不能跨不同機台亂補。
後向填補／插值	離線修復且未來點確實可用時，依連續性假設處理。	線上預測可能用了未來資訊；不宜直接跨測試邊界。
模型推估／缺失指示	以其他可用欄位推估，或加入「原值是否缺失」。	仍需訓練內擬合及驗證；缺失本身可能帶有訊號。
刪列／刪欄	評估缺失程度、必要性、樣本量及偏差後。	沒有適用所有資料的固定刪除百分比。

白話：缺少年收入，不一定等於零收入；「尚未接受檢查」與「檢查正常」也不同。填補前先確認資料意義，必要時回到蒐集與標註流程。

必記｜填補器也會學習，所以也會洩漏

中位數、分組統計或模型參數只能從訓練部分估計；驗證／測試資料沿用同一套已學好的規則。時間序列需特別注意當時是否可得。

重複與異常：偵測到，不等於直接刪掉

02 重要比較 D / Duplicate Values與Outliers。

重複值：先看鍵與版本

同一交易被重送可去重；同顧客多次購買是合法多筆。資料訂正紀錄須決定保留版本。

異常值：先問錯誤或稀有

999°C可能是通訊錯值；大額交易也可能是要辨識的詐欺。兩者不能同樣處理。

方式	作用與邊界
Z-score／IQR	依數值或分布標出候選異常；門檻不是業務真偽的裁決。
Isolation Forest	以隨機切分隔離樣本；較容易被隔離者可作異常候選。
LOF	Local Outlier Factor；比較局部密度差異，依鄰域與尺度而變。
資料框去重	pandas用drop_duplicates；Spark有dropDuplicates及drop_duplicates別名。指定欄位後仍須確認保留語意。

歷屆已考｜115 Q38公告D：題幹已確認999°C是錯值

此時刪除該錯誤紀錄或合理填補較合適。不能靠Z-score把它「變合理」；標準化只是換尺度，不會修正不可能的量測值。

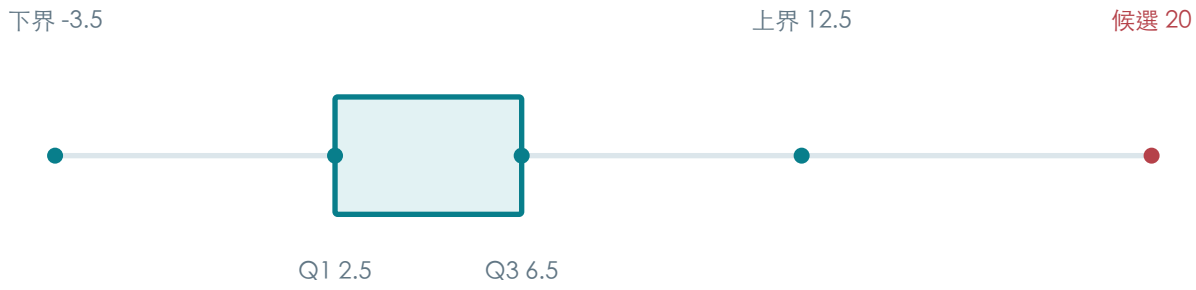
來源 [1] 5-4；[5] Q38公告D；[26]、[27] DataFrame API。

IQR算例：把中央一半資料當參考

03 公式與步驟 A / 延伸補充 | 非原教材數值；四分位數採上下半部中位數法。

已排序資料：1、2、3、4、5、6、7、20

步驟	計算
Q1／Q3	下半部[1,2,3,4]中位數Q1=2.5；上半部[5,6,7,20]中位數Q3=6.5。
四分位距	IQR（Interquartile Range）=Q3-Q1=6.5-2.5=4。
候選範圍	下界Q1-1.5×IQR=-3.5；上界Q3+1.5×IQR=12.5。
標出候選	20大於12.5，所以被標為候選異常；是否排除仍須調查。



容易混淆 | 四分位算法不同，結果可能略有差異

先依題設算法計算。Z-score=(x-μ)/σ中，x是觀測值、μ是平均、σ是標準差；沒有常態假設，不能直接套固定尾端機率。

來源 [1] 5-4；偵測範圍與數值為自編示範。

避免資料洩漏：先切分，再學處理規則

03 核心流程 B / Data Leakage：使用了預測當時不應知道的資訊。

依時間／實體／抽樣設計先保留獨立評估資料

訓練部分：fit

估填補值、縮放參數、PCA方向、特徵選擇及模型；重採樣也只用訓練部分。

驗證／測試：transform

沿用訓練學得的參數；評估時不重新學習、不先看測試標籤選特徵。

資料特性	切分提醒
同一病患／顧客多筆	以群組分開，避免同一個體同時落在訓練與測試。
時間序列／事件窗口	按預測時間切分，避免未來資料或重疊窗口洩漏；必要時留間隔。
類別不平衡	適當分層可保留比例，但不能取代時間或群組限制。
交叉驗證 CV	Cross-Validation；每摺都重新在訓練摺內擬合全部會學習的步驟。

必記｜沒有用y，也可能發生洩漏

用全資料平均值、PCA或SMOTE後再切分，都可能讓評估資料影響訓練。真正固定、逐筆且不依資料估參數的格式修正，與會學習的轉換要分開理解。

來源 [6] scikit-learn常見陷阱；[18] 重採樣洩漏；[4] Q41公告A。

數值縮放：Min-Max與Z-score改變的是尺度

03 公式與步驟 C / 原教材的Normalization在此指Min-Max；術語須看上下文。

方法	公式與符號
Min-Max縮放	x’=(x-a)/(b-a)；a、b為訓練資料最小／最大值，b>a。
Z-score標準化	z=(x-μ)/σ；μ為訓練平均，σ為訓練標準差，σ>0。

例：訓練值[10,10,30,30]，採母體標準差（ddof=0），因此a=10、b=30、μ=20、σ=10。x是待轉換的數值。

新值x=40：Min-Max

(40-10)/(30-10)=1.5。超出訓練範圍，預設不裁切時可以超過1。

新值x=40：Z-score

(40-20)/10=2。這表示離訓練平均2個標準差，並非把資料變常態。

距離型KNN／K-means、SVM及部分正則化模型常受尺度影響；樹模型通常較不依賴縮放。常數欄位會使上述分母為零，須刪除、另訂規則或交由明確實作處理。

考題陷阱｜標準化不保證[-3,3]，也不是樣本L2正規化

訓練集的中心與尺度改變，不代表形狀改為常態；新資料也不必平均0、標準差1。另有把每一列向量縮至單位長度的Normalization，用途不同。

來源 [1] 5-4；[7] 前處理；[9] MinMaxScaler；數字自編。

類別編碼：不要憑空製造大小關係

03 核心知識 D / One-hot、Ordinal與Target Encoding各有條件。

方法	如何表示	主要限制
獨熱 One-hot	顏色紅／藍／綠，各建一個0/1欄位；適合無順序類別。	類別多會增加欄數；未知類別的處理須預先設計。
序位 Ordinal	小／中／大→0／1／2，明定業務順序。	整數距離不必等於真實間距；避免把無序品牌亂編成高低。
目標 Target	用訓練資料的類別條件目標統計，常搭配平滑。	會用到y，須交叉擬合／摺內處理，避免把自身或驗證標籤洩漏。

API用語校正：LabelEncoder與OrdinalEncoder

原教材把整數編碼稱Label Encoding；在scikit-learn中，LabelEncoder主要處理目標y，OrdinalEncoder處理輸入特徵X的類別。不要只按名稱互換。

歷屆已考｜114 Q28公告C，仍須補上防洩漏條件

該題選標準化、目標編碼與交互特徵的組合，不代表所有資料永遠以此最佳。編碼方式取決於類別數、順序、模型及驗證結果。

來源 [1] 5-4～5-6；[4] Q28公告C；[7]、[23]、[25]。

時間、文字與互動：特徵要有業務意義

03 應用案例 E / 原始欄位不是模型唯一可學的表示方式。

資料型態	可建立的特徵	要檢查什麼
時間與事件	星期／時段／工作日、過去7天交易次數、距上次維護時間。	窗口只涵蓋當時可得的過去；回填資料與晚到事件要控管。
巢狀JSON日誌	遞迴展開欄位，再按機台及時間窗聚合。	保留實體與時間關係，不是只把JSON字串送模型。
文字	TF-IDF（Term Frequency-Inverse Document Frequency）、Word Embeddings等數值表示。	詞彙／IDF若由資料學得，也要訓練內擬合；延續3.1。
交互與組合	數量×單價、比率、滯後值、週期的sin/cos表示。	除以零、時序、語意及新增維度；不保證組合越多越好。



歷屆已考 | 115 Q35公告B：先適配模態，再融合

基因數值與病歷文本性質不同，先做適合各自的選擇／表示，再融合。不能因都是特徵，就一律合併後用同一個降維步驟取代所有處理。

來源 [1] 5-5～5-6；[4] Q27公告C；[5] Q35公告B。

特徵選擇：留下原欄位，減少冗餘與雜訊

04 核心知識 A / Feature Selection；選擇依據不等於因果證據。

方法	核心原理	主要限制
資訊增益	Information Gain；看分割或特徵能降低多少不確定性。	須看估計方法與任務；不能只按欄位數量判斷。
Pearson相關	Pearson Correlation；衡量數值間的線性關聯，可看冗餘。	接近0不代表完全無關；非線性關係可能仍很強。
L1／Lasso	以L1懲罰使部分係數變為0，可形成嵌入式選擇。	受尺度、正則化強度及相關特徵影響；不是永遠找出真因。
模型與驗證回饋	在訓練內反覆比較特徵組合，評估泛化及成本。	不可先用測試標籤選欄位，再拿同測試資料報成績。

多重共線性Multicollinearity會使一般線性迴歸的係數估計不穩。可評估正則化、刪除冗餘或PCA等；不同方法會改變解釋方式與預測取捨。

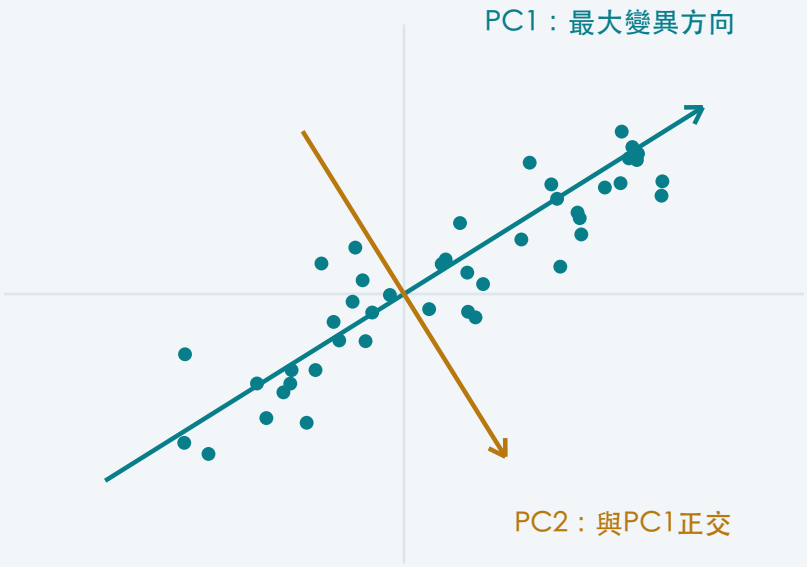
歷屆已考｜114 Q26公告D：LASSO；不可過度延伸

不應反推「樹模型完全不受相關特徵影響」。樹不需要反解同一個線性係數系統，但相關特徵仍可能影響分裂選擇與重要度解讀。

來源 [1] 5-5；[4] Q26公告D；[10]、[13]。

PCA：換新座標，找變異最大的方向

04 核心原理 B / Principal Component Analysis，主成分分析。



圖為自編方向示意；PCA把中心化後資料投影到新軸。主成分通常是原欄位的線性組合，因此不像特徵選擇那樣保留原欄位。

重點	正確判斷
數學操作	可對協方差矩陣作特徵值分解；實作也常對資料矩陣作SVD。
尺度與中心化	先檢查單位；PCA通常中心化，但不代表實作自動將每欄標準差縮為1。
資訊與預測	保留最大變異，不直接使用y；低變異方向仍可能有重要預測訊號。

教材與題目用語校正｜不相關，不等於統計獨立

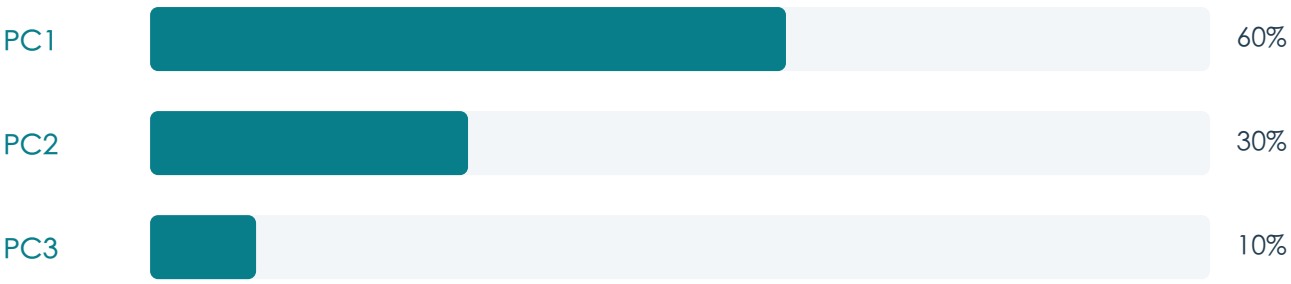
PCA主軸正交、主成分彼此不相關；一般情況不能保證統計獨立。114 Q12公告B的「獨立」用語應依此精確理解，不照抄成通則。

降維怎麼選：解釋變異，與看起來分開不同

04 公式與比較 C / 延伸補充 | 非原教材數值；比例的分母要用全部變異。

保留比例 = 所選主成分特徵值之和 / 全部特徵值之和

假設協方差矩陣特徵值λ依序為6、3、1，λ代表各主成分的變異量。總量為10：只留PC1為60%；留前兩軸為90%。若要求至少85%，本例需保留2軸。



方法	常用目的	不要這樣推論
PCA	線性投影、壓縮與視覺化；容易套用學得投影。	保留90%變異≠預測準確率90%。
t-SNE	t-distributed Stochastic Neighbor Embedding；強調局部鄰域的低維視覺化。	圖上群距與大小不一定有原高維意義。
UMAP	Uniform Manifold Approximation and Projection；非線性嵌入，常用於探索。	可見團塊不等於已驗證真實類別或下游泛化。

【歷屆已考】114 Q45=D：PCA後接SVM「可」降低計算或過擬合風險；不是保證提升準確率，也不會自動把線性SVM變成非線性模型。

來源 [1] 5-5；[4] Q45公告D；[11]、[19]、[20]。

自動特徵工程：加速搜尋，仍須驗證

04 應用知識 D / Auto Feature Engineering與AutoML不是免除資料責任。

功能	可以自動協助什麼	仍需人判斷
建立特徵	日期拆解、數學轉換、滯後或多項式。	當時可得性、語意、單位與有效期間。
篩選特徵	依統計、L1或模型回饋刪除冗餘／低貢獻欄位。	切分、穩定性、相關性與公平影響。
組合與互動	搜尋欄位交互、比率與窗口。	是否洩漏答案、增加成本或形成假關聯。
適配資料型態	嘗試填補、編碼、縮放等管線。	未知類別、缺失模式、模態及用途。
模型回饋迭代	比較多個特徵集與候選模型。	搜尋預算與獨立評估，避免反覆看測試集。

原教材舉Google AutoML、H2O.ai、AutoKeras、TPOT等。不同工具／版本支援範圍不同；本冊不把所有產品概括成具備全部特徵生成功能，也不宣稱必提升分數。

必記｜降低手工成本，不等於省略業務與品質檢查

自動流程仍可能學到錯誤標籤、未來資訊或族群代理特徵。資料來源、流程版本、切分與搜尋設定要可追溯，結果須在適合用途的獨立資料驗證。

來源 [1] 5-5～5-7；[6]、[10]、[25]；產品名稱沿用教材作辨識。

類別不平衡：高準確率，可能完全漏掉瑕疵

05 資料應用 A / Class Imbalance；延伸算例：1000筆，正例為10筆瑕疵。

模型	TP	FN	FP	TN	準確率
全判良品	0	10	0	990	99%
候選模型	6	4	14	976	98.2%

TP = 抓對瑕疵，FN = 漏掉瑕疵，FP = 把良品誤報，TN = 抓對良品。候選模型雖少0.8個百分點準確率，卻開始辨識真正的瑕疵。

Precision 精確率

TP/(TP+FP)=6/20=30%。在被報為瑕疵的樣本中，有多少是真的？

Recall 召回率

TP/(TP+FN)=6/10=60%。真正瑕疵中，有多少被抓到？

$$F1 = 2\times Precision\times Recall/(Precision+Recall) = 0.40$$

考試角度｜114 Q10=D；指標應反映錯誤代價

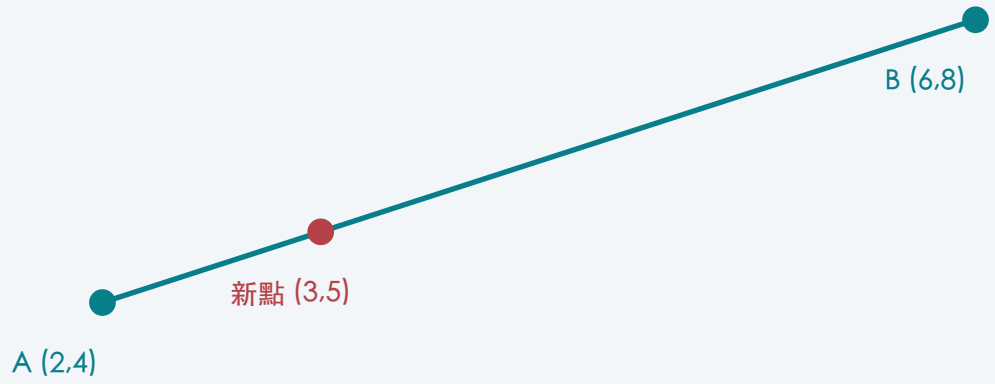
F1綜合精確率與召回率，仍不直接納入TN或實際金錢成本。全判良品的Recall為0；Precision分母為0時須說明處理約定，不能自動解讀成完美。

SMOTE：在少數類近鄰之間插值

05 公式與圖解 B / Synthetic Minority Over-sampling Technique。

$$x_{new} = x_A + \lambda \times (x_B - x_A)，0 \leqslant \lambda \leqslant 1$$

先選少數類樣本A，再從其少數類近鄰中選B。x為特徵向量，λ為插值比例；本例A=(2,4)、B=(6,8)、λ=0.25，所以新點=(3,5)。



圖為特徵空間插值示意。基本SMOTE常用於數值特徵；類別資料須用適合的方法，不能把類別編號插成「半個品牌」。近鄰距離也受尺度影響。

附件說法收斂｜不保證避免過擬合，也不保證物理合理

插值可能跨越錯誤邊界或產生不合理樣本。先切分，再只在訓練／訓練摺內合成；驗證與測試保留適合實際用途的分布。重複抽樣也非必然失敗。

資料增強：要增加變化，不能改壞答案

05 重要比較 C / Data Augmentation；變換是否保留標籤取決於任務。

資料	可考慮的增強	檢查情境
影像	裁切、亮度、旋轉、翻轉。	翻轉數字、左右側病灶或方向標誌，可能改變標籤。
文字	同義改寫、替換、生成候選樣本。	否定、情緒、實體或法律語意可能被改壞；需驗證。
語音	加噪、調整速度、音高等。	強度不能破壞可辨識性；情緒／聲紋任務更須注意。
數值／合成	小幅擾動、適當重採樣、生成模型。	保留欄位約束、關聯與少數類真實性；不等於新增真實觀測。

先切分
按個體或時間

→

只增強訓練
保留語意與約束

→

獨立評估
避免衍生樣本跨集

→

調整策略
比較實際效果

歷屆已考｜114 Q9公告B：增強可能導致效能下降

先查增強是否改變目標語意與有效分布，而不是盲目增加比例。相同原始影像的多個衍生版本若跨訓練與測試，容易得到過度樂觀結果。

來源 [2] p.15～17；[4] Q9公告B；[18]。

模型地圖：不同問題，不能只靠模型名稱選

06 基礎觀念 A / 先看目標與學習訊號，再看架構。

問題／訊號	典型任務	輸出與例子
有目標y的監督學習	迴歸 Regression	連續數值：銷售額、維修時間、房價。
有目標y的監督學習	分類 Classification	離散類別／類別機率：流失與否、瑕疵類型。
不靠目標y學結構	非監督學習	群集、表示或壓縮：顧客分群、PCA。
行動影響後續回報	強化學習 RL	學策略：倉儲路徑、連續資源調度。
學分布並生成樣本	生成式模型	文本、影像或合成樣本；可使用標註或條件資訊。

深度學習是架構軸，不是互斥的第六種任務

多層神經網路可做監督、非監督、強化或生成；Transformer可做分類也可生成。模型家族、任務與學習訊號常會重疊。

常見陷阱｜分群編號，不等於已知分類答案

K-means的群1、群2只是相似性群組，不能未驗證就把群1直接當「詐欺」。判別式模型也可預測連續數值，並非只做分類。

來源 [1] 5-7～5-13；分類軸重組為教學整理。

迴歸與分類：線性迴歸，不是邏輯迴歸

06 核心模型 B / Linear Regression與Logistic Regression。

線性迴歸：預測連續量

以特徵的線性組合估數值；基礎模型容易建立與解讀，但須檢查非線性、異常與共線性。

邏輯迴歸：分類模型

二元分類把線性分數經Sigmoid轉成機率，再依門檻分類；不是拿來直接預測任意房價。

二元例：s = b + w×x；p = 1/(1+e^(-s))

- x是輸入特徵，w是權重，b是截距，s是分數，p是所定義正例的機率，e是自然對數底數。
- 取b=-2、w=1、x=2，則s=0、p=0.5。若門檻採p≥0.5為正例，這筆會判成正例；門檻須依任務決定。
- 多類別常以Softmax或一對其餘（One-vs-Rest）擴充。不是把單一Sigmoid直接視作所有類別的機率和。

教材校正｜邏輯迴歸不要求資料完全線性可分

基礎形式的log-odds對輸入特徵為線性；可結合轉換與交互特徵。完全分離甚至可能使未正則化的係數估計發散，不能把「完全可分」當必要條件。

樹模型：單樹、隨機森林與梯度提升

06 重要比較 C / 三類都可依設定做迴歸或分類。

模型	如何學習	優點與限制
決策樹 Decision Tree	用特徵條件逐層切分；葉節點輸出數值或類別資訊。	小樹可讀性高、可表達非線性；深樹易過擬合與不穩。
隨機森林 Random Forest	多棵帶有隨機性的樹，聚合預測，常透過自助抽樣及特徵抽樣增加差異。	可降低單樹方差；模型較大、整體難像小樹直接解讀。
梯度提升 Gradient Boosting	逐步加入模型，朝降低目前損失的方向修正；不是所有損失都簡單等於殘差。	可擬合複雜結構；須調學習率、樹複雜度與迭代數，仍會過擬合。

森林：多個觀點再聚合

迴歸常取平均；分類可聚合機率或投票。具體做法依演算法實作。

提升：逐步改善目標

每輪依目前損失調整；不是只靠增加更多樹就必然提升測試表現。

實務判斷：表格資料可把線性與樹模型列為候選基準；缺失與類別原生支援依工具而異，不能假設任何決策樹都直接接受所有字串或缺值。

來源 [1] 5-7～5-9；[14] 集成方法官方文件。

SVM與KNN：邊界與鄰近，是兩種判斷方式

06 核心模型 D / 輸入尺度、維度及資料量會影響選擇。

SVM 支持向量機

Support Vector Machine；找兼顧間隔與錯誤代價的邊界。核函數kernel可表達非線性；C調整錯誤懲罰與正則化取捨。

KNN K最近鄰

K-Nearest Neighbors；找K個近鄰，分類聚合標籤、迴歸聚合數值。簡單，但儲存與查詢成本須考量。

比較項目	SVM	KNN
前處理	通常需要適當縮放；核函數與參數須驗證。	距離依尺度與度量而變；資料表示很重要。
資料量與維度	核SVM在大量樣本可能昂貴；線性版本有不同成本。	高維距離可能失去辨別力，查詢成本也可能增加。
解讀與輸出	決策分數不必是校準機率；需要時另評估。	K小可能不穩，K大可能過度平滑；依驗證挑選。

判斷法｜PCA、標準化與非線性核的作用不同

標準化改尺度，PCA換座標／降維，核函數改變模型表達能力；三者不能互相代替。KNN中的K是鄰居數，K-means的K則是群集數。

分群模型：中心、密度，還是層級？

07 核心模型 A / Clustering；群集是否有價值仍須回到業務驗證。

方法	做法與適用	限制
K-means	以中心點分派、更新中心，降低群內平方距離；常用於緊密群集。	需先給K；對尺度、初始中心、極端值敏感；不適合所有形狀。
DBSCAN	Density-Based Spatial Clustering of Applications with Noise；按密度連接群集，可標出雜訊。	主要參數ε、MinPts；密度差異大或高維距離失真可能難處理。
階層式分群	Hierarchical Clustering；建立樹狀關係 Dendrogram，可逐步合併或分割。	建樹時不一定先給群數，但取最終分群仍須切樹規則；成本依方法而異。

DBSCAN的ε為鄰域半徑，MinPts為密度所需最少點數；在scikit-learn的min_samples計數包含樣本本身。雜訊是依密度設定得到的結果，不等於每一點都是真正錯資料。

⚠ **教材校正 | DBSCAN不是特別擅長密度差異很大的群集**

單一全域密度門檻可能把稀疏群當雜訊或合併密集群。115 Q31公告A考高維距離集中；114 Q48公告B選距離索引，但高維下索引也未必加速。

來源 [1] 5-9～5-10；[4] Q11、Q48；[5] Q31；[12]。

分群圖解：同一批點，問題設定不同

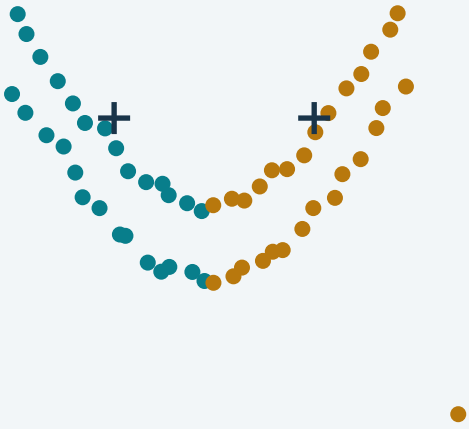
07 圖形記憶 B / 原創結構示意，未執行真實分群，也不是特定參數下的輸出。

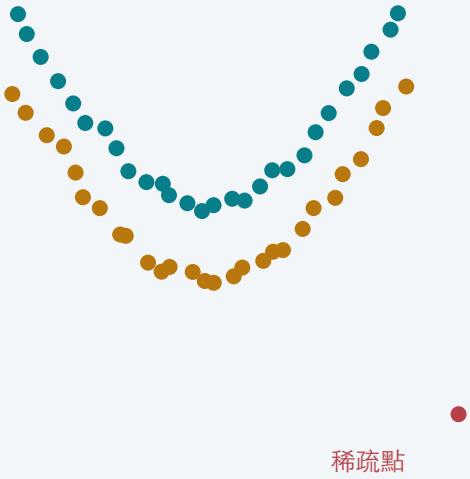
中心觀點

哪些點靠近同一中心？

密度觀點

哪些點以足夠密的鄰域相連？





中心式分法可能切開彎曲形狀；密度式思考鄰近連接，依距離、尺度與密度門檻而定。上圖僅用來記憶原理，不代表DBSCAN在任何設定都會找出兩條曲線。

維度詛咒｜距離集中時，找近鄰與密度都可能困難

先檢查無關特徵、縮放、距離定義與必要降維；不是看到300維就宣稱數學上不可能分群，也不是把ε調得很小就一定改善。

來源 [12] 分群原理；圖形與數值示意皆為自編。

深度模型：從資料結構找架構偏好

07 核心模型 C / Deep Learning，使用多層神經網路學習表示。

架構	核心原理與情境	限制與辨識
CNN	Convolutional Neural Network；局部連結、卷積與共享參數，適合影像等網格結構。	不是對任何位移／旋轉天然完全不變；仍須合適資料與驗證。
RNN	Recurrent Neural Network；藉隱狀態處理序列順序，常見於感測或語音序列。	基本RNN可能有梯度消失／爆炸與長期依賴困難。
LSTM／GRU	Long Short-Term Memory／Gated Recurrent Unit；以門控調節記憶。	可改善長期依賴學習，但不保證任意長序列永不遺忘。
Transformer	以Self-Attention建立元素關聯；常加入位置資訊，文字、影像與多模態皆可用。	標準全注意力對長度的計算／記憶成本常呈平方；生成通常仍逐步輸出。

BERT／GPT用途辨識

BERT典型編碼器適合語意表示；GPT典型自迴歸生成。架構可依任務接不同頭。

選型不靠流行程度

結構化小資料也值得比較較簡單基準。資料量、預訓練、硬體與延遲會影響可行性。

例：醫療影像用CNN輔助判讀；序列用LSTM建模；客服用Transformer。這些是候選方向，不是排他規定或效果保證。

來源 [1] 5-10～5-11；延續本系列3.1～3.4的技術原理。

有限資料與資源：先評估能否借用已學表示

07 應用選型 D / Transfer Learning遷移學習與模型調整。

預訓練知識 相關任務與表示 → **目標資料** 標籤與資料差異 → **調整方式** 凍結／微調／適配 → **獨立驗證** 與簡單基準比較

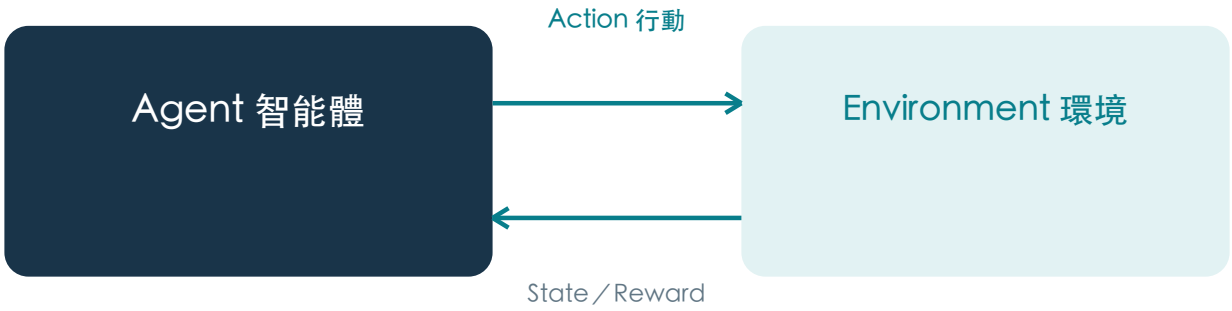
方式	用途與邊界
凍結特徵 + 新任務頭	保留部分預訓練參數，先訓練輸出層；資料少時可評估。
微調 Fine-tuning	調整部分或全部參數；需控制學習率、過擬合與領域差異。
LoRA	Low-Rank Adaptation；以低秩適配降低可訓練參數等成本，不等於無須標註或驗證。
蒸餾／壓縮	Knowledge Distillation借教師訊號訓練學生；剪枝／壓縮則改模型表示或結構，須重新量測品質與成本。

歷屆已考 | 115 Q36公告A：500張影像可先評估遷移CNN

題內標註有限，相關預訓練CNN微調優於從頭訓練大型模型等選項。不能把500張背成所有任務的足夠門檻；域差、授權與實際驗證仍要考慮。

強化學習：不是猜答案，而是學行動策略

08 核心模型 A / Reinforcement Learning（RL）；目標為累積回報。



方法	原理與限制
Q-learning	學狀態 – 行動的預期回報Q值；表格版較適合有限且較小空間，訓練亦需探索。
DQN	Deep Q-Network；以神經網路近似Q函數，可處理高維輸入；標準DQN常對應離散動作。
Policy Gradient	策略梯度直接優化策略；REINFORCE及Actor-Critic等為代表。
PPO	Proximal Policy Optimization，近端策略優化；以適當目標約束過大的策略更新，不保證全域最優。

案例：倉儲機器人選路徑，行動會影響後續位置與耗時；不能只用單步分類準確率判斷整體策略。序列資料本身也不代表一定要用RL。

安全與訊號｜無人工標註，不代表無資料或無人設計

仍需環境、觀測、行動、獎勵與訓練經驗。獎勵設計可能被鑽漏洞，真實試誤可能昂貴或危險；需受控環境、約束與驗證，不能保證學到最優策略。

來源 [1] 5-11～5-12；[22] PPO原始論文；框圖為教學重繪。

生成模型：用於合成，不代表能免除資料驗證

08 核心模型 B / Generative Models；延續3.3，此處聚焦選型。

家族	核心原理	選型限制
GAN	Generative Adversarial Network；生成器與判別器對抗學習。	訓練可能不穩、模式崩潰，合成多樣性須檢查。
VAE	Variational Autoencoder；透過變分下界等目標學潛在分布與重建。	可用潛在表示或生成；樣本平滑等特徵依模型與訓練而異。
擴散模型	Diffusion Model；學去噪或反向生成過程。	品質、採樣步數與成本須衡量；加速方法使「一定慢」不是通則。
自迴歸生成	依先前內容預測下一元素；Transformer可作此架構。	可用於文本／語音等；生成內容可能錯誤、記憶資料或失去代表性。

生成候選
模擬／補全／擴增

→

檢查內容
約束／標籤／多樣性

→

訓練內使用
不汙染獨立測試

→

下游驗證
任務效用與限制

判斷法｜看下游任務，而不是只看合成圖像漂亮

114 Q44公告C涉及VAE／GAN合成再支援分類。合成不等於新增真實證據，也不自動匿名、合法或保證提升泛化；需檢查資料來源、洩漏與真實評估。

來源 [1] 5-12～5-13；[4] Q44公告C；數據補全與擴增情境。

公平比較模型：調參分數，不等於獨立成績

09 驗證原理 A / 訓練、驗證與測試的角色須明確。

訓練
學參數與特徵處理

→

驗證／內層CV
挑特徵、模型與設定

→

獨立評估
保留測試或外層CV

→

選型記錄
品質、成本與限制

問題	正確做法
調參會不會過度貼合驗證集？	會；反覆挑選最好的設定，再報同一批選型分數，可能樂觀。可用保留測試或巢狀CV評估整體選型程序。
CV與調參本身有衝突嗎？	沒有；114 Q14支持CV選設定。Q41提醒的是把用於選擇的同一分數當獨立泛化成績。
低標註資料如何比較？	固定合適的評估切分，在訓練部分改變可用標註比例，控制預訓練與其他資源差異。
指標怎麼選？	迴歸看誤差，分類看錯誤代價與Precision／Recall等；分群看結構與用途，生成還要看真實效用與安全。

必記｜所有會學習的步驟，都屬於被評估的程序

交叉驗證時，在訓練摺內擬合填補、編碼、選擇、PCA及SMOTE等；驗證摺僅套用已學規則。先用全資料選欄位再CV，仍可能洩漏。

來源 [4] Q14公告A、Q41公告A、Q43公告B；[6]、[18]。

模型選擇：先過必要條件，再比較價值

09 選型實務 B / 下例分數、延遲與門檻皆自編，非官方固定標準。

某服務在代表性負載下要求P95延遲≤100ms。P95表示95百分位延遲；只比較平均速度不足以驗收此條件。三個模型在相同保留資料評估如下：

候選	F1	P95延遲	相對維運負擔
A：較小模型	0.86	50ms	較低
B：較大模型	0.89	180ms	較高
C：簡單基準	0.80	25ms	較低

依題設：B未過門檻

F1較高仍不能宣稱已符合上線條件；可先優化再驗證，不直接忽略延遲。

A是否可用，還要看需求

若品質與其他安全／合規條件均通過，A可能是較好的候選；C仍有基準與簡化參考價值。

選型清單｜任務、資料、品質、成本、解釋、維護

比較訓練／推論資源、延遲、可解釋性、授權、安全與更新難度。不能只用參數量、流行度或單一分數判定所有情境的最佳模型。

來源 [1] 5-7；[2] p.12；比較表為教學情境。

管線思維：把前處理與模型綁在同一程序

09 程式閱讀準備 C / Pipeline讓轉換與模型在切分內一起擬合。

訓練階段

X_train → fit填補 → fit縮放／編碼 → fit選擇或PCA → fit模型。

↓

評估階段

X_valid → 沿用填補值 → 沿用轉換 → 沿用模型 → 指標。

↓

發布階段

保存資料規格、整條已擬合管線與版本；預測沿用相同處理。

```
# 流程示意：非可單獨執行的完整程式
pipe.fit(X_train, y_train)
pred = pipe.predict(X_valid)
# 不對 X_valid 呼叫 fit 或 fit_transform
# 每一個 CV 訓練摺重新擬合 pipe
```

⚠ **目的與陷阱｜transform套規則；fit會重新學規則**

Pipeline可協助避免不一致與洩漏，但不能自動修正錯誤時間切分、事後特徵或不當資料來源。不同管線也有差異：重採樣需用能正確管理sampler的流程。

來源 [6] 常見陷阱；[7]、[8]、[9]；流程為自編示意。

整合案例：連鎖零售的下週銷售額預測

10 應用整合 / 自編案例；不代表特定企業的真實成效。

關卡	案例安排	判斷理由
資料定義	一列為門市×週；目標為下週銷售額。	連續量，屬迴歸；不是先假定某模型名稱。
來源與品質	ERP銷售、庫存、過去氣象與事件；檢查退款、重送及單位。	保留可追溯來源，避免連接放大筆數或錯誤補零。
特徵與切分	只用預測當時已知資訊；依時間保留評估區間。	事後實際銷售不能當輸入；規劃促銷也須確認當時已知。
候選模型	簡單歷史基準、線性與樹迴歸；缺失與編碼在訓練內處理。	比較非線性需求、資料量、誤差與維護成本。
驗證與交接	看誤差、不同門市／時段與成本，保存整條管線。	平均成績不能掩蓋重要群組失效；5.2再接部署。

反推題幹｜先判資料問題，還是模型表達問題

漏掉退款或使用未來特徵，優先修資料流程；穩健驗證後仍有可解釋的非線性不足，再比較其他模型。不是每次分數不好都直接加深網路。

來源 [1] 5-2～5-13；流程為重整與延伸。

教材比對與常見陷阱：關鍵條件不能省

10 完整性與概念比較 / 不把示例、簡化術語或題目措辭當成通則。

容易誤記	本冊採用的精確判斷
正規化／標準化皆變常態	Min-Max改範圍、Z-score改中心與尺度；樣本單位長度又是另一種正規化。
Label Encoding適合直接編所有X	區分序位、無序與y；目標編碼須交叉擬合，避免標籤洩漏。
PCA保留資訊且必提高效能	最大變異不等於預測訊號；不相關不等於統計獨立。
DBSCAN適合密度差異極大	單一密度門檻可能困難；高維亦須檢查距離，不一律宣稱不能處理。
所有模型類型互斥	監督／非監督／RL是訊號軸，深度是架構，生成是目標／分布觀點。
Logistic要求完全線性可分	基本形式log-odds為線性；完全可分不是必要條件，多類可用其他擴充。
SMOTE／自動工程必提升	須保留語意／約束、只在訓練內使用；效果靠獨立驗證。
分類／生成／RL必能取代彼此	輸出與評估目的不同；群集不等於標籤，合成不等於真實因果證據。

已涵蓋官方：內外部來源、五品質、缺失／重複／異常、數值／類別／時間文字、資訊增益／Pearson／L1、PCA／t-SNE／UMAP、五類自動工程功能，以及迴歸、分類、非監督、深度、RL與生成全部列舉家族。

待後續深入：5.2系統部署與維運；L22／L23的完整統計、參數調校與建模數學。附件的完整模型壓縮／Agent平台內容不在此逐頁重述。

考試重點：實題證據與推測題型分開

11 考點索引 / 紅色優先、橙色重要；不是官方權重或必考預測。

知識點	優先程度	考查方式與判斷依據
異常／資料清理	優先掌握	【歷屆已考】115 Q38=D；已確認的錯值與單純換尺度分清。
特徵編碼與結構	優先掌握	【歷屆已考】114 Q27=C、Q28=C；115 Q35=B。
選擇／PCA	優先掌握	【歷屆已考】114 Q12=B、Q26=D、Q45=D；115 Q30=C。
DBSCAN與高維	優先掌握	【歷屆已考】114 Q11=C、Q48=B；115 Q31=A；含索引限制。
增強／少數類	優先掌握	【歷屆已考】114 Q9=B、Q10=D；115 Q37=A。
資料切分／模型比較	優先掌握	【歷屆已考】114 Q14=A、Q41=A、Q43=B；不能同分數調參與獨立報分。
模型與任務／遷移	優先掌握	【官方評鑑】模型優缺點；【歷屆已考】115 Q36=A；114 Q44=C。
完整模型家族／AutoML	重要理解	【教材重點】5-5～5-13；【推測題型】任務、限制與架構比較。



考前必記｜五個判斷

①粒度與當時可得性 ②切分後才學轉換 ③縮放、選擇、降維各有目的 ④任務、架構與訊號分清 ⑤同條件驗證，兼顧錯誤代價、資源與維護。

來源 [3] L21301；[4] 114第二次；[5] 115第一次；教師分類。

考前3分鐘：從資料走到可比較的模型

12 章節總整理 / 八個記憶錨點；公式要連到目的與限制。

01 來源與品質

先定粒度、鍵、時間與用途；完整、一致、準確、時效、唯一缺一不可。

02 缺失／異常

找原因再處理；IQR=Q3-Q1；候選離群不等於錯值，詐欺可能正是目標。

03 切分與管線

fit只用訓練；評估只沿用transform；時間、群組、增強與SMOTE都須防洩漏。

04 縮放與編碼

Min-Max=(x-a)/(b-a)，Z=(x-μ)/σ；One-hot、Ordinal、Target依語意與模型挑選。

05 選擇與降維

選擇留欄位，PCA換座標；最大變異不等於最有用的y訊號；視覺團塊須驗證。

06 不平衡與增強

平均Accuracy會誤導；Precision、Recall、F1看分母；合成不保證語意／物理正確。

07 任務與家族

數值迴歸、類別分類、無y找結構、行動看回報；深度與生成不是互斥分法。

08 公平比較

調參分數不等於獨立成績；先基準，再看品質、解釋、延遲、成本與維護。

題目先問：要預測什麼？當時知道什麼？這個轉換學了什麼？評估資料是否仍獨立？

練習1／2：任務選型與類別不平衡

13 自編中級單選 / 非官方原題；三題解析集中最後p.40～42。

01 基礎概念與應用

零售商要根據歷史資料預測下週各店的「銷售額」。下列模型選擇方式何者最合理？

A 因為名稱有迴歸，直接以邏輯迴歸預測任意大小的銷售額。

B 將K-means群集編號直接當成下週銷售額，不需驗證。

C 只比較生成影像的清晰度，就能決定銷售額模型。

D 建立基準，將線性與樹迴歸列為候選，在合適的時間切分下比較誤差與成本。

我的選擇：_____

02 情境應用

瑕疵偵測資料中正例僅1%。團隊想用SMOTE改善少數類辨識，同時保留可信的評估。下列流程何者最合適？

A 先依用途切分資料，再於訓練部分／訓練摺內重採樣，評估保留適合實際用途的分布。

B 先對全資料做SMOTE，再隨機切分，確保每份都有合成樣本。

C 刪光少數類，只要準確率變高就代表模型改善。

D 只看99%的準確率即可，不必檢查瑕疵召回率或誤報成本。

我的選擇：_____

練習3：填補與縮放，哪些值真的被學到？

13 自編中級程式閱讀題 / Python；採預設MinMaxScaler，不裁切新資料。

閱讀以下程式。np.nan表示缺失值；ravel把二維結果展平。最後輸出在數值上等於哪一個選項？

```
import numpy as np
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import MinMaxScaler
from sklearn.pipeline import make_pipeline
train = np.array([[0.], [10.], [np.nan], [20.]])
valid = np.array([[30.], [np.nan]])
pipe = make_pipeline(
    SimpleImputer(strategy="median"), MinMaxScaler())
pipe.fit(train)
print(pipe.transform(valid).ravel())
```

A [1.0, 0.5]

B [1.5, 1.5]

C [1.5, 0.5]

D [1.0, 1/3]

我的選擇：_____

提示：分別追蹤填補器學到的值、縮放器學到的上下界，以及valid是否再次參與fit。

來源索引與分析邊界 1/2

14 來源可追溯 / 青綠條目可點開；圖解、數字與練習均自行編製。

[1] 官方科目一學習指引：5-2～5-13（PDF p.143～154）。

[2] 附件002_AI導入評估：PDF p.12～17、21～29相關內容。

[3] 官方評鑑內容範圍115.06：L21301及相關項目。

[4] 114第二次科目一：Q9～12、14、26～28、41、43～45、48。

[5] 115第一次科目一：Q30、31、35～38等公告題與答案。

[6] scikit-learn：Common pitfalls；洩漏、切分與Pipeline。

[7] scikit-learn：Preprocessing；縮放、編碼與轉換。

[8] scikit-learn：Imputation of missing values。

[9] scikit-learn：MinMaxScaler；學得範圍與clip條件。

[10] scikit-learn：Feature selection；訓練內特徵選擇。

[11] scikit-learn：PCA／Decomposition；中心化、SVD與變異。

[12] scikit-learn：Clustering；K-means、DBSCAN、階層與限制。

[13] scikit-learn：Linear Models；迴歸、Lasso與Logistic。

[14] scikit-learn：Ensembles；森林與梯度提升。

證據屬性：【官方評鑑】能力範圍；【教材重點】原指引與附件；【歷屆已考】實際公告題與答案；【推測題型】依觀念自編。兩卷各50題，只選本章相關題並標來源，未用概念交叉重複累算頻率，也未預測未來必考或配分。

教材用語如PCA「獨立」或DBSCAN「密度變化明顯」，本冊已與官方技術定義比對並校正。公告答案保留來源，不把選項中的過度概括照抄成正確定義。

來源索引與分析邊界 2/2

14 來源可追溯 / 青綠條目可點開；圖解、數字與練習均自行編製。

[15] scikit-learn：Support Vector Machines；尺度與核方法。

[16] scikit-learn：Nearest Neighbors；距離、索引與維度。

[17] imbalanced-learn：Over-sampling；SMOTE機制與限制。

[18] imbalanced-learn：Common pitfalls；重採樣與評估洩漏。

[19] scikit-learn：Manifold learning；t-SNE。

[20] UMAP官方文件：Basic parameters；非線性嵌入與設定。

[21] TensorFlow／Keras：Transfer learning and fine-tuning。

[22] Schulman et al.（2017）：Proximal Policy Optimization Algorithms。

[23] scikit-learn：OrdinalEncoder；輸入特徵的類別編碼。

[24] scikit-learn：SimpleImputer；中位數學習與轉換。

[25] scikit-learn：TargetEncoder；訓練表示與交叉擬合。

[26] pandas：DataFrame.drop_duplicates。

[27] PySpark：DataFrame.drop_duplicates；dropDuplicates別名。

延伸補充｜非原教材內容：粒度與連接例、切分／Pipeline流程、IQR／縮放／PCA變異／SMOTE／指標算例，以及比較圖與三題均為教學整合。程式題依官方API規則與獨立數值計算核對；不把示例門檻、樣本數或工具名稱當效果保證。

覆蓋邊界：完整對應官方5.1主文；附件僅取相關頁。5.2部署、L22／L23完整統計與建模數學待後續。本冊不要求優先背誦完整RL推導、工具安裝指令或產品版本功能清單。

附錄解析1：先看要預測什麼，再選候選模型

15 答案與逐項解析 / 第1題，題目見p.36。

正確答案 D

銷售額是連續數值，因此先以迴歸思考，建立可比較基準；線性與樹迴歸可列為候選。依時間切分並比較誤差、成本與限制，才能支持選型。

選項	判斷與理由
A 錯誤	邏輯迴歸雖有「迴歸」二字，本章用法是分類／類別機率，不是直接預測任意大小的銷售額。
B 錯誤	群集編號是分群結果，沒有銷售額單位；不能未經建模與驗證直接當預測數值。
C 錯誤	影像清晰度與銷售額誤差不是同一任務指標，不能據此選出銷售額模型。
D 正確	先建立基準與適合連續量的候選，再依時間可得性、獨立評估與實際成本比較。

解題口訣｜數值、類別、結構、行動，先辨目標

模型名稱相似不代表任務相同。選型先確認輸入與輸出，再比較表達能力和驗證結果；不能直接從「AI」跳到最大或最流行的模型。回到p.19～22、29～30。

附錄解析2：合成只能從訓練部分開始

15 答案與逐項解析 / 第2題，題目見p.36。

正確答案 A

先依任務切分，重採樣只在訓練部分進行；CV時也須在每個訓練摺內做。評估資料應能反映實際用途，不讓測試資訊參與合成，也不因重採樣改變評估問題。

選項	判斷與理由
A 正確	同時控制合成步驟的資訊來源與評估分布；仍須驗證少數類辨識、誤報及合成合理性。
B 錯誤	先用全資料SMOTE，測試樣本可能參與近鄰與合成，且測試分布可能被改變，造成樂觀偏差。
C 錯誤	刪光少數類使模型無法從正例學習；多數類比例高的表面準確率不代表瑕疵能力改善。
D 錯誤	全判良品也可達99%準確率；必須看正例Recall、Precision及錯誤成本等。

重要限制｜正確流程，不代表SMOTE一定有效

類別型資料、孤立錯標、重疊邊界與物理約束都會影響合成品質。選擇方法與參數須在訓練內比較，驗證後才決定是否採用。回到p.8、16～18。

附錄解析3：中位數與範圍，都來自train

15 答案與逐項解析 / 第3題，題目見p.37。

正確答案 C

步驟	計算與結果
學填補值	train非缺失值0、10、20，中位數為10；填補後為0、10、10、20。
學縮放範圍	縮放器接到上述訓練資料，因此最小0、最大20；分母20。
轉換valid	[30,NaN]先變成[30,10]，再變成[(30-0)/20,(10-0)/20]。
展平輸出	ravel後為[1.5,0.5]；預設clip=False，30超出訓練最大值仍可得1.5。

選項	判斷與理由
A 錯誤	把1.5裁成1；程式的MinMaxScaler沒有啟用裁切。
B 錯誤	把valid缺失值也當30處理；填補器已學到的是訓練中位數10。
C 正確	依序沿用訓練中位數10與上下界0、20；數值結果為[1.5,0.5]。
D 錯誤	相當於改用30作縮放上界、填補仍為10；valid並未參與fit，所以不能改變上界。

解題順序：先追蹤每個fit學到的統計量，再按管線順序transform。驗證資料超出訓練範圍，並不代表程式自動重新學範圍或一定出錯。回到p.5、8～9、31。