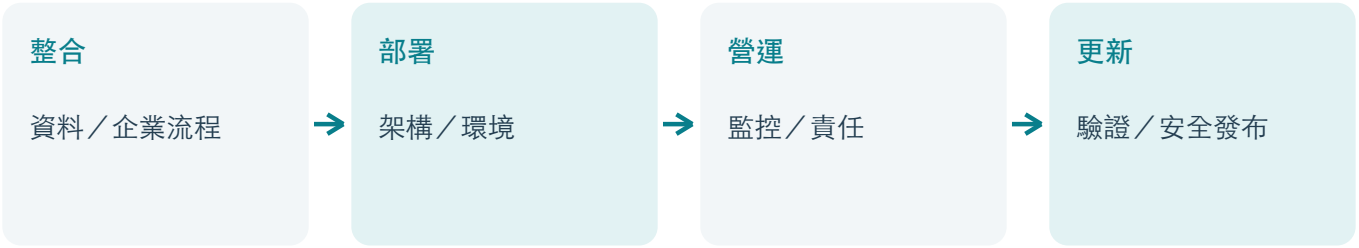
# AI技術系統集成與部署

5.2 圖解精讀 / 從候選模型到穩定服務，建立可監控、可更新的營運循環。

共同科目 L21 | L21302

## 模型能預測，系統還要能持續服務。

部署（Deployment）把模型接到資料、應用、人員與營運流程。本章會沿著一筆請求的旅程，理解如何整合、封裝、發布與監控，並判斷異常時該擴容、修資料、回滾，還是重新訓練。




| 閱讀方式 | 本冊安排 |
| --- | --- |
| 學習目標 | 能辨別整合介面與工具角色，選擇部署方式，規劃測試、發布及監控回饋。 |
| 重要程度 | 優先掌握：官方核心，且兩卷有多項具體試題；優先序不是官方配分。 |
| 時間估算 | 精讀約100～140分鐘，可分成整合架構、上線策略、監控更新三次。 |
| 練習與解析 | 三題見p.37～38；正確答案與所有選項解析集中最後p.41～43。 |

來源與技術查核日：2026.10.30。圖解、算例與練習自行編製；例示流量、比例及門檻均非官方通則。

# 本章速覽：把六個問題串起來

01 學習地圖 / 【官方評鑑】L21302：架構、模型部署、監控更新、測試與雲端環境。

### 01 AI接到哪裡？

資料管線取得輸入，API提供結果，ERP／CRM等系統把結果轉成業務行動。

### 02 哪些權限要分開？

可推論、可看資料、可重訓與可發布是不同權限；登入成功不代表全部可做。

### 03 容器與K8s各做什麼？

容器封裝執行環境；Kubernetes協調副本、資源與更新，不替你證明模型正確。

### 04 系統放哪裡？

公有雲、私有雲、邊緣及混合各有取捨，要先看資料、延遲、資源與維護限制。

### 05 如何安全換版本？

測試與版本追蹤先行，再用滾動、藍綠或金絲雀發布，預先定義停止與回滾條件。

### 06 上線後看什麼？

同看系統、資料、模型與業務；先找根因，再選擴容、修流程、補標註或重訓。

### 先備與本章邊界

延續5.1的資料與模型選擇；4.3的風險管理在此落實為權限、測試、監控與責任。工具安裝、完整K8s設定與法規條文不列為本章優先背誦內容。

來源 [3] L21302；[1] 5-14～5-22。

# 先看全貌：兩條路徑，一個回饋循環

02 核心知識 / 系統集成（System Integration）讓模型與企業既有系統協同運作。

## 訓練路徑 | 準備候選，不直接服務顧客

**歷史資料**
清理／標註
→
**訓練驗證**
比較品質
→
**登錄候選**
版本／證據

## 推論路徑 | 每筆請求都要走完

**業務入口**
App／CRM
→
**資料 + 服務**
特徵／模型API
→
**業務行動**
呈現／核准／執行

↓

**回饋閉環：紀錄版本與請求 → 收集結果／人工修正 → 分析根因 → 驗證改善 → 安全發布**

電商例：離線每天訓練推薦模型，線上仍可透過API即時推論；點擊事件持續更新特徵。批次訓練與即時服務可以並存，無須把每次推論都送回訓練流程。

### 歷屆已考 | 115第一次 Q20，公告A

題意重點是即時事件、低延遲特徵與線上推論的串接。先寫入資料倉儲、再每次掃描批次查詢，可能無法滿足即時回應要求。

來源 [1] 5-14～5-15；[2] p.46～56；[5] Q20。

# 資料管線：讓資料持續、可靠地進來

03 整合面向A / 資料管線（Data Pipeline）包含擷取、轉換、清理、儲存與交付。

| 來源與介面 | 常見資料 | 部署時確認 |
| --- | --- | --- |
| 資料倉儲／資料湖 | 倉儲常供結構化分析；湖常保存原始、半結構與非結構資料。 | 欄位定義、權限、版本及可用時間。 |
| IoT／事件串流 | 機台感測、點擊、交易等持續事件。 | 順序、延遲、重複、掉訊及補送。 |
| 第三方API | 天氣、物流、授權外部資訊。 | 額度、格式變動、逾時與替代資料。 |

### 批次 Batch

定時處理一批資料，適合報表與大量歷史特徵；等待批次完成才更新。

### 串流 Streaming

持續處理事件，適合近即時特徵；需管理事件時間、遲到資料與處理狀態。

製造例：MES生產紀錄每晚彙整，機台震動即時傳入。異常警報使用近期感測特徵，週報使用長期統計；先依用途設定新鮮度，不必把所有資料都改成串流。

**必記｜資料湖與倉儲是常見分工，不是永久互斥**

【歷屆已考】115第一次Q39公告A，以原始影像／文字與結構化分析辨識常見選擇。現代平台能力可能交疊；仍要設計資料品質、目錄、權限與追溯。

來源 [1] 5-14～5-15；[5] Q20、Q39。

# 同一個特徵，訓練與服務要說同一種話

03 整合延伸 / 特徵儲存庫（Feature Store）統一特徵定義、版本與取得方式。

**事件**

訂單完成

→

**共同定義**

過去7日購買次數

→

**兩種使用**

離線訓練／線上查取

| 檢查項目 | 例子與判斷 |
| --- | --- |
| 定義一致 | 訓練計算含退貨、線上卻排除退貨，即使欄名相同，也可能造成偏差。 |
| 時間正確 | 訓練快照只使用當時已知資料；線上顯示特徵更新時間與允許延遲。 |
| 新鮮度與備援 | 查不到或過期時，依規則使用預設、快取或人工流程，並記錄降級原因。 |
| 快取隔離 | 快取鍵納入租戶／權限與必要版本；避免跨客戶讀到別人的資料或舊版結果。 |

白話理解：大家查的是同一本有版本的字典。Feature Store有助減少訓練與服務偏差，但不會自動修好錯誤定義、過期輸入或標註問題。

**延伸補充｜非原教材內容**

時間點一致性、快取鍵與降級設計用來理解整合風險；具體產品設定不建議優先背誦。題目問「即時特徵」時，重點是可及時取得所需資料，不是只背工具名稱。

來源 [1] 5-15；[5] Q20；延伸核對 [10]。

# API、gRPC、Webhook：先看互動方式

04 整合面向B、C / API（Application Programming Interface）是系統溝通的契約。

| 方式 | 如何互動 | 常見用途與限制 |
| --- | --- | --- |
| HTTP／REST | 呼叫端送請求，服務回傳結果；常用JSON交換。 | 前端或ERP呼叫推論。REST是架構風格，不等於所有HTTP API。 |
| gRPC | 以服務定義呼叫遠端方法；支援單次與不同串流模式。 | 內部服務互通、型別契約。需考慮客戶端、閘道及網路支援。 |
| Webhook | 事件發生時，事件來源向預先設定的接收端發HTTP請求。 | 長任務完成、訂單狀態通知。不是持續雙向連線協定。 |




ERP（Enterprise Resource Planning）、CRM（Customer Relationship Management）、MES（Manufacturing Execution System）、POS（Point of Sale）不只是資料來源，也可能接收AI結果並啟動補貨、服務或現場處置。

**常見陷阱｜介接成功，不代表動作可以任意執行**

Webhook需驗證來源，設計重試與重複事件處理。AI Agent呼叫工具時，還要限定可讀／可寫範圍、停止條件與必要人工核准；不能把模型輸出直接當作操作授權。

來源 [1] 5-15；[2] p.54～56；延伸核對 [22]、[23]。

# 服務契約：輸入、輸出與失敗都要定義

04 核心原理 / 模型服務化（Model Serving）把模型能力變成可呼叫、可管理的服務。

POST /predict （教學介面示意，非可直接執行程式）
請求本文：影像檔 + 必要欄位；另附適當授權資訊
服務：檢查型別／大小／權限 → 前處理 → 推論 → 後處理
回應：request_id、prediction、model_version、狀態
失敗：回傳明確錯誤；記錄原因，依契約決定重試或降級

| 契約要素 | 規劃時必須記住 |
| --- | --- |
| 輸入／輸出 | 欄位型別、單位、缺值規則、模型與前後處理版本；分數不一定是校準機率。 |
| 延遲與錯誤 | 逾時上限、併發限制、輸入過大、未授權、服務不可用等情形需明確處理。 |
| 追溯與安全 | 請求識別碼串接紀錄；避免在一般日誌暴露憑證、原始個資與機密內容。 |
| 重試邊界 | 推論與扣款／下單的副作用不同；業務寫入需防止重試造成重複動作。 |

**歷屆已考｜115第一次Q44，公告B**

大量影像經HTTP傳送，題目以POST本文、multipart/form-data或application/octet-stream為適當方向。把大圖Base64塞入GET網址，可能遇到長度、紀錄暴露與效能問題。

# 驗證身分與授權，是兩個不同問題

05 整合面向D / Authentication問「你是誰」；Authorization問「你可以做什麼」。

### 身分驗證 Authentication

確認人或呼叫端身分。帳號、憑證或權杖都必須有對應的驗證程序。

### 授權 Authorization

依角色、範圍與資源判定可做的事。可使用推論，不代表可下載資料或發布模型。

| 名詞 | 準確定位 | 不能誤記成 |
| --- | --- | --- |
| OAuth 2.0 | 委派存取權的授權框架；Access Token不限定一定是JWT。 | 單憑OAuth就完成所有登入驗證。 |
| JWT | JSON Web Token；傳遞宣告的權杖格式，可簽章／加密。 | 只要有JWT就安全；簽章即內容保密。 |
| OIDC | OpenID Connect；建立在OAuth 2.0之上的身分層。 | 與OAuth、JWT完全相同的名詞。 |
| API Key | 常用於識別與驗證呼叫應用；需安全儲存、輪替及控權。 | 任何情況都能代表最終使用者身分。 |

**原教材校準｜把相關機制分清楚**

原指引並列OAuth2／JWT於驗證與授權。本冊保留其安全目的，細分協定與格式；JWT仍須檢查簽章、發行者、對象、有效期等，且不能取代速率限制。OIDC與驗證細節屬延伸補充，非原教材內容。

# Gateway、Service Mesh與同步，不是同一層

05 整合面向D、E / 跨雲與異質系統整合，需要分清流量管理與資料一致性。




Service Mesh：協助服務間的流量、通訊安全與可觀測性；不是把所有業務資料自動複製一致的資料庫。

| 層次 | 規劃重點 | 實際案例 |
| --- | --- | --- |
| 入口管理 | 驗證與授權、限流、路由、存取紀錄。 | 同一應用突然大量呼叫，先執行Rate Limit與容量保護。 |
| 服務間通訊 | 呼叫逾時、重試、加密、流量觀測及故障隔離。 | 推薦API呼叫特徵服務，需知道耗時與失敗來源。 |
| 資料一致性 | 版本、同步策略、事件處理、交易與衝突解決另行設計。 | 多雲庫存更新不可只裝Mesh就假設完全一致。 |

**必記｜至少三種限制要分開**

誰能呼叫是權限；能呼叫多快是限流；承載得住多少是容量。日誌能追查，不會自動阻擋攻擊。跨雲還要盤點資料流向、網路故障、版本相容與成本。

來源 [1] 5-15；[2] p.56～57；延伸核對 [25]。

# 微服務：可獨立擴展，仍要防連鎖失效

06 架構A / 微服務Microservices；斷路器屬延伸補充｜非原教材內容，有歷屆題證。

### 優點

推薦、搜尋、付款各自更新與擴容；不同團隊可沿明確介面協作。

### 代價

增加網路呼叫、分散式追蹤、相容性與維運負擔；小系統不必為拆而拆。

### 上游服務

有期限地等待

→

### 斷路器

異常時快速拒絕

→

### 下游模型

保護恢復空間

斷路器（Circuit Breaker）像電路保護裝置：下游連續失敗達條件時暫停一般呼叫；之後以有限探測確認恢復。與逾時、限制重試、隔離資源及替代流程搭配，降低連鎖故障。

| 情境 | 判斷方式 |
| --- | --- |
| 模型API變慢 | 先查下游／排隊／資源，避免上游無限制等待與無限重試。 |
| 微服務拆好了 | 仍可能共用資料庫、節點或依賴服務；故障隔離必須刻意設計。 |

### 歷屆已考｜115第一次Q45，公告B

斷路器用來避免下游異常擴散。無限制增加執行緒、取消逾時或持續重試，可能加重壅塞；微服務本身不保證單一失效完全不影響其他服務。

來源 [1] 5-16；[5] Q45；技術核對 [24]。

# 容器：把模型連同執行環境一起交付

06 架構B / 容器化（Containerization）減少「我電腦可以、正式環境不行」的落差。

## 可追溯的部署單位

| | |
|---|---|
| **應用與介面** | API程式、錯誤處理 |
| **模型與前後處理** | 權重、Tokenizer／編碼器、推論設定 |
| **依賴與環境** | 套件版本、映像識別碼、啟動方式 |

| 名詞 | 用途與限制 |
|---|---|
| Image 映像檔 | 建立容器的封裝範本。模型也可外部掛載，但須固定版本與完整性。 |
| Container 容器 | 映像啟動後的執行實例；機密憑證不宜直接烘焙進映像。 |
| Docker | 常見建置與執行工具；不是模型訓練演算法，也不會自動處理所有營運問題。 |

**必記｜一致性仍有相容條件**

需考慮CPU架構、主機核心、GPU與驅動等；同一映像不代表在任何硬體都能執行或有相同性能。容器與VM也不同：容器通常共享主機核心，VM具有各自的客體作業系統核心。

# Kubernetes：管理副本與資源的調度員

06 架構B、C / 容器編排（Orchestration）協調服務在哪裡、跑幾份、如何更新。

### Docker看封裝

把應用及依賴做成可重複部署的映像與容器。

### K8s看協調

管理期望副本、排程、更新與故障恢復；需要正確設定與足夠資源。

| 核心元件／機制 | 白話解釋 | 不要混淆 |
| --- | --- | --- |
| Pod／Deployment | Pod承載容器；Deployment維持期望副本並管理更新。 | 模型登錄中心不等於Pod。 |
| Service／流量分配 | 提供服務存取與分散請求的基礎機制。 | 多個副本不表示所有外部依賴都有備援。 |
| HPA水平自動擴縮 | 依CPU或自訂／外部指標，調整工作負載副本數。 | 需設定指標與界限；不會瞬間產生無限運算力。 |
| 模型服務工具 | Flask／FastAPI可建API；TensorFlow Serving提供模型服務能力。 | 工具角色不同，授權、限流、監控仍需設計與整合。 |

### 歷屆已考｜114第二次Q13公告B、Q31公告B

K8s與部署協調、彈性擴充相關；流量增加可評估水平擴展。每秒1萬請求不代表需要1萬個容器，仍要依單副本基準測試、瓶頸與服務目標估算。

# 滾動更新前，先分清三種健康檢查

06 架構延伸 / 滾動更新（Rolling Update）逐批替換實例，過程可能同時有新舊版本。

**載入新版**

模型／快取暖機

→

**檢查可接流量**

成功才納入路由

→

**逐批替換**

舊請求妥善完成

| 檢查 | 回答什麼 | 典型行為 |
| --- | --- | --- |
| Startup 啟動 | 啟動是否完成？ | 容許大型模型載入；成功前暫緩其他兩種Probe。 |
| Readiness 就緒 | 目前能接流量嗎？ | 失敗時從相應Service端點移除；不因此直接重啟容器。 |
| Liveness 存活 | 是否卡死到需要重啟？ | 達失敗門檻時依規則重啟；避免把短暫下游故障一律當自身死鎖。 |

必須記住：預留替換容量、正確就緒檢查、相容的API／特徵格式與優雅終止（Graceful Termination），才能降低中斷風險。資料庫不相容變更，可能使只回滾容器仍無法恢復。

**延伸補充｜非原教材內容**

三種Probe與替換配套用來理解「不中斷更新」的條件。原教材的滾動更新描述應解讀為設計目標，不能當作任何設定都必然零停機的保證。完整YAML設定不建議優先背誦。

# 擴展與高可用：算容量，也要看失效範圍

06 架構D / 水平增加實例，垂直增加單機資源；HA指High Availability高可用性。

### 冗餘 Redundancy

多份服務分散在獨立失效範圍，避免全放在同一故障節點。

### 容錯切換 Failover

偵測異常並轉移流量；剩餘節點還要有足夠容量與可用資料。

## 延伸補充丨非原教材內容：兩個數值回答不同問題

| 問題 | 假設與計算 |
| --- | --- |
| 平均同時在途量 | 穩態同一邊界：L=λW；L是平均在途筆數，λ是每秒進入量（RPS），W是平均停留秒數。120×0.2＝24筆；不能用P95代替平均值。 |
| 最低副本數 | 同模型與硬體、在目標延遲及錯誤率下，每份實測可持續50 RPS，規劃取70%＝35 RPS；120÷35向上取整=4份。 |
| 失去一份仍可用 | 同上且容量可均分，(N-1)×35≥120，至少5份；還需確認共享資料庫與網路瓶頸。 |

### 必記丨有副本，不代表有完整高可用

上列容量公式是假設題，不是所有系統都線性擴展。擴縮有偵測與啟動時間，尖峰前可預留容量；備份用來復原資料，不能直接替代線上副本與故障切換。

# 延遲：模型很快，使用者仍可能等很久

07 公式與算例 / 延遲Latency是耗時；吞吐量Throughput是單位時間完成量。




單筆示例：10 + 25 + 15 + 40 + 10 = 100毫秒。端到端延遲（End-to-end Latency）要先定義量測起訖；只量模型forward時間，會漏掉其他等待。本圖是單筆路徑，不能把各元件P95直接加成整體P95。

| 觀察 | 怎麼讀 |
| --- | --- |
| 平均與尾端延遲 | 20筆耗時：18筆50ms、1筆150ms、1筆350ms；平均70ms。依nearest-rank定義，P95取第19筆 = 150ms。 |
| 批次與資源 | Batching可提升裝置利用率／吞吐量，卻可能增加等待；要實測延遲與成本，不能只看GPU百分比。 |
| 邊緣最佳化 | 量化與推論最佳化可能降低資源需求；仍須確認硬體支援、端到端速度與品質損失。 |

**歷屆已考｜115第一次Q24公告D、Q40公告D、Q41公告A**

Q24辨端到端延遲；Q40在題定硬體限制下選INT8與推論最佳化；Q41依已排除的條件定位GPU排程／批次。GPU利用率60%並不是普遍診斷標準。

來源 [1] 5-20；[5] Q24、Q40～41；延伸核對 [16]。

# 可用性：先定義量測，再談99.9%

07 公式與算例 / SLI、SLO、SLA用來把「服務要穩」變成可檢查的條件。

| 名詞 | 解釋 | 教學例子 |
| --- | --- | --- |
| SLI 指標 | Service Level Indicator；實際量到的服務品質。 | 有效請求成功率、端到端延遲。 |
| SLO 目標 | Service Level Objective；指標在特定視窗的目標。 | 本月有效請求成功率至少99.9%。 |
| SLA 協議 | Service Level Agreement；約定服務條件與未達時的處理／責任。 | 需讀契約的定義、排除項與補償規則。 |

### 請求型示例

10,000筆有效請求中4筆失敗，成功率=(10,000-4)÷10,000=99.96%。

### 時間型示例

若以連續30天可用時間計：43,200分鐘×(1-99.9%)=43.2分鐘不可用預算。

先說明成功的定義、視窗、分母與排除項。請求成功率與時間可用率是不同量測方式；低流量與高流量時段的影響也不同，不可拿兩種分母直接互換。

### 延伸補充｜非原教材內容

SLI／SLO／SLA與誤差預算協助理解可用性及發布門檻；99.9%與30天均是算例設定，並非iPAS或所有雲端服務的統一要求。

來源 [1] 5-17、5-20；延伸核對 [15]。

# 部署位置：先列限制，再比較環境

08 環境選型 / 公有雲、私有雲、邊緣與混合，是部署位置與資源管理的選擇。

| 方式 | 常見優點／適用 | 成本、條件與限制 |
| --- | --- | --- |
| 公有雲 Public Cloud | 快速取得運算與託管服務，適合彈性流量、缺維運人力且資料可依規範處理。 | 費用、網路、資料流向、供應商依賴；並非使用就必然省錢。 |
| 私有雲 Private Cloud | 供單一組織專用，可依需求掌握管理與隔離方式。 | 建置與營運責任較重；可在內部或外部託管，不等於絕對安全。 |
| 邊緣 Edge | 在手機、機台或現場節點執行；可減少傳輸與支援離線情境。 | 記憶體、功耗、模型大小、裝置異質性與更新管理。 |
| 混合 Hybrid | 按資料、工作負載或流程分配不同環境。 | 身份、網路、同步、版本、觀測與成本需共同管理。 |

企業機密文件必須留內部、公開文件可用外部服務：可按資料分類採混合方案。若資料已獲准由合格雲端處理、流量增加且缺維運人員，可評估具彈性的雲端託管服務。

**常見陷阱｜API、容器與邊緣不在同一分類軸**

同一模型可以「容器封裝、部署在邊緣、透過API服務」。本地部署也不一定形成私有雲；混合情境可比正式的混合雲定義更廣，要看題目描述。

來源 [1] 5-17～5-18；[2] p.48～52；概念校準 [27]。

# 雲端訓練、邊緣推論：資料怎麼走？

08 應用案例 / 訓練與推論可以在不同位置，先畫出可移動的資料與資產。

**可用訓練環境**

取得授權資料

→

**候選驗證**

品質／壓縮測試

→

**邊緣發布**

簽章／版本／回復

### 一般混合例

工廠在允許的環境訓練；經驗證模型下發產線裝置做推論，必要時回傳允許的摘要。

### 聯邦學習例

各據點在本地訓練，集中端聚合允許的模型更新；原始資料不必集中。

聯邦學習（Federated Learning）仍需考慮更新資訊可能洩漏、傳輸保護、惡意參與者與使用規範。它不是把原始資料集中到雲端訓練，也不能單憑技術名稱推定已符合法規。

部署選型先問：資料可否離開？推論是否必須離線？硬體與延遲限制？誰負責裝置更新？雲端服務失效時，現場要繼續、降級還是停機？

**歷屆已考｜115第一次Q46，公告C**

在題定「原始資料不得離開、可聚合更新」限制下辨識聯邦學習方向。不能把題目條件擴寫為任何醫療資料一律不能用雲端；實際權限與規範要另行確認。

來源 [1] 5-15、5-18；[2] p.50～52、62；[5] Q23、Q40、Q46。

# 測試：能跑、跑得快、答得對，要分開驗證

09 測試與驗證 / 模型品質通過，不代表整個應用已具備上線條件。

| 測試 | 主要問題 | 客服系統例 |
| --- | --- | --- |
| 單元 Unit | 單一函式或模組是否正確？ | 文字處理、欄位檢查及錯誤碼。 |
| 整合 Integration | API、資料庫、模型能協作？ | 登入後是否只能查自己的訂單。 |
| 效能 Performance | 目標負載下延遲與吞吐是否達標？ | 特定併發下P95與錯誤率。 |
| 壓力 Stress | 超出正常負載或故障時如何退化？ | 尖峰、節點失效與資源耗盡。 |
| 品質 Evaluation | 模型輸出是否符合任務？ | 正確性、切題、少數情境與拒答。 |
| 安全 Security | 是否越權、洩漏或遭不當利用？ | 跨租戶查詢、憑證、工具操作。 |

品質指標銜接5.1：Accuracy看整體正確比例；Precision=TP／(TP+FP)，看判正者有多少真的正；Recall=TP／(TP+FN)，看真正例抓到多少；F1綜合Precision與Recall。TP為判對的正例、FP為誤報、FN為漏報，須搭配業務成本解讀。

必須記住：使用接近實際的資料、流量與依賴條件；測試集與上線監控各有角色。負載測試可檢驗預期需求，壓力測試探索極限及失效後的恢復行為。

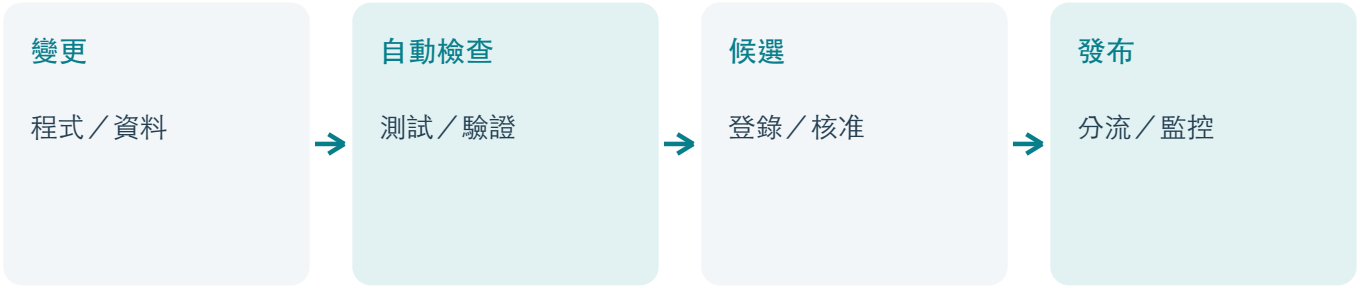
**推測題型｜看到症狀，挑能驗證問題的測試**

「預測很準但大量請求超時」優先檢查效能與容量；「回傳別人的資料」檢查授權與整合。加測試的目的在消除具體不確定性，不是把測試數量當品質。

# CI、CD、CT：三種自動化各管一段

10 MLOps核心 / MLOps（Machine Learning Operations）管理開發到營運的模型生命週期。

| 機制 | 目的與典型工作 | 判斷重點 |
| --- | --- | --- |
| CI 持續整合 | Continuous Integration；變更後建置、單元／靜態檢查與適當驗證。 | 不代表每次小改動都必須完整重訓所有模型。 |
| CD 持續交付 | Continuous Delivery；自動準備可發布版本，正式發布可有核准關卡。 | 與Continuous Deployment區分：後者通過關卡後自動發布正式環境。 |
| CT 持續訓練 | Continuous Training；依資料、排程或合適事件觸發訓練與驗證管線。 | 訓練成功只是產生候選；不等於通過業務／安全門檻。 |




白話理解：自動化把可重複的步驟接起來，責任與驗收條件仍需人設計。高風險服務可保留核准、追溯與緊急停止機制。

**歷屆已考｜114第二次Q29公告B；115第一次Q22公告C**

CI辨識程式提交後的自動建置與檢查；MLOps以自動化、版本管理及持續維護為重點，不能宣稱部署後便不再需要調整與監控。

來源 [1] 5-19；[2] p.71～73；[4] Q29；技術核對 [10]。

# 版本管理：要能回答「這次結果從哪裡來」

10 MLOps資產 / 模型登錄中心（Model Registry）管理可識別的模型版本及相關資訊。

**一次發布 = 模型 + 資料證據 + 程式 + 環境 + 設定**

| 資產 | 追溯內容 |
| --- | --- |
| 資料與前處理 | 資料快照／來源／標註版本、特徵定義、編碼與縮放器，必要時保留可重現流程。 |
| 模型與實驗 | 權重識別、訓練程式、超參數、評估結果、限制與核准紀錄。 |
| 部署與環境 | 映像識別、套件、硬體條件、路由、門檻、上線時間與目前服務版本。 |
| LLMOps銜接 | 大型語言模型營運另納Prompt、模型供應版本、RAG知識庫／索引、工具與評估集。 |

血緣（Lineage）把產物和來源串起來。線上請求帶request_id與model_version，有助追查是哪個版本出錯；只記「latest」而沒有可解析的固定識別，難以重現。

**歷屆已考｜114第二次Q15公告C、Q30公告A**

Q15辨識登錄中心的版本／狀態追蹤；Q30以雜湊與數位簽章支持完整性、來源追溯與不可否認性。雜湊不是加密；只有雜湊也不能證明發布者身分，仍需可信金鑰與流程。

# 工具分工：記實驗、管版本、看系統

10 MLOps元件 / 先理解功能，再把工具放回流程；不需把品牌清單當流程本身。

| 角色／工具 | 主要用途 | 限制與辨別 |
| --- | --- | --- |
| MLflow Tracking | 追蹤參數、指標、程式版本與產物。 | 實驗epoch／學習率紀錄，不等於線上請求監控。 |
| Model Registry | 模型版本、關聯血緣、標記／別名與中繼資料。 | 部署狀態追蹤需與實際發布流程連動；登錄不等於已上線。 |
| DVC | 以Git等中繼資料追蹤大型資料與模型檔版本，內容可在cache／remote。 | 不把所有大型原始資料直接塞入Git；也不取代品質驗證。 |
| 流程編排 | 協調擷取、轉換、訓練、測試等相依步驟。 | 與K8s容器編排概念相關但任務層次不同。 |
| Prometheus | 收集、儲存與查詢數值時間序列，可配合告警機制。 | 不是通用完整日誌資料庫。 |
| Grafana | 連接資料來源，查詢視覺化與告警。 | 圖表不會自動證明模型變差；日誌仍需要對應資料來源。 |

### 必記 | 完整MLOps還包括治理與稽核

權限、核准、責任與稽核紀錄需貫穿資料到模型部署。工具支援流程；漂移門檻、上線條件與處置責任由團隊依情境定義，不能期待裝好儀表板就自動完成。

# 發布與驗證：五種方式，目的不同

11 持續交付 / 不只問「換了沒」，還要問誰接到新版、怎麼觀察、怎麼退回。

| 方式 | 怎麼做 | 重點與代價 |
| --- | --- | --- |
| 滾動 Rolling | 逐批替換實例，期間可能混合版本。 | 節省重建整套環境需求；注意相容、容量與就緒檢查。 |
| 藍綠 Blue-Green | 準備新舊兩套環境，驗證後切換流量。 | 切換與切回較快；額外資源與資料相容需設計。 |
| 金絲雀 Canary | 先給部分正式流量，觀察後逐步擴大。 | 控制影響範圍；需要分流、監控與停止條件。 |
| 影子 Shadow | 複製請求給候選，候選結果不直接影響使用者。 | 比較行為與負載；要隔離寫入／扣款等副作用。 |
| A/B實驗 | 將適當單位分組比較目標與護欄指標。 | 著重效果證據；分組、樣本量、視窗與統計判斷要合理。 |

記憶圖：滾動看「逐批換」，藍綠看「環境切換」，金絲雀看「小流量漸增」，影子看「候選不作決策」。A/B著重比較效果，可與金絲雀共享分流機制，但目的不完全相同。

**延伸補充｜非原教材內容**

影子與A/B比較用來釐清發布安全與效果驗證。不存在所有情境最好的策略；有無額外容量、狀態變更風險及能否量到真實成效，會影響選擇。

# 藍綠部署：換路由之前，先備好可服務版本

11 圖解 / Blue是目前正式版本，Green是已準備的新版本；名稱僅用來區分兩套環境。




圖中兩條箭頭表示不同時間的路由狀態，並非同時各半分流。若要逐步分流，可另搭配金絲雀策略。

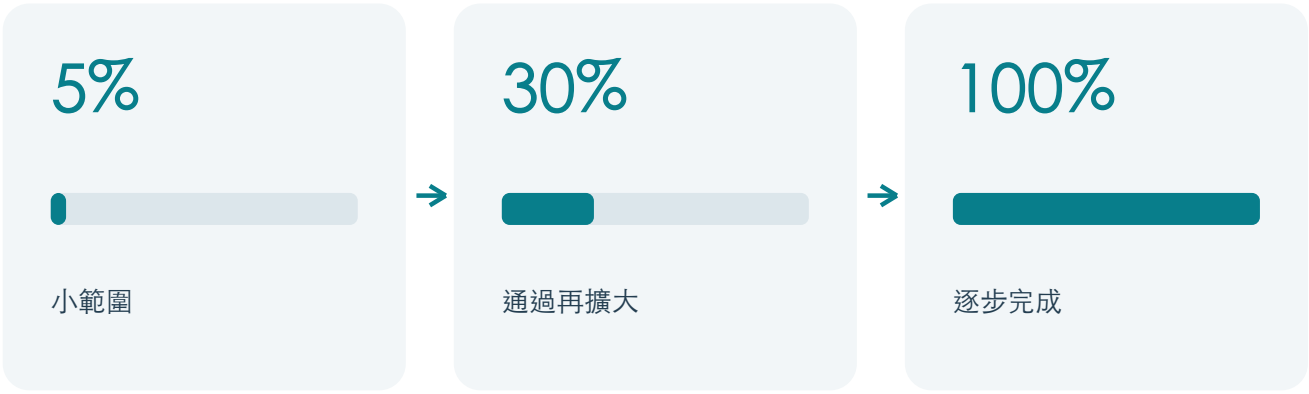
| 階段 | 必須確認 |
| --- | --- |
| 切換前 | Green健康與品質達標；路由、憑證、資料格式及依賴都正確。 |
| 切換後 | 持續看新版本品質、錯誤率與延遲；保留可用Blue及處置權限。 |
| 需要回滾 | 流量可切回，但資料庫已改欄位、發出錯誤交易等不會自動復原。 |

**常見陷阱｜「能快速切回」有前提**

需維持舊版可用、確保資料與介面相容，且處理在途請求。兩套環境有資源成本；藍綠不是必然零成本、零風險或任何狀態變更都可瞬間回復。

# 金絲雀：逐步擴大之前，先訂好停止規則

11 圖解 / 小範圍正式流量帶來真實觀察，也會影響實際使用者。




以上比例只是圖解示例。每階段都需足夠觀察時間、代表性樣本與分群；未達觀測條件就持續等待，異常則依預設護欄停止或回滾。

| 決策 | 典型依據 |
| --- | --- |
| 繼續擴大 | 延遲、錯誤、品質、業務及關鍵族群指標均滿足預定條件。 |
| 暫停擴大 | 資料不足、指標矛盾或出現需診斷的異常，先定位根因。 |
| 回滾／降級 | 觸及已訂安全或服務護欄，轉回穩定版本並記錄事故與影響。 |

**歷屆已考｜115第一次Q43公告C、Q47公告D**

Q43以1～5%真實用戶與業務指標支持金絲雀；比例是該題設定。Q47在30%階段延遲異常，重點是停止擴大並分析優化；是否立即回滾要看已訂護欄，不能仍擴到100%。

# A/B比較：離線更準，不保證線上更有價值

11 應用算例 / 離線評估看資料集上的品質；線上實驗觀察真實流程中的影響。

### A 舊版 | 10,000位

200位轉換 → 轉換率2.0%。

### B 新版 | 10,000位

230位轉換 → 轉換率2.3%。

絕對增加：2.3% - 2.0% = 0.3個百分點

相對增加：0.3% ÷ 2.0% = 15%

| 檢查 | 為什麼需要 |
| --- | --- |
| 分組與歸因 | 依任務選用戶等適當單位隨機分派，維持分組一致，避免同一人混用版本與行為互相影響。 |
| 觀察與樣本 | 確認時間、樣本量、資料品質與不確定性；觀察到15%增幅不等於已證明顯著。 |
| 護欄 Guardrail | 轉換增加仍需看退款、錯誤、延遲、公平與成本；避免單一KPI犧牲其他目標。 |

**延伸補充 | 非原教材內容**

百分點與相對變化、分組與不確定性用來理解成效比較。使用者選擇偏差、同期活動與追蹤變動都會影響結果；未經適當實驗設計，不宜只憑兩個比率宣稱因果。

# 監控四個面向，對接三層成效指標

12 持續營運 / 系統穩定、模型有效、業務有價值，需要不同證據。

| 監控面向 | 看什麼 | 接到哪層成效 |
| --- | --- | --- |
| 系統／服務 | 請求量、端到端P95、錯誤率、可用性、排隊、CPU／GPU與成本。 | 系統層：服務能穩定回應。 |
| 資料 | 缺值、欄位／類型、新鮮度、特徵／輸出分布、重要族群。 | 提供模型與應用診斷依據。 |
| 模型／應用 | 有標註後看Accuracy、F1、RMSE、校準；推薦點擊率等依任務定義。 | 應用層：功能結果是否有效。 |
| 業務 | 轉換、留存、作業成本、錯誤損失與投資報酬率ROI（Return on Investment）；並看安全／風險護欄。 | 商業層：是否形成實際效益。 |

重要差異：日誌Log記錄事件，指標Metric摘要數值，追蹤Trace串起一次請求跨服務的耗時。三者互補；日誌的欄位與保存範圍也需符合資料管理要求。



歷屆已考｜115第一次Q42公告D、Q49公告A

整體RMSE穩定仍可能漏掉高額族群的退化，須分群監控；不能說RMSE天生不在乎大誤差。epoch、學習率與超參數是訓練實驗追蹤，不能直接當作正式環境的即時服務指標。

# 漂移：分布變了，不等於已證明模型壞了

12 核心辨析 / 漂移偵測是預警線索；成效判斷仍需任務、標註與業務證據。

### 資料漂移 Data Drift

常指輸入分布P(X)改變，例如年齡、交易金額或影像亮度改變。

### 概念漂移 Concept Drift

輸入與標籤的條件關係P(Y|X)改變；同樣特徵對結果的意義可能改變。

| 看到的訊號 | 可推論／不可推論 |
| --- | --- |
| PSI／KL等分布差異 | 可提示特徵分布改變；需合理分箱、參考視窗與門檻，不能直接證明準確率已下降。 |
| 輸出分布改變 | 可能來自輸入或模型／設定變動；不等於單憑此就證明概念漂移。 |
| P(X)大致相同 | 仍可能有P(Y\|X)改變；整體AUC穩定也不能排除局部或校準問題。 |
| 品質或族群退化 | 檢查標註延遲、樣本量、分群與資料管線，才能判斷修資料、調門檻或重訓。 |

符號：X是輸入特徵，Y是預測目標。PSI（Population Stability Index，群體穩定性指標）比較分箱占比；KL（Kullback-Leibler Divergence，KL散度）衡量分布差異。兩者的數值不是模型準確率，也不能共用一個通用告警門檻。

**歷屆已考｜114第二次Q22公告D、Q32公告D、Q46公告A；115 Q48公告C**

KL／PSI用於分布監測；Q48辨識P(Y|X)變化。偵測到漂移後先檢查原因與影響，不能跳成「任何漂移都必須立刻重訓並自動全量上線」。

# 回饋與HITL：把錯誤轉成可用證據

12 營運回饋 / Human-in-the-Loop人機協作，要讓人能看懂、修正與介入。

### 01 收集

系統錯誤、使用者申訴、客服與營運案例，連同版本與情境。

↓

### 02 專業複核

判定是否錯誤、原因與影響；避免把點擊、申訴或模型自評直接當真值。

↓

### 03 修正標註與流程

建立一致規則，處理分歧，更新資料／知識／工具或交給人工處置。

↓

### 04 驗證與追蹤

確認改善未傷害其他族群；追蹤結果並回到發布循環。

例：客服回報「配送地址答錯」。先查是讀錯訂單、權限或工具失敗，還是模型理解錯。若資料查錯，直接重訓未必有效；若需人工介入，審核者應具備資訊與處置權限。

**必記｜節奏依風險與資料速度調整**

原教材以每日看系統、每週回收案例、每月重新評估為例；這是營運安排示意，不是固定考試規定。高風險事故要即時處理，不必等到例行會議。

來源 [1] 5-20～5-21；[2] p.69～70。

# 改善循環：先找原因，再選擇更新方式

12 模型更新 / 再訓練Retraining只是選項之一，發布新模型仍要重新驗收。

### 01 告警與影響確認

看分群、標註、時間與版本；必要時先降級或回滾。

↓

### 02 根因診斷

資料錯誤、輸入變化、概念變化、服務瓶頸或操作流程？

↓

### 03 產生改善候選

修管線／更新知識／調Prompt或門檻／補標註／微調或重訓。

↓

### 04 驗證與核准

比較品質、族群、效能、成本與安全；保留完整血緣。

↓

### 05 安全發布並觀察

依風險分流；準備回復方案，確認改善後再擴大。

**原教材門檻解讀｜5%不是所有模型的共同觸發標準**

若準確率90%降到85%，是下降5個百分點，相對下降約5.56%。需先約定分母、觀察視窗與樣本量；自動觸發流程可以先啟動診斷／訓練，不代表候選必須自動上線。

# AutoML、線上學習與重訓，不要畫等號

12 持續優化 / 自動化搜尋與持續更新解決不同問題，也有各自的風險。

| 方式 | 目的與運作 | 適用條件與限制 |
| --- | --- | --- |
| AutoML | 自動化部分模型、特徵或超參數搜尋與比較。 | 需適當資料切分、搜尋預算與驗收；不保證找到所有情境最佳模型。 |
| 批次重訓 | 累積一段資料後重新建立候選，再驗證發布。 | 易設審查與比較；更新有週期，需計算訓練成本。 |
| 線上／增量學習 | Online／Incremental Learning；依新資料逐步更新參數。 | 適合可用的更新演算法；需防錯標、污染、遺忘與不穩定。 |
| 動態特徵維護 | 特徵欄位／維度、前處理與模型一起管理。 | 增量更新樣本不表示自動支援新增任意特徵維度。 |

情境判斷：模型收到新的交易案例，可能使用增量更新；若新增一整組從未定義的特徵，需檢查表示方式、介面及模型是否支援。不能單憑partial_fit或「在線」二字假設一切相容。



歷屆已考｜115第一次Q34，公告B

題目以動態變化情境選增量學習方向。本冊補上演算法條件：固定維度模型通常仍需固定輸入形狀；使用線上學習與AutoML也不能保證準確率永遠維持。

來源 [1] 5-21；[5] Q34；技術延伸 [30]。

# 跨部門治理：上線之後，誰決定下一步？

13 組織協作 / 技術指標與業務指標共用，處置權限與責任也要清楚。

| 角色 | 主要責任 | 遇到異常時 |
| --- | --- | --- |
| 業務／行銷 | 情境、成功指標、策略應用與效益回饋。 | 確認哪些損失、族群與業務行為受影響。 |
| 客服／營運 | 回收互動案例、申訴及現場問題。 | 提供可追溯案例；執行替代與人工流程。 |
| 法務／風險 | 隱私、公平、風險揭露與使用框架審查。 | 評估是否需限制使用、通報或補救。 |
| 資訊／技術 | 部署、權限、API整合、監控與維運。 | 故障定位、止血、回復與修正驗證。 |
| AI產品經理／協調人 | 連接技術與部門，維持一致目標與決策紀錄。 | 協調優先序、核准人與改善時程。 |
| AI治理委員會 | 資源、風險與戰略；建立跨部門教育。 | 處理重大跨部門取捨與持續治理。 |

常態機制：定期工作小組、共用KPI、資料異常與需求變更的快速決策通道。例：推薦點擊上升但退貨也升高，業務、營運及技術須共同檢查，不宜只宣布模型成功。

**必記｜人工審核要有實際介入能力**

Agent下單、改帳或發送訊息等操作需明確授權與界限；設計審核資訊、停止條件及處置責任。共用儀表板能促進溝通，不能替代責任分工與決策程序。

來源 [1] 5-21～5-22；[2] p.59～60、73。

# 整合案例：把電商推薦服務交給營運

13 應用整合 / 以下為自編案例，示範從業務限制到監控、回滾與改善的連結。

**需求與資料**

CRM與訂單來源有權限；線上特徵定義一致，先定品質、延遲與成本目標。

↓

**封裝與介接**

固定模型／映像／前後處理版本；API驗證與限流；ERP／CRM依契約使用結果。

↓

**測試與發布**

離線與分群品質 + 整合／負載／安全測試；小流量金絲雀，預設停止與回滾條件。

↓

**營運與改善**

技術看延遲與錯誤，業務看轉換與退貨，客服回收案例；根因確認後產生候選。

| 異常 | 合理第一步 |
| --- | --- |
| 新版慢、品質正常 | 先檢查排隊、特徵讀取、硬體與路由；依護欄處置，避免直接重訓。 |
| 高額訂單效果退化 | 補看該族群資料、標註與校準；整體平均正常也須處理。 |

**考試解法：圈出硬限制 → 定位流程層次 → 選對工具角色 → 看驗收證據 → 確認異常處置。**

教學整合：[1] 5-14～5-22；[2] p.44～74。

# 原教材對照：保留核心，補上適用條件

14 完整性與常見陷阱 / 以下是技術釐清，並非官方更改考試答案的公告。

| 容易誤記的說法 | 本冊判斷方法 |
| --- | --- |
| OAuth／JWT都等於登入 | 區分授權框架、權杖格式與身分層；驗證後仍需授權、限流。 |
| 微服務天然完全隔離 | 依賴仍可能連鎖故障，要有逾時、斷路器、資源隔離及降級。 |
| 容器／滾動必然零停機 | 檢查硬體相容、就緒、容量、優雅終止與資料／API相容。 |
| Service Mesh自動同步資料 | 服務通訊與可觀測性不同於資料複製、交易與衝突處理。 |
| 監控告警就直接重訓 | 先診斷資料、系統與品質；候選模型驗證通過後再安全發布。 |
| AutoML／在線能永遠準確 | 需要切分、標註、預算、風險與驗收；也未必接受任意新增欄位。 |

覆蓋核對：官方5.2的五類整合、四類架構、四種部署位置、MLOps、三層成效、持續優化與跨部門協作，均已涵蓋。附件的API、Agent權限、測試、HITL與LLMOps亦已銜接。

**延伸補充｜非原教材內容的閱讀順序**

Probes、SLI／SLO、容量與百分點算例、影子／A/B細節用來理解題意；完整設定與推導不建議優先背誦。LLMOps還需看回答品質、Token成本、工具操作與安全，不能只沿用單一Accuracy。

# 考試重點：優先順序要有證據

14 考點索引 / 紅 = 優先掌握；橙 = 重要理解；綠 = 補充認識。不是官方公布權重。

| 知識點 | 優先 | 考查方式 | 判斷依據 |
| --- | --- | --- | --- |
| 整合與即時服務 | 紅 | 情境選型 | 官方評鑑；115 Q20、Q44。 |
| K8s與彈性擴展 | 紅 | 工具／架構 | 114 Q13、Q31。 |
| 版本、CI與MLOps | 紅 | 流程／角色 | 114 Q15、Q29～30；115 Q22。 |
| 發布、金絲雀與保護 | 紅 | 情境決策 | 115 Q43、Q45、Q47。 |
| 監控、分群與漂移 | 紅 | 指標／概念 | 114 Q22、Q32、Q46；115 Q42、Q48～49。 |
| 延遲／邊緣最佳化 | 紅 | 限制下選擇 | 115 Q24、Q40～41。 |
| 環境、測試與治理 | 橙 | 架構／協作 | 官方評鑑；教材5-17～5-22；附件p.66～73。 |
| 完整Probe設定／公式推導 | 綠 | 補充理解 | 延伸工具細節；無本冊兩卷直接題證。 |

## 考前必記

① API、容器、邊緣是不同面向。 ② 發布前先定驗收與回復條件。

③ 系統、模型與商業指標要聯動。 ④ 漂移是線索，重訓先驗證。

⑤ 裝工具之外，仍需可追溯資產、授權與跨部門決策。

# 考前3分鐘：八個判斷點

15 章節總整理 / 先確認流程層次，再從選項辨識適用條件。

- **整合五面向**：資料管線、企業系統、API平台、安全權限、跨雲異質環境。結果要能接回實際流程。
- **三種觀察軸**：API是溝通方式，容器是封裝，公有雲／私有雲／邊緣是位置與管理選擇，可以組合。
- **服務要保護**：授權控制能做什麼，限流控制頻率；斷路器抑制故障擴散，Mesh不替代資料一致性設計。
- **容量要實測**：RPS不是實例數。依單實例在SLO下的承載估算，還須預留失效容量；平均在途量L=λW。
- **發布要可退**：滾動逐批換、藍綠切環境、金絲雀漸增流量；健康、相容、監控與回復條件先定好。
- **MLOps要追溯**：資料、程式、模型、前後處理、環境與核准一起記；CI／CD／CT各有角色。
- **監控要分群**：延遲與錯誤看系統，標註品質與指標看應用，轉換／成本／ROI看商業；整體正常不代表人人正常。
- **改善要找根因**：P(X)變是資料漂移線索，P(Y|X)變是概念漂移；修資料／流程、補標註或重訓後，都要再驗證。



**最容易掉分的語句**

「一定零停機」「有JWT就不會大量呼叫」「有漂移必須立即重訓」「裝上工具就自動治理」「某比例一定適用」都省略了必要條件。先找題幹限制與證據，再判斷。

整合 [1]、[2]、[3]；紅色考點依兩卷可核實題目，未推測配分。

# 練習1～2：工具角色與發布處置

16 自編模擬題 / 單選，每題只有一個最佳答案。先作答，詳解集中p.41～43。

## 第1題 | 下列工具／機制的描述，何者正確？

A 只要改用JWT，就能自動阻止同一使用者短時間大量請求。

B Kubernetes擴增副本後，便可保證所有族群的模型品質不下降。

C Model Registry可管理模型版本與血緣；發布與線上監控仍需整合。

D Service Mesh會自動讓各雲端的業務資料保持完全一致。

我的選擇：_____

## 第2題 | 金絲雀擴至30%後，應如何處理？

護欄：新版P95連續兩窗超過200ms即回滾；目前兩窗皆280ms，舊版穩定。何者最適當？

A 直接擴大到100%，用更多請求攤平平均值。

B 只把護欄改成300ms，不需核實原因。

C 略過部署與容量檢查，直接重訓並全量替換。

D 停止擴大，依護欄切回穩定版，保留紀錄並診斷原因。

我的選擇：_____

# 練習3：留下一份故障空間

16 自編模擬題 / 單選計算；承載基準、安全餘裕與故障條件都已明示。

## 第3題 | 至少需要幾個相同實例？

某AI推論服務的峰值需求為180 RPS（每秒請求數）。在相同模型、硬體及目標延遲／錯誤率下，每個實例實測可持續80 RPS。規劃時，每個實例只採用此承載的75%，且必須在任意一個實例故障後，仍可滿足全部180 RPS需求。

假設：流量可均分、所有實例承載相同、故障切換有效；後端與網路不構成額外瓶頸。問題問的是滿足上述條件的「最少」總實例數。

A 3個

B 4個

C 5個

D 240個

我的選擇：_____

計算區：_____

_____

# 來源索引與分析邊界 1/2

17 可追溯來源 / 青綠條目可點開；圖解、數字與練習均自行編製。

[1] 官方科目一學習指引：5.2，5-14～5-22／PDF p.155～163。

[2] 附件002_AI導入評估：PDF p.44～74；含p.45、65圖示。

[3] 官方評鑑內容範圍115.06：L21302。

[4] 114第二次科目一公告題與答案；本冊標示相關題號。

[5] 115第一次科目一公告題與答案；本冊標示相關題號。

[6] Docker：What is a container；封裝、隔離與VM差異。

[7] Kubernetes：Deployments；副本與Rolling Update。

[8] Kubernetes：Liveness, Readiness, and Startup Probes。

[9] Kubernetes：Horizontal Pod Autoscaling；控制與指標。

[10] Google Cloud：MLOps；CI／CD／CT、驗證與特徵。

[11] MLflow：Model Registry；版本、血緣與中繼資料。

[12] DVC：Get Started；資料／模型版本、cache與remote。

[13] Prometheus：Overview；數值時間序列與告警。

[14] Grafana：Fundamentals；資料來源、視覺化與告警。

[15] Google SRE：Service Level Objectives；SLI／SLO／SLA。

證據屬性：【官方評鑑】能力範圍；【教材重點】原指引與附件；【歷屆已考】公告題與答案；【推測題型】依觀念自編。兩卷各50題，本冊選取相關題建立索引，未進行完整頻率排名；同題支持不同概念仍只是一題，不宣稱未來必考或配分。

原教材已實讀範圍：官方5.2完整主文；附件相關p.44～74，包含文字抽取以外的圖示。勘誤表未見科目一5.2專屬修正；本冊技術釐清不冒稱官方更正公告。

# 來源索引與分析邊界 2/2

17 可追溯來源 / 青綠條目可點開；圖解、數字與練習均自行編製。

[16] Google SRE：Monitoring Distributed Systems；延遲與監控。

[17] Google SRE：Canarying Releases；部分流量與發布判斷。

[18] AWS：Blue/Green Deployments；環境切換與資料層考量。

[19] IETF RFC6749：OAuth 2.0 Authorization Framework。

[20] IETF RFC7519：JSON Web Token；宣告與保護方式。

[21] OpenID Connect Core 1.0：OAuth2上的身分層。

[22] gRPC：Core concepts；各種RPC及串流型態。

[23] GitHub：About webhooks；事件觸發HTTP通知。

[24] Microsoft Azure：Circuit Breaker pattern；故障隔離。

[25] Istio：What is a service mesh；流量、安全與觀測。

[26] MLflow：Tracking；實驗參數、指標及產物。

[27] NIST SP800-145：The NIST Definition of Cloud Computing。

[28] MIT 1.041／1.200（2026）：Queuing models；Little's Law。

[29] Firebase：About A/B tests；分組、觀測與統計判斷。

[30] scikit-learn：Scaling strategies；增量學習與固定特徵空間。

延伸補充｜非原教材內容：介面契約、快取、身分層、斷路器、probes、容量與可用率／百分點算例、影子／A/B及圖解題均屬教學補充。斷路器等雖非主文詳述，已有本冊所引歷屆題證；完整工具設定與推導不建議優先背誦。

覆蓋邊界：官方5.2相關項目已涵蓋；附件Agent推理流程、雲端服務模式僅作跨章銜接，工具設定與L22／L23完整數學另學。實際法規與契約須另依情境查證；聯邦學習案例只解讀題設限制。

# 附錄解析1：工具支援流程，不代替流程

18 答案與逐項解析 / 第1題，題目見p.37。

**正確答案 C**

Model Registry管理模型版本與來源關聯，協助可追溯與一致發布；是否已上線、線上品質如何，仍需與發布、路由及監控流程連動。

| 選項 | 判斷與理由 |
| --- | --- |
| A 錯誤 | JWT是權杖格式，可承載身分／授權宣告；不會單憑存在就限制請求頻率。大量呼叫需速率限制與容量保護。 |
| B 錯誤 | Kubernetes協調執行資源及副本，不能由擴容保證所有族群的模型品質；仍要標註、評估與分群監控。 |
| C 正確 | 版本與血緣是登錄中心的重要角色；發布與線上監控需具體整合，不把登錄誤當作完整營運。 |
| D 錯誤 | Mesh管理服務流量、安全與觀測；跨雲資料同步與業務狀態一致性，要另做資料和交易設計。 |

### 解題口訣｜先問工具在處理哪一層

身分與授權、流量保護、運算編排、模型血緣、資料同步是不同責任。凡選項用「有某工具就保證全部結果」的語氣，先檢查是否省略條件。回到p.8～12、21～22。

學習重點：權限／限流、編排、Registry、Service Mesh；[1]、[11]、[25]。

# 附錄解析2：依事前護欄處置，再找根因

18 答案與逐項解析 / 第2題，題目見p.37。

正確答案 D

題幹已明定P95連續兩窗超過200ms即回滾，且兩窗均為280ms、舊版穩定。因此先停止擴大並依約切回，保留版本、流量、追蹤與錯誤紀錄，再調查瓶頸。

| 選項 | 判斷與理由 |
| --- | --- |
| A 錯誤 | 擴到100%會增加曝險；更多流量不保證攤平尾端延遲，甚至可能使排隊與錯誤更嚴重。 |
| B 錯誤 | 事後只放寬門檻會掩蓋未達標；改目標需有業務依據與正式決策，不可取代診斷與止血。 |
| C 錯誤 | 延遲問題可能在排隊、硬體、取特徵或路由。未定位就重訓，且跳過驗證全量替換，無法合理控制風險。 |
| D 正確 | 先依既定護欄降低影響，再分析與驗證改善；候選通過後重新小範圍發布，而非永久放棄新版本。 |

**判斷差異｜這一題明示了回滾條件**

一般金絲雀異常可能先暫停增流、診斷或降級；本題額外給出「達門檻即回滾」，所以選擇明確。不要把所有異常都背成同一種處置。回到p.23～25、30。

# 附錄解析3：故障後仍要夠用，最少四份

18 答案與逐項解析 / 第3題，題目見p.38。

**正確答案 B**

| 步驟 | 計算與判斷 |
| --- | --- |
| 每份規劃承載 | 80 RPS × 75% = 60 RPS；此為題定安全餘裕，不再重複打折。 |
| 故障後可用份數 | N個相同實例失去一個後，只剩N-1個可分擔需求。 |
| 建立不等式 | (N-1)×60 ≥ 180，因此N-1 ≥ 3，N ≥ 4。 |
| 檢查最少值 | N=4時失去一個，3×60=180 RPS，恰能達標；N=3時只剩120 RPS。 |

| 選項 | 判斷與理由 |
| --- | --- |
| A 錯誤 | 3份只在全部正常時達180 RPS；一份故障便不足，漏掉備援條件。 |
| B 正確 | 4份可在任一份故障後，留下3份、總計180 RPS；符合最少數。 |
| C 錯誤 | 5份也能承載，但題目問最少數；4份已足夠，沒有必要多加一份。 |
| D 錯誤 | 180÷75%=240仍是RPS量綱，不能直接當成實例數；必須除以單份承載。 |

實務限制：此為理想容量估算。共享後端、分流不均、啟動時間、尾端延遲與多節點失效都要另測；不能拿算例保證實際部署一定達標。回到p.14～16。