iPAS 中級 AI 應用規劃師

3.4

多模態 AI 技術與應用

Multimodal Artificial Intelligence

把不同來源的線索，對得上、合得好、驗得清。

圖解精讀教材 / 第 1 版

本章的記憶主線

先對齊	再融合	最後驗證
時間／空間／語意	早期／中期／晚期	互補／缺失／成效

章節基本資訊

科目：L21 人工智慧技術應用與規劃
主要評鑑：L21104 多模態人工智慧應用
銜接 L21201／L21203／L21301／L21302
預估閱讀：70～95 分鐘（估算，含解析、不含作答）

優先掌握：對齊與融合差異、CLIP 零樣本分類、模態缺失及架構選擇。依官方範圍、已取得的兩份考題與核心先備必要性排序，不代表官方配分。

完成後，你應該能夠

- 依資料特性選擇編碼器與融合位置。
- 用圖解說明 CLIP、生成模型與跨模態注意力的差別。
- 計算相似度及融合分數，規劃缺失情境與成效驗證。

閱讀：觀念 p.2～9 → 模型與對齊 p.10～18 → 應用與治理 p.19～24
考點 p.25～26 → 三題 p.27～28 → 複習／來源 p.29～30
三題完整解析只放最後 p.31～33，可先作答再翻閱。

多模態：整合線索，不是只把檔案放一起

01 重點速覽 / Modality 指資料表達或感知形式；本章學整合的條件。

- 文字、影像、音訊與感測訊號，具有不同的結構與取樣方式。
- 同一事件的多種線索可以互補，也可能互相矛盾或帶入雜訊。
- 對齊建立對應關係；融合把線索整合成表示或決策。
- CLIP 以圖文對比學習建立共同嵌入空間；原始模型不直接生成描述。
- 多模態是否有幫助，要與單模態基準比較，也要測模態缺失。

輸入	可提供的線索	不能只憑它推斷
商品照片	顏色、外觀、可見瑕疵。	未入鏡的規格或實際庫存。
顧客文字	需求、主觀評價、背景敘述。	敘述全部屬實或時間正確。
語音／環境音	說話內容、節奏、機器異音。	情緒、身分或故障原因一定正確。
感測器時序	溫度、振動、位置等變化。	與照片就是同一台機器、同一時間。

判斷法｜看資料關係與任務，不只看檔案數

十份文字 PDF 不因檔案變多就變成多模態；同一圖片的 PNG 與 JPEG 也不是兩種感知模態。圖像加文字可以做多模態分類或檢索，不必一定生成內容。資料庫雖收多種資料，仍要看系統如何關聯與利用。

來源 [1] 3-73～74；[2] p.62～63；[4] L21104；例子為自編。

演進脈絡：從拼接，到可互動的共同表示

02 核心知識 A / 這些方法可以共存，並非每個系統都必須採統一大模型。

特徵拼接｜先把線索裝進同一袋

各來源轉成數值特徵，再交給分類器；簡單、容易建立基準。

↓

模態專屬網路｜各有所長再合作

影像、文字、時序各用合適編碼器，再設計融合層。

↓

對比與注意力｜學對應或細部互動

對比學習拉近配對表示；跨模態注意力依內容選擇另一模態線索。

↓

共享與混合架構｜依任務整合

可用統一編碼器、橋接模組或多個模型；系統端到端不等於全共用權重。

基礎拼接也能由後續模型學到某些交互關係，只是不會自動保證時間或語意對齊。使用 Transformer 也不代表任何資料都能不經轉換就直接送入。

重要差異｜多模態與生成式是不同分類軸

影像 + 文字做風險分類：多模態但輸出是分類。只靠文字提示寫文章：可屬生成式但使用的是單一輸入模態。影像 + 文字產生報告：同時具有多模態整合與生成能力。

來源 [1] 3-74～75、3-83；[2] p.64～68；[7]。

對齊：先確認「是不是同一件事」

02 核心知識 B / Alignment 建立對應；Fusion 才是整合資訊。

層次	解決的問題	實務判斷
實體／樣本配對	照片、紀錄是否來自同一個對象？	用設備ID、事件ID、病患ID與時間窗配對，避免錯人錯物。
時間對齊 Temporal Alignment	語音、影片、振動的事件是否同時？	檢查時鐘偏移、頻率與延遲；必要時重取樣或對齊序列。
空間對齊 Spatial Alignment	不同感測器的位置是否能對應？	攝影機與雷達須考慮座標轉換、校正與遮蔽。
語意對齊 Semantic Alignment	不同表示是否對應同樣的意思？	將「紅色鞋」文字與相關圖片映射至可比較的語意表示。

時間戳一樣 ≠ 語意一樣；維度一樣 ≠ 已經對齊

白話例：同一分鐘拍到一台機器，感測檔卻來自隔壁產線；即使向量長度相同、時間也相近，融合仍可能把線索接錯。必須先查資料的身分、時間與內容。

【歷屆已考】115第一次 Q18，公告答案 D：共同語意空間讓不同模態建立語意關聯。它不等於自動補標註，也不保證儲存或計算成本下降。

來源 [1] 3-74、3-77、3-80～81；[6] Q18；[7]；空間例為延伸。

編碼器：資料先轉成模型能用的表示

02 核心知識 C / Encoder 擷取特徵；Embedding 是學到的數值表示。

模態	可用的表示／模型	選擇理由與限制
影像	像素／影像區塊；CNN 或 Vision Transformer（ViT）。	保留空間、紋理或物件線索；縮圖可能丟掉小字與瑕疵。
文字	Token 序列；Transformer，例如BERT類編碼器。	利用字詞與上下文；需斷詞、詞元化與長度管理。
語音／音訊	波形、頻譜或音訊嵌入。	同時含內容、韻律與環境聲；ASR文字不保留全部聲學線索。
數值時序	帶時間索引的序列；LSTM 或 Temporal CNN。	學時間變化；需處理頻率、單位、缺值與有效時間窗。

Long Short-Term Memory：長短期記憶網路；Temporal CNN：時序卷積網路

白話：像是請不同專家先整理各自能看懂的資料，再決定怎麼合作。不能把原始圖片直接當成已經對齊的文字詞元；模型架構具通用性，也仍需要輸入編碼及合適訓練。

考試角度｜挑「符合資料特性」的組合

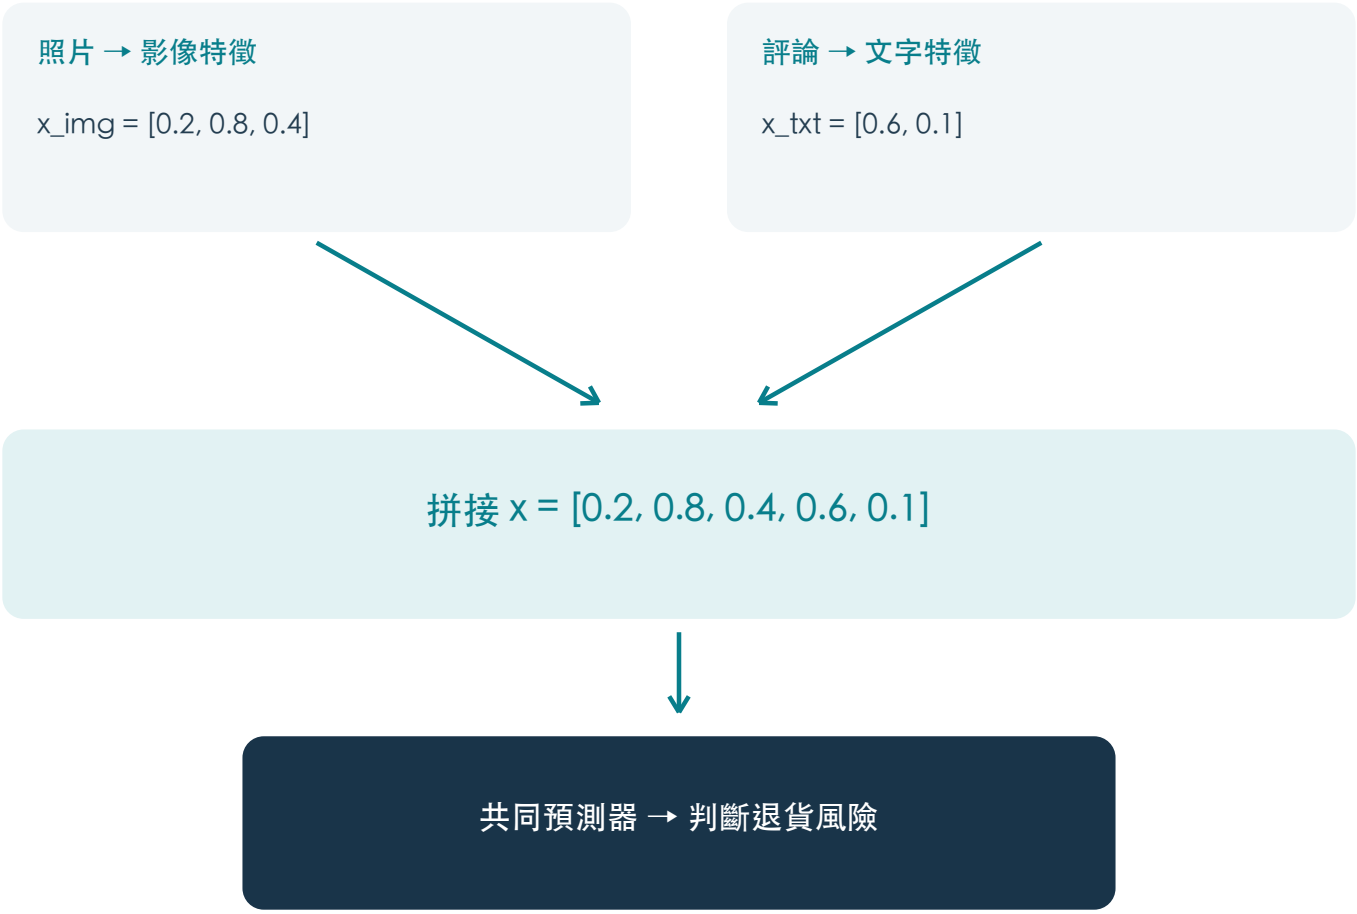
115第一次 Q17 公告 D：影像CNN、文字Transformer、時序LSTM或Temporal CNN。這是該題選項中合理的組合，並非宣告影像只能CNN、所有時序不能用Transformer。

來源 [1] 3-74～77；[2] p.65～66；[6] Q17；例子為自編。

早期融合：先整合特徵，再共同預測

02 核心知識 D / Early Fusion；本冊以「進入主要聯合預測器之前」為判準。

定義：先把原始資料或基礎特徵放在一起，再交給共同模型。常見做法是特徵拼接（Concatenation），不是把圖片與音訊的原始位元直接相加。



維度計算：3 維 + 2 維 = 5 維；拼接保留兩組欄位，不會自動把不同單位、樣本或語意變成可比。標準化與降維若需要學習統計量，應只在訓練資料擬合。

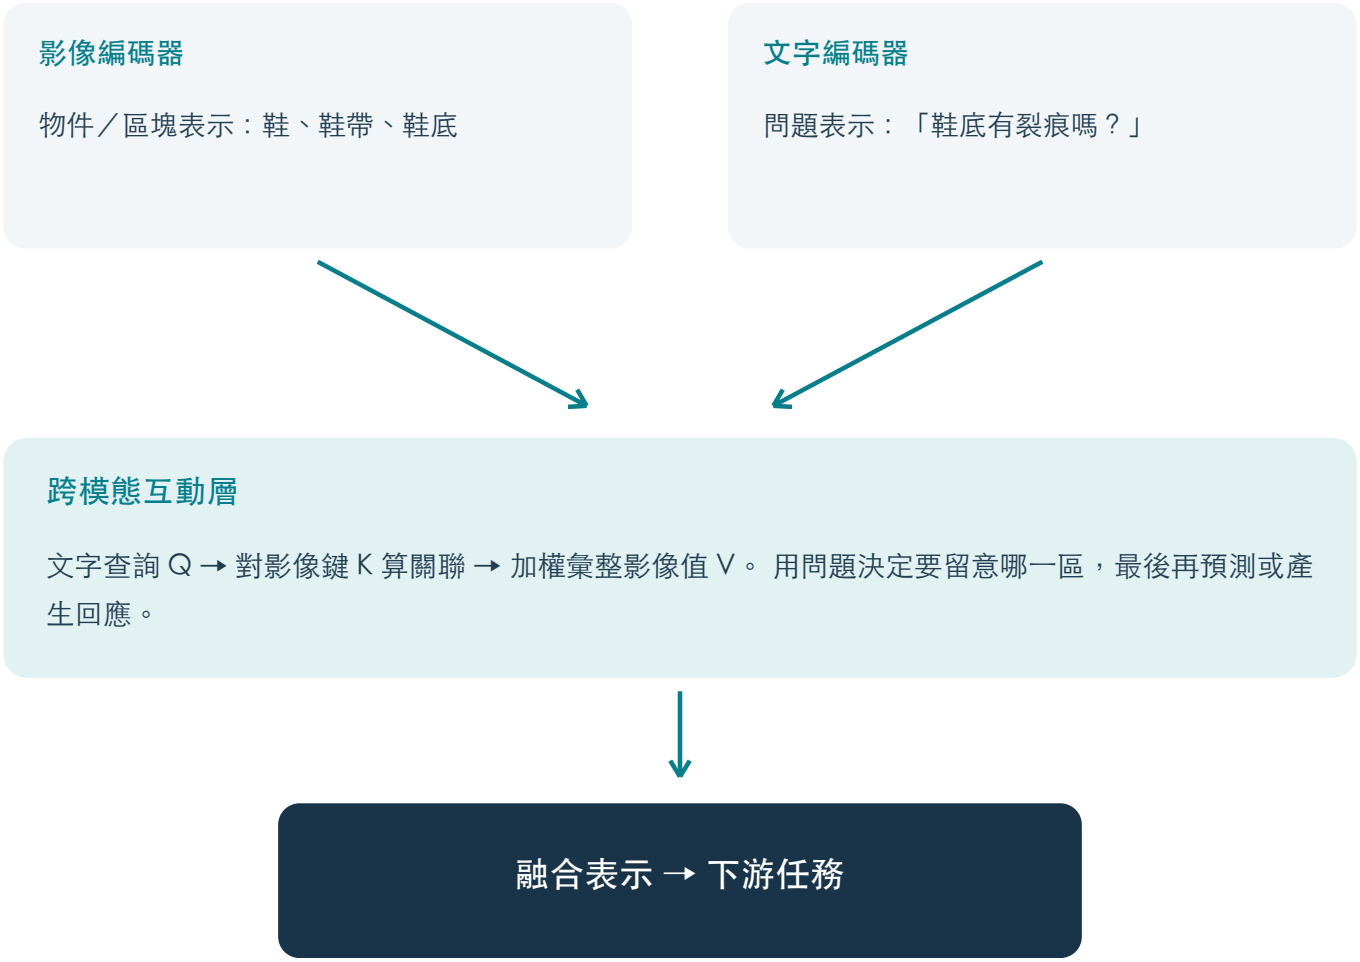
必記｜可學交互作用，也會一起承受雜訊

優點是流程直接、共同模型能利用多來源線索；限制是配對、縮放與缺失處理。雜訊模態可能干擾主模型，多加資料不保證優於單模態。

中期融合：先各自編碼，再在中間互動

02 核心知識 E / Intermediate Fusion；跨模態注意力是常見互動方式之一。

定義：模態專屬編碼器先形成表示，再讓中間層交換資訊。跨模態注意力（Cross-modal Attention）可讓某模態的查詢，選擇另一模態的相關特徵。



Q = Query（查詢）；K = Key（鍵）；V = Value（值）。此處是概念示意，實作通常包含可學投影、多頭及多層結構。優點是能依內容互動，代價是設計與運算較複雜。

容易混淆：Self-Attention 在同一序列內取Q/K/V；Cross-Attention由一組表示查詢另一組。原始CLIP雙塔沒有這個跨圖文注意力層，不能只見Transformer就判中期融合。

來源 [2] p.66、68；[7][10]；圖解與客服例為自編。

晚期融合：各自預測，再整合決策

02 核心知識 F / Late Fusion／Decision-level Fusion；保留各分支的獨立結果。

定義：每個模態先完成同一任務的預測，再以投票、加權等方法形成最終結果。例：影像與振動各自預測「設備將故障」的分數。

影像模型的故障分數

p_img = 0.80；權重 w_img = 0.70

振動模型的故障分數

p_vib = 0.40；權重 w_vib = 0.30



$$p_{fuse} = 0.70 \times 0.80 + 0.30 \times 0.40 = 0.68$$

符號：p 是同一目標事件的預測分數，w 是非負權重；本例權重合計1。兩模型的類別定義、有效時間窗及分數尺度應一致，必要時先做校準。

逐步計算：影像貢獻0.56，振動貢獻0.12，合計0.68。若題設門檻為0.60，則判為需預警。0.68是本例融合分數，不代表已證明真實故障機率為68%。

歷屆已考｜115第一次 Q50，公告 D（問最不可能）

D錯在把晚期融合說成輸入階段整合特徵。模態分支獨立與權重調整有助降低局部雜訊影響，但不是免疫；仍需同一對象與時間窗，不可完全不對齊。

來源 [1] 3-77需釐清；[2] p.67；[6] Q50；計算為延伸自編。

比較融合策略：看「資訊第一次匯合」在哪裡

03 重要差異 / 分類用於理解架構，命名仍需配合原圖與定義。

策略	整合位置	主要優點	主要限制
早期	原始資料／基礎特徵，進入共同模型前。	直接利用聯合線索；基準容易建立。	對齊、單位、雜訊與缺失可能一起影響模型。
中期	專屬編碼器之後，在中間層互動。	保留專業特徵，又可細緻交互。	設計及運算成本較高；仍需資料關係正確。
晚期	各分支輸出預測後，在決策層整合。	模組化；可調權重或做部分降級。	難直接利用細粒度特徵交互；分數需可比。
混合／多層	同時在多個層級整合。	依任務安排互動與獨立分支。	不能只靠名稱判斷；需看實際資訊流。

名詞提醒：Feature-level Fusion 有時統稱較早的特徵融合；若先有深層專屬編碼器，也可能歸為中期。附件把 Mid／Hybrid並列，本冊不將兩者視為嚴格同義：Hybrid可能混用早、中、晚多種機制。

情境選擇｜需求比「哪個最先進」重要

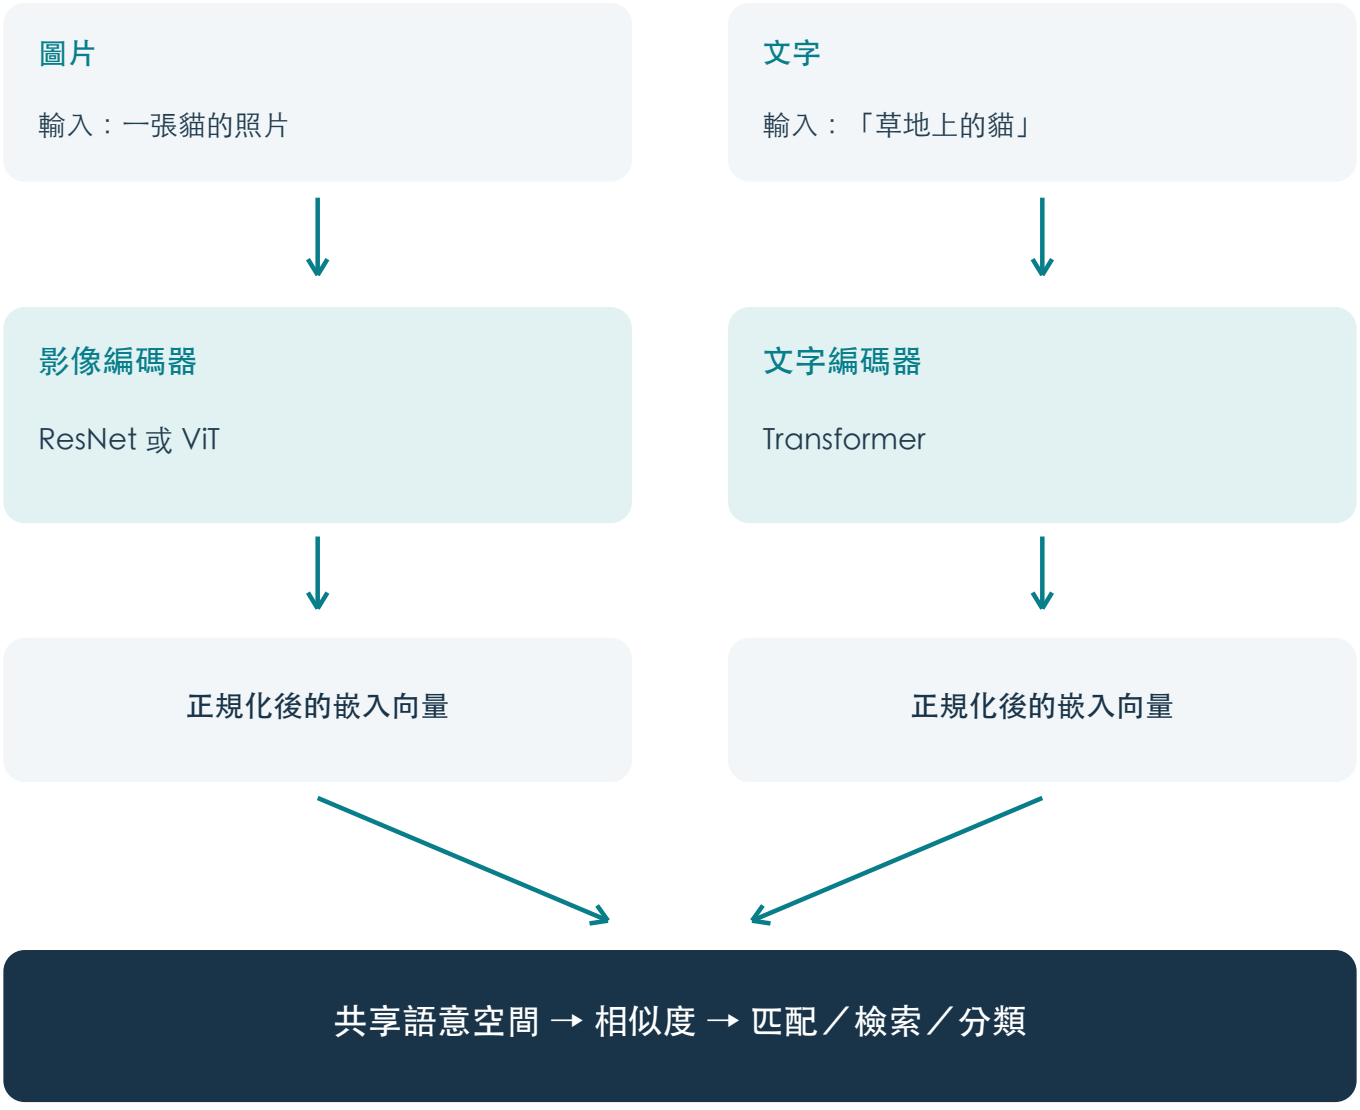
小型結構化特徵可先試拼接；圖文細部問答需要內容互動；既有多模型、不同來源可能失效時，可評估決策融合與降級路徑。最後用相同測試集比較成效、延遲與缺失表現。

來源 [1] 3-74～77；[2] p.64～68；[7]。

CLIP：兩個編碼器，學會互相比對

04 核心模型 A / Contrastive Language-Image Pre-training，對比式語言影像預訓練。

定義與目的：原始CLIP以配對圖片與文字訓練兩個編碼器，學習可比較的表示。它用「哪張圖對哪段文字」建立關係，而不是逐詞生成描述。



容易混淆｜對齊不等於把兩模態放進同一注意力層

原始CLIP是雙編碼器（Dual Encoder），兩分支由對比目標共同學習；沒有跨圖文的token互動層，也沒有文字生成解碼器。要做開放式caption，需另加生成模型或其他機制。

來源 [1] 3-75～76；[5] Q35；[8][9]；原創雙塔示意。

對比學習：讓正確配對在候選中勝出

04 核心模型 B / Contrastive Learning；正負例由資料配對定義，仍可能含雜訊。

延伸補充｜非原教材內容：最小對比算例

一批有兩對圖文：貓圖↔貓描述、狗圖↔狗描述。以下是經縮放的相似度分數 logits，並非原始餘弦值，因此分數2不是超出餘弦範圍的錯誤。

圖片查文字	貓描述	狗描述
貓圖	2（正確配對）	0
狗圖	0	2（正確配對）

$$p_{correct} = \exp(2) / [\exp(2) + \exp(0)] \approx 0.8808$$

exp是指數函數；exp(0)=1，exp(2)≈7.389。先把同列分數轉成正值，再除以總和。訓練希望正確配對的候選機率更高；它不是現實內容正確率。

以自然對數ln計算：單列交叉熵損失 $L = -\ln(0.8808) \approx 0.1269$。原始CLIP同時平均「圖片找文字」與「文字找圖片」兩方向的交叉熵；本例矩陣對稱，總平均也約0.1269。

必記：同批其他配對常當負例，但描述相近、重複圖片或錯標可能產生假負例。共享空間是訓練結果，不是把兩種向量設成同維度就自動得到。

來源 [8][9]；本頁矩陣與損失數值為延伸補充、自編示例。

相似度計算：先看方向，再做排序

05 公式與數學 A / Cosine Similarity，餘弦相似度；本頁數字是自編。

延伸補充｜非原教材內容

$$sim(u, v) = (u \cdot v) / (||u|| \times ||v||)$$

u、v是同一可比較空間的非零向量；「· 」是內積；||u||是向量長度。餘弦值範圍為−1～1，越大代表方向越接近，不是已校準的真實機率。

步驟	圖片u=(1,0)；文字v=(3,4)
1 內積	u· v = 1×3 + 0×4 = 3。
2 向量長度	||u|| = √(1²+0²)=1；||v|| = √(3²+4²)=5。
3 相似度	sim = 3 / (1×5) = 0.6。
4 比較另一描述	若w=(0,2)，sim(u,w)=0；此候選組中v較相近。

考題陷阱｜0.6不是「有60%機率是真的」

零向量會讓分母為0，需按系統規則處理；不同模型或不同候選集的分數不宜直接混用。即使對候選分數做softmax，數值仍取決於候選及縮放，不能直接當事實可信度。

來源 [8][9]；公式算例為延伸補充，不宣稱歷屆原題。

零樣本分類與檢索：選候選，不是生句子

04 核心模型 C / Zero-shot指下游任務無額外標註訓練，不是完全沒訓練。

準備候選文字

例如「一張貓的照片」「一張狗的照片」；先定義要辨識的範圍。

↓

分別編碼並比較

圖片與候選文字各自轉向量，計算相似度並排序。

↓

輸出候選或搜尋結果

分類取最高者；檢索取前k筆。需要時設拒答／人工檢查規則。

「零樣本」仍使用已預訓練的模型；沒有為這個下游分類器再蒐集標註訓練，不代表類別從未以任何方式出現在預訓練資料。文字模板、領域差異與候選集合都可能改變結果。

任務	輸入／輸出	評估重點
圖文檢索	文字找圖、圖片找文字。	排序是否找回相關項目；例Recall@k。
零樣本分類	圖片 + 候選文字 → 選類別。	分類指標、各類別與域外樣本。
圖片描述／問答	圖片（+ 問題）→新文字回答。	需要生成或任務模組；原始CLIP不直接輸出新句子。

延伸算例：每個查詢恰有1筆正解，4個查詢中3個的正解進入前5名，Recall@5=3/4=75%。若每查詢有多筆正解，應另明確定義逐筆召回或命中率，不能混稱。

來源 [1] 3-76；[5] Q35公告A；[8][9]；召回數值為自編。

BLIP與BLIP-2：補上理解與生成的橋樑

04 核心模型 D / BLIP：Bootstrapping Language-Image Pre-training。

BLIP：結合圖文表示與生成任務，並用產生描述與篩選來改善含雜訊的網路圖文資料。這些合成描述是訓練資料處理策略，不代表標註天然正確。

BLIP-2：保留預訓練模型，訓練連接方式



Q-Former（Querying Transformer，查詢Transformer）以可學習的查詢擷取視覺資訊。BLIP-2分兩階段：先學圖文表示，再把視覺資訊連到語言生成。它不是把原始CLIP改名，也不是把全部模型從零重訓。

概念	記憶關鍵	容易誤選
BLIP	圖文理解＋生成；描述產生與篩選。	把全部合成描述直接當黃金標註。
BLIP-2	凍結影像編碼器與LLM，訓練橋接。	宣稱推論時不用跑影像編碼器或LLM。
與CLIP比較	CLIP重點是圖文表示對齊與相似度。	把對比學習直接當逐詞生成機制。

應用：商品圖片描述、圖片問題回答（Visual Question Answering, VQA）。仍需檢查圖像證據；能流暢描述，不保證細節正確或不存在幻覺。

來源 [1] 3-77；[10][11]；結構為原研究概念重繪。

其他代表模型：看訓練目標與連接方式

04 核心模型 E / 保留原教材模型辨識；研究例不等於現行產品規格。

模型	核心機制	適合記住的差異
Flamingo	視覺編碼器、Perceiver Resampler及插入語言模型的跨注意力；可接受交錯圖文。	少樣本情境可在提示中給圖文示例；不是原始CLIP雙塔架構。
M3AE	Multimodal Masked Autoencoder：統一編碼器，從遮罩的圖像／文字詞元學習表示。	學習目標是遮罩重建；可利用配對與非配對資料，不等於通用繪圖產品。
ImageBind	以影像配對為樞紐，學圖像、文字、音訊、深度、熱影像、IMU六種模態的共同嵌入。	不必每兩種模態都有直接配對；共同空間仍需訓練，非保證任意模態自動互通。

Perceiver Resampler：將視覺特徵整理成固定數量表示的橋接模組；IMU（Inertial Measurement Unit，慣性測量單元）提供加速度、角速度等訊號。了解作用即可，暫不必背各模型參數規格。

判斷法｜對比、重建、生成與注意力分開看

對比與遮罩重建是學習目標；注意力是資訊互動機制；生成是輸出能力。它們可以組合。原教材的商用模型名稱只作用途例，不能憑名稱推論未公開架構、模態範圍或精度保證。

來源 [1] 3-73、3-75、3-77～78；[12][13][14]。

語音與感測：不能只剩下文字與圖片

06 應用流程 A / ASR、NLU、NMT、TTS各有角色；感測器需要身分與時序。

語音助理：一條常見串接流程



ASR = Automatic Speech Recognition，語音辨識；NLU = Natural Language Understanding，自然語言理解；TTS = Text-to-Speech，文字轉語音。跨語言可加NMT（Neural Machine Translation，神經機器翻譯）。

例：「倉庫現在幾度？」→辨識問題→查正確感測器與時間戳→產生有依據的答覆→播出。ASR文字可能遺失語調與背景音；若任務需要異音或韻律，應保留音訊特徵。

整合場景	互補線索	上線前要驗證
智慧城市	交通影像＋車流／環境感測。	同路段、同時間；異常與斷線情境。
自動駕駛／機器人	攝影機＋雷達／深度／超音波。	時間同步、座標校正、遮蔽與安全處理。
智慧醫療（技術例）	影像＋紀錄＋生命徵象。	同一對象、有效時間窗、資料缺失與專家查核。

必記｜模組串接可以是多模態系統，不保證保留所有資訊

語音轉文字後交給文字模型，是系統層的跨模態流程；不代表文字模型本身直接理解聲音。若前段漏辨識或對錯感測器，後段再流暢也無法自動修復事實。

來源 [1] 3-76～77；[2] p.62、69；語音例為自編。

時間同步與DTW：先對時，再談序列變形

05 公式與流程 B / Dynamic Time Warping，動態時間校正；不是萬用同步工具。

延伸補充｜非原教材內容：時間對齊示例

固定時鐘偏移：相機事件時間1.0秒，已知振動裝置時鐘快0.2秒，振動紀錄1.2秒可校正為1.0秒。校正的是已知偏移；仍要確認設備、延遲與事件相同。

問題	可評估的方法	不可混淆
時鐘偏移／漂移	時鐘同步與偏移校正。	不應用任意變形來掩蓋錯誤時間。
取樣頻率不同	重取樣、區間彙整、時間窗。	需考慮混疊、延遲與資料可用時間。
同一動作速度不同	DTW對齊可比較的特徵序列。	需要合理的距離與路徑限制，不是直接算文字與像素差。

DTW例：X=[1,2,3]；Y=[1,1,2,3]

i、j為兩序列的位置，局部代價取|x_i−y_j|。合法路徑可為(1,1)→(1,2)→(2,3)→(3,4)；對應值全相同，因此總代價為0。它允許較慢的序列重複對到同一位置，而不改變先後順序。

必記：DTW保留單調路徑，能處理速度差；不負責語意空間學習。對即時系統還須設時間窗與延遲限制，不能使用預測當下尚未取得的未來資料。

模態缺失與衝突：訓練時就準備降級路徑

02 核心知識 G / Missing Modality；多一個來源也可能多一個失敗點。

做法	作用	條件與限制
缺失標記／遮罩	告訴模型哪一模態不可用。	不是把缺失當有效的全零觀測；訓練需見過相似缺失。
模態隨機丟棄訓練	Modality Dropout：訓練時隨機停用完整模態，減少過度依賴。	不同於只丟少量神經元；仍要測實際缺失模式。
分支降級／品質權重	停用失效分支、使用可用分支或轉人工。	剩餘模態必須足夠，權重和門檻重新驗證。
推估缺失模態	產生替代表示供模型使用。	推估可能有幻覺或偏差；需標成推估，不能當實測。

延伸算例：沿用p.8權重，若振動缺失且系統允許只用影像，分數可按有效權重重正規化：(0.7×0.8)/0.7=0.8。若直接把振動當0又保留原權重，只得到0.56，代表另一套決策規則，不能偷偷混用。

互相衝突時：先查時間、設備身分與資料品質，再評估信心、替代來源及人工處理。模型自行把兩個矛盾說法平均成一句話，不是證據查核。

【歷屆已考】114第二次 Q21 公告B：訓練可感知並適應模態缺失的模型；不是宣稱固定補0、生成補全或丟樣本在所有場景都最有效。

企業應用：先定義任務，再找互補資料

06 應用流程 B / 下列為教學情境，成效需要實證，不保證優於單模態。

場景	資料與任務	成效與主要限制
醫療決策支援	影像＋病歷＋生命徵象，支援風險預測與摘要。	按任務評估漏報、誤報及報告依據；分對象測試、專家查核。
零售／電商	商品圖片＋評論＋交易資料，做搜尋、推薦與分析。	看檢索相關性、分類及線上業務指標；留意個資與偏差。
虛實互動／教育	語音＋手勢＋畫面，做導覽、會議或互動教學。	看意圖／手勢辨識、任務完成率與延遲；測衝突指令。
製造／機器人	瑕疵影像＋振動／溫度＋維修紀錄，預警或查因。	看漏報、誤報、停機影響；要對同一設備與工況。
金融安全	交易＋聲音／裝置行為，輔助辨識異常。	比較攔截與誤拒、各族群表現；聲音相似不等於身分已驗證。

例：把貨架動線影像與POS（Point of Sale，銷售時點）資料放到BI（Business Intelligence，商業智慧）儀表板，能幫助觀察。若宣稱模型已融合並改善決策，仍需說明配對、整合方式與驗證結果。

界線：本節介紹技術選擇與評估，不提供診療、授信或法律判斷；上述改善方向是應用目標，不能把教材案例中的「提升」當成已保證的實際效果。

來源 [1] 3-78～80；[2] p.69；[3] AI導入成效與風險；情境為轉述。

指標要對準任務：整合越多，越不能只看一分數

05 公式與評估 C / 數值例為自編；語音與文字指標延續3.3。

任務	可用指標	容易誤判
分類／預警	準確率Accuracy、精確率Precision、召回率Recall、F1、假陽性率FPR；必要時看校準。	類別不平衡只看Accuracy；把模型信心當正確性。
搜尋／推薦	Recall@k、排序相關性；線上轉換與滿意度。	離線排序好，便保證營收增加。
區域偵測／分割	IoU（Intersection over Union，交並比）等。	IoU只能評估有對應區域的任務，不能直接代表整條動線或銷售成效。
語音／報告／互動	WER、ROUGE、人工事實查核；任務完成率與Latency。	字詞重疊高便代表報告正確；只看平均延遲忽略慢請求。

延伸補充｜非原教材內容：不平衡反例

假設1000筆中只有10筆陽性；模型全判陰性，TN=990、FN=10、TP=0、FP=0。Accuracy=(TP+TN)/N=990/1000=99%，但Recall=TP/(TP+FN)=0/10=0，完全漏掉陽性。

符號：TP真陽性、TN真陰性、FP假陽性、FN假陰性；N為總筆數。假陽性率FPR=FP/(FP+TN)，本例為0；FPR=0也不能掩蓋漏報。它不同於1−Precision。

必記：報告相似度、生成流暢度、分類效能、業務成效與安全性各有不同證據。先定義代價，再選門檻與指標；不要把一個高分當整套系統通過。

運算與部署：先找瓶頸，再決定怎麼縮小

06 應用流程 C / 影像尺寸、音訊長度、序列數量都會影響成本與延遲。

手段	主要改變	必須驗證
量化 Quantization	用較低數值精度表示權重／運算。	硬體與算子支援、精度損失、實際記憶體與延遲。
剪枝 Pruning	移除部分權重或結構。	稀疏或結構化結果能否被執行環境加速。
知識蒸餾 Distillation	由教師模型協助訓練較小學生。	學生在各模態、缺失與困難案例的表現。
LoRA低秩適應	凍結基礎權重，訓練小型低秩更新。	降低的是可訓練參數；不自動縮小基礎模型或省下全部推論成本。
雲端／邊緣／混合	安排模型與資料在哪裡處理。	網路、頻寬、設備算力、離線需求與資料保護。

工具辨識：TensorRT、OpenVINO是推論最佳化／執行工具例；MobileNet是輕量視覺網路例。工具不保證每個模型都加速，需確認版本、硬體與運算支援，再量測整條流程。

記憶法｜訓練便宜、模型較小、推論較快是三件事

凍結大模型或使用LoRA可減少訓練更新與記憶體負擔；推論仍可能需要整個基礎模型。降低影像解析度或抽少影片幀數可省運算，但可能漏掉小字、細節或短暫事件。

風險：多條線索，也多了攻擊與洩漏的入口

07 常見陷阱與治理 / 安全措施要看威脅與情境，不能當全面保證。

風險	為何多模態特別要查	對應做法與界線
隱私／身分連結	遮臉後，聲紋、衣著、地點或時間仍可能連回個人。	最小蒐集、分離身分、存取權限與留存控管；遮罩不等於保證匿名。
偽造／冒用	合成影像與聲音可一起建立誤導情境。	獨立管道驗證、來源查核與敏感操作審核；偽造偵測器也會誤判。
圖像／音訊提示注入	圖片上的字、語音或檢索內容可能藏惡意指令。	外部內容當資料；系統限制工具與授權，不只靠模型一句拒絕。
偏差與捷徑學習	模型可能依賴背景、設備或某模態易取得的線索。	分群測試、換場景驗證、消融與錯誤分析。
標註與語境不一致	錯配圖文、過期紀錄或合成標註帶入錯誤。	標記來源、版本、時間與推估狀態；抽查，不把生成內容當事實。

加密可降低特定傳輸／儲存暴露，但不能保證已授權端點不會誤用。臉部或聲音辨識的高分也不等於獲得操作權限；身分、任務授權與外部動作應分層檢查。

【教材重點】原指引提及個資、GDPR、HIPAA等法規例；是否適用須依所在地、角色與資料情境判斷。本冊保留治理觀念，不把外國法規視為臺灣所有系統一體適用的要求。

來源 [1] 3-80～82；[2] p.70；[3] 風險管理；[18]；情境為自編。

導入驗證：證明新增模態值得付出成本

06 應用流程 D / Ablation Study，消融實驗：有控制地移除部分資訊或模組。

定義任務與資料契約

同一對象與時間窗、輸入可用時間、成功指標及可接受延遲。

↓

建立單模態與多模態基準

用相同切分比較各單分支、簡單融合與較複雜架構。

↓

測缺失、雜訊與衝突

不只看全資料齊備；按缺失型態、場域與族群分開評估。

↓

小範圍發布並持續監控

記錄來源、版本、權重與降級；監控品質、P95延遲、成本和人工介入。

延伸算例：同一測試集，影像F1=0.82、文字F1=0.75、融合F1=0.84，融合比最佳單模態高0.02（絕對值）。這只是觀察差異；仍須評估樣本不確定性、成本及失效場景，不能直接稱提升2%的所有業務成果。

資料管理：弱監督（Weak Supervision）可用規則或弱標籤降低標註成本，但要抽查；配對索引、分散式儲存及資料版本也需維護。

必記｜切分單位決定有沒有資料洩漏

同病患、同設備、相鄰影片幀或同一事件可能高度相似；訓練與測試若互相混入，成效會過度樂觀。依實際部署用對象／事件／時間切分；融合權重與門檻在驗證集選，測試集留作最後評估。

來源 [1] 3-80～81；[3] 導入評估／監控；[7]；流程與數值為延伸。

趨勢與選型：方向可以記，保證不能背

08 重要理解與補充 / 依原指引的發展方向整理，不做當前產品排名。

方向	為什麼重要	考題判斷界線
統一架構／共享表示	減少模態隔閡，擴充輸入與任務。	統一不代表每層相同、不需要前處理或任意模態都能直接輸入。
低資源與即時部署	面向移動端、邊緣設備與互動需求。	壓縮與抽樣需查品質；本地端也不等於沒有隱私與維運問題。
自我監督學習	Self-supervised Learning：由資料本身建立學習目標，降低人工標註依賴。	圖文配對仍是監督訊號，未人工逐筆標註不等於完全沒有資料關係。
多模態 + Agent	模型觀察畫面、聲音，再用工具完成任務。	感知高分不等於工具動作可靠；仍需驗證、授權、停止與回復機制。
倫理與治理	來源、個資、偽造與稽核貫穿生命週期。	檢測器、水印、去識別或對抗訓練都是部分措施，沒有單一萬靈丹。

工具選型順序：先分清要「編碼／檢索」「問答／生成」「音訊轉換」「模型執行」還是「資料管理」。模型權重、推論函式庫、服務介面與應用產品是不同層次，不能互當同義詞。

學習優先：先能看懂融合位置、對齊與失效，再認識代表模型與工具。進階研究的層數、參數量與產品現行功能，不屬本冊優先背誦項。

考試重點：有證據的概念先掌握

09 考點索引 / 紅色優先、橙色理解、綠色補充；這是學習順序，不是配分。

知識點	優先程度	考查方式與判斷依據
模態特性與編碼器	優先掌握	【歷屆已考】115 Q17=D：依影像、文字、時序特性選架構。
共同語意空間	優先掌握	【歷屆已考】115 Q18=D：跨模態對齊的目的。
CLIP與零樣本	優先掌握	【歷屆已考】114 Q35=A：圖文對比學習與候選相似度。
模態缺失處理	優先掌握	【歷屆已考】114 Q21=B：訓練可感知缺失狀況的模型。
融合位置與雜訊	優先掌握	【歷屆已考】115 Q50=D（問最不可能）；【教材重點】附件p.64～68。
應用／同步／部署風險	重要理解	【官方評鑑】L21104及相關導入／部署項；【教材重點】3-76～83。
BLIP／Flamingo／M3AE	重要理解	【教材重點】3-75、3-77～78；理解機制差異。
完整損失推導／模型規格	補充認識	【推測題型】本冊計算用於理解；目前未見兩卷直接考完整推導。

考前必記｜五個判斷

① 對齊建對應，融合整合資訊。② CLIP雙塔比相似，不直接生描述。③ 晚期在決策層，不是輸入層。④ 缺失要標記、訓練與驗證。⑤ 多模態的優勢要有基準與失效測試支持。

來源 [4] L21104；[5] 114第二次；[6] 115第一次；教師分類。

常見陷阱與教材比對：保留範圍，補足條件

10 完整性檢查 / 原文含過度概括或名詞混用時，以可查證機制釐清。

易誤記說法	本冊採用的精確判斷
CLIP可以直接生成caption	原始CLIP只有雙編碼器與相似度；需額外生成機制。
CLIP是跨圖文注意力例	原始CLIP用對比目標對齊；Flamingo有跨注意力。
晚期是特徵層融合	本冊依決策層整合；原指引3-77的層級用語需釐清。
晚期融合不需對齊	仍要同對象、類別與時間窗；只是不必逐token交互。
多模態一定更準、更完整	可能受雜訊、錯配、偏差與缺失影響；用消融驗證。
LoRA會縮小基礎模型	減少可訓練參數，不自動省去基礎模型推論。
遮臉後就完成匿名化	其他模態或背景仍可能重新識別，需要情境風險評估。

已覆蓋：定義與演進、對齊／融合、CLIP及代表模型、語音與感測器、醫療／零售／虛實互動、標註與資料管理、部署、安全隱私及五項發展方向；附件的製造與金融例也保留。

待後章深入：完整部署操作、進階數學推導及各法規條文；本冊不將其細節當成已完成。只查讀兩附件與本節相關頁，未宣稱附件全書每個主題都已處理。

證據邊界：兩份科目一各50題，以題號建索引，未將同題多概念重複計為多題，也未據此推算未來出題率。三題自編練習及數字例均不冒稱歷屆原題。

比對 [1] 3-73～83；[2] p.61～70；[3] 相關章；[8]～[18]。

練習1／2：辨識模型與失效處理

11 自編中級單選 / 非官方原題 / 三題解析均在最後p.31～33。

01 基礎概念與比較

電商團隊使用原始CLIP，以商品圖片和四段候選文字做零樣本分類。下列敘述何者最正確？

A 模型不曾做任何預訓練，因此稱為零樣本。

B 圖文各自編碼，再以共同空間中的相似度比較候選。

C 每一次分類都必須由跨圖文注意力逐詞生成新描述。

D 相似度0.8表示商品描述具有80%的客觀正確機率。

我的選擇：_____

02 比較與應用

工廠使用影像與振動的晚期融合模型。相機鏡頭被遮住，影像不可用；振動仍正常。下列處理何者最合理？

A 固定把影像分數設為0且保留原權重，便保證決策不受影響。

B 依振動生成一張假想正常照片，當作已拍到的現場影像。

C 標記影像缺失，啟用已驗證的振動分支降級流程，必要時轉人工。

D 晚期融合位於輸入層，所以不必管理模態缺失。

我的選擇：_____

練習3：融合分數、門檻與缺失權重

11 自編中級單選計算題 / 依本題明示規則計算，不推論真實機率。

某預警系統有影像與振動兩分支，皆預測同一目標事件。分數與權重如下；兩模態齊備時做加權平均，分數≥0.60則預警。若影像缺失，題設允許只用振動，並將有效權重重正規化。哪一組結果正確？

分支	預測分數	原權重
影像	0.90	0.40
振動	0.30	0.60

A 齊備分數0.54、不預警；影像缺失後分數0.30。

B 齊備分數0.60、預警；影像缺失後分數0.30。

C 齊備分數0.54、不預警；影像缺失後分數0.18。

D 齊備分數0.90、預警；影像缺失後分數0。

我的選擇：_____

請分別列出：兩模態貢獻、總分、缺失後有效權重。

考前3分鐘：先配對，再互動，最後驗證

12 章節總整理 / 八個重點，回想資料流與失效條件。

01 模態與互補

不同資料型態提供不同線索；多檔案、多格式不等於多模態整合。

02 對齊

樣本／時間／空間／語意各有問題；同維度不等於共同語意。

03 融合位置

早期：共同模型前；中期：表示互動；晚期：各自預測後整合。

04 CLIP

雙編碼器 + 圖文對比；零樣本比較候選，不直接逐詞產生描述。

05 模型目標

BLIP-2橋接；Flamingo跨注意力；M3AE遮罩重建；ImageBind共同嵌入。

06 計算

餘弦=內積／長度乘積；融合=加權加總；分數不是事實保證。

07 缺失與驗證

缺失標記、模態丟棄訓練、已驗證降級；消融比較最佳單模態。

08 部署與治理

對齊與資料契約、來源版本、任務指標、延遲成本、隱私授權一起管理。

記憶順序：資料對得上 → 模型合得好 → 缺失能處理 → 新增模態有價值。

來源索引與證據範圍

13 來源可追溯 / 藍綠色條目可點開；圖解、算例與三題均自行編製。

[1] 官方科目一學習指引：3-73～3-83（PDF p.80～90）。

[2] 附件001_人工智慧技術應用：PDF p.61～70。

[3] 附件002_AI導入評估：PDF p.12～16、24～35、48～50、71～73、84。

[4] 官方評鑑內容範圍參考115.06：L21104及相關銜接項目。

[5] 114第二次科目一：Q21、Q35。

[6] 115第一次科目一：Q17、Q18、Q50。

[7] Baltrušaitis等 | Multimodal Machine Learning: A Survey and Taxonomy。

[8] Radford等 | Learning Transferable Visual Models From Natural Language Supervision。

[9] 原作者CLIP程式與用法：編碼、正規化、候選相似度。

[10] Li等 | BLIP：圖文理解與生成。

[11] Li等 | BLIP-2：凍結影像編碼器與大型語言模型的橋接。

[12] Alayrac等 | Flamingo: a Visual Language Model for Few-Shot Learning。

[13] Geng等 | Multimodal Masked Autoencoders Learn Transferable Representations。

[14] Girdhar等 | ImageBind: One Embedding Space To Bind Them All。

[15] Müller | FMP：Dynamic Time Warping教學與路徑定義。

[16] Neverova等 | ModDrop: adaptive multi-modal gesture recognition。

[17] Hu等 | LoRA: Low-Rank Adaptation of Large Language Models。

[18] OWASP | LLM01:2025 Prompt Injection。

證據標示：【官方評鑑】能力範圍；【歷屆已考】上述兩卷實際題號；【教材重點】原指引與附件；【推測題型】教師推估，非官方出題承諾。公告答案以原卷標示，解析為本冊教學整理。

延伸補充｜非原教材內容：本冊融合／缺失權重、對比損失、餘弦、DTW與指標數值、消融流程、空間例與注入情境用於理解；不是每個細節都由官方逐一列為必考。進階推導有助理解，不建議優先背誦。

本章可讀範圍：官方3.4及附件001多模態專章，附件002僅相關銜接。圖解非模型實測結果；產品名稱僅作教材辨識，不宣稱現行規格、價格或法律適用結論。

附錄解析1：CLIP是比較候選的雙編碼器

14 答案與逐項解析 / 第1題 / 題目見p.27。

正確答案 B

原始CLIP已先利用大量配對圖文預訓練。下游零樣本分類時，把圖片與候選文字分別編碼，再以共同嵌入空間中的相似度選候選，不需要逐詞產生描述。

選項	判斷與理由
A 錯誤	零樣本是下游任務不做額外標註訓練，不是完全沒有預訓練。
B 正確	符合原始CLIP的雙編碼器與對比學習後的候選比較方式。
C 錯誤	把跨圖文注意力與生成解碼器當成原始CLIP必要結構，混淆模型。
D 錯誤	相似度衡量表示方向或匹配關係，不直接等於客觀正確機率。



解題口訣｜兩塔比相似；生成要另有機制

判題先分清模型架構、訓練目標與下游任務。候選最高只能說在該集合中較相似；若候選全錯，也仍可能排出第一名。回到p.10～14。

附錄解析2：缺失要明示，降級要先驗證

14 答案與逐項解析 / 第2題 / 題目見p.27。

正確答案 C

鏡頭被遮住代表該模態不可用。合理流程是標記失效，採用已訓練並驗證的振動分支降級規則；若剩餘資訊或信心不足，就轉人工或進入預先定義的保守流程。

選項	判斷與理由
A 錯誤	補0會改變分數意義，保留權重也可能壓低預警；不能保證不受影響。
B 錯誤	推估照片不是現場實測，當作已觀測資料會掩蓋缺失與不確定性。
C 正確	明示缺失，使用經驗證的降級路徑，並保留必要的人工介入。
D 錯誤	晚期融合在各分支預測後整合決策，不在輸入層；也仍須處理缺失。

解題關鍵｜能繼續輸出，不代表仍然可靠

事先測試只剩某模態時的漏報、誤報、門檻與延遲，不能等失效才臨時發明權重。若應用規則要求兩來源確認，也不能擅自單分支放行。回到p.8～9、p.18、p.23。

附錄解析3：依題設加權，再重正規化

14 答案與逐項解析 / 第3題 / 題目見p.28。

正確答案 A

步驟	計算與結果
影像貢獻	0.40×0.90=0.36。
振動貢獻	0.60×0.30=0.18。
模態齊備	0.36+0.18=0.54；小於0.60，不預警。
影像缺失	有效權重合計0.60；(0.60×0.30)/0.60=0.30。

0.54 < 0.60；缺失後 0.18 / 0.60 = 0.30

選項	判斷與理由
A 正確	齊備總分0.54不預警；只保留振動並重正規化後為0.30。
B 錯誤	把兩模態分數直接平均得到0.60，忽略題設0.40／0.60權重。
C 錯誤	0.18只是振動按原權重的貢獻，尚未除以有效權重0.60。
D 錯誤	0.90只取影像分數，且把影像缺失誤當所有可用線索皆為0。

本題已明示允許單分支及重正規化，才能依此算。實務的降級規則與門檻必須另驗證；本例分數不能直接當已校準的真實機率。回到p.8、p.18。